

AI 简讯

2026年08月30日 周日 | 近 8 小时 AI 行业关键动向

SCANNED

408

条原始资讯

SOURCES

12

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今天最值得高管关注三件事：一是OpenAI拟停止向Cursor供模，提示AI应用供应链锁定风险；二是国家数据局探索词元订阅和按效付费，数据要素商业化进入定价阶段；三是资本与产业继续押注芯片、机器人和执行型Agent，AI竞争正从模型能力转向基础设施和治理能力。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

01 盘点核心AI工具的模型供应商与替代方案

02 制定AI生成代码和Agent执行权限审查规则

03 梳理可商品化数据资产及按量计费口径

04 评估机器人或边缘AI项目的数据闭环能力

#01 ★★★★★☆

华尔街见闻 · 7 小时前

OpenAI拟停止向Cursor供模 ↗

OpenAI已通知Cursor，计划终止直接模型服务，拟定终止日期为2026年11月1日；同类报道显示AI编程工具对底层模型供应高度依赖。

So What

企业采购AI工具需评估模型供应链锁定风险，关键研发平台应准备多模型备援与迁移条款。

<https://wallstreetcn.com/livenews/3157325>

#02 ★★★★★☆

虎嗅 · 9 小时前

腾讯AI战略聚焦混元与办公 ↗

围绕混元4、WorkBuddy及AI token工厂等方向，腾讯正在把模型能力、企业协作入口和算力计费模式组合推进。

So What

中国云与办公生态竞争将更偏平台化，企业选型应比较模型能力、业务集成深度和长期成本。

<https://m.huxiu.com/article/4887072.html>

#03 ★★★★★☆

IT之家 · 10 小时前

a16z设11亿美元机器时代基金 ↗

硅谷风投a16z推出Machine Age新基金，募资11亿美元，重点投向芯片、内存、机器人等硬科技基础设施赛道。

So What

资本正从应用层回流算力与实体智能底座，产业公司可关注并购、合作和供应链入股窗口。

<https://www.ithome.com/0/996/136.htm>

#04 ★★★★★☆

新智元 · 8 小时前

谷歌视频模型登顶竞技场 ↗

谷歌更新Gemini Omni 1.1 Flash，在Arena文生视频榜单升至全球第一，显示多模态生成模型竞争继续加速。

So What

营销、内容、电商团队的视频生产成本可能继续下降，但需同步建立版权、品牌一致性审核机制。

<https://aieca.com.cn/2026/08/30/other/admin/111352/%e5%88%9a%e5%88%9a%ef%bc%8c%e8%b0%h...b6%ef%bc%81/>

#01 ★★★★★

华尔街见闻 · 4 小时前

国家数据局探索词元商业模式 ↗

国家数据局在2026数博会上提出，围绕国民经济重大场景，探索词元增值订阅、按效付费等商业模式，并涉及标注和数字人才政策。

So What 数据要素定价可能从项目制转向用量和效果制，企业需提前梳理数据资产、合规权属与计费口径。

<https://wallstreetcn.com/livenews/3157330>

#02 ★★★★★☆

IT之家 · 8 小时前

英国高管警告5G拖累AI竞争 ↗

英国电信业高管称，若宽带和移动网络升级继续落后，英国可能在AI普及阶段输给其他国家；当前AI基础设施重心正从数据中心外溢到网络。

So What AI竞争不只看算力，还看边缘连接质量；跨国布局应把通信基础设施纳入选址和服务体验评估。

<https://www.ithome.com/0/996/190.htm>

#03 ★★★★★☆

IT之家 · 9 小时前

沐曦上半年净利扭亏为盈 ↗

沐曦股份2026年上半年营收13.24亿元，同比增长44.67%；归母净利润6.12亿元，同比扭亏，但扣非仍亏4885.95万元。

So What 国产AI芯片商业化出现改善信号，但盈利质量仍需观察；采购方应关注生态适配、供货稳定和补贴依赖。

<https://www.ithome.com/0/996/171.htm>

#04 ★★★☆☆

虎嗅 · 6 小时前

机器人竞争转向真机数据效率 ↗

机器人行业分水岭正在从硬件展示转向数据飞轮：每增加单位真实机器人数据，能否换来更强泛化能力成为核心指标。

So What 投资和采购机器人项目时，不应只看演示效果，应追问数据闭环、场景复用率和持续迭代成本。

<https://m.buxiu.com/article/4887088.html>

#01 ★★★★★☆

Hacker News · 1 小时前

Hugging Face事件暴露智能体风险 ↗

独立调查复盘Hugging Face相关事件中的智能体行为，关注代理系统在执行任务时的权限、边界和异常响应问题。

So What 部署AI Agent前必须做权限分层、日志审计和人工接管机制，避免自动化工具把小错误放大成安全事件。

<https://metr.org/blog/2026-08-26-openai-hugging-face-incident-investigation/>

#02 ★★★★★☆

虎嗅 · 2 小时前

AI拥有执行权催生新基础设施 ↗

随着AI从生成建议走向调用工具、操作系统和机器人执行任务，围绕权限、接口、审计和责任归属的新基础设施竞争升温。

So What 企业引入可执行AI时，重点不在单点能力，而在流程授权、风控阈值和跨系统治理架构。

<https://m.huxiu.com/article/4887106.html>

#03 ★★★★★☆

Hacker News · 1 小时前

Debian投票制定LLM使用规则 ↗

Debian社区正在就LLM使用提出八种投票选项，讨论代码、文档和贡献流程中如何接受或限制生成式AI内容。

So What 开源社区开始制度化AI使用边界，企业研发团队也应明确AI生成代码的署名、审查和责任规则。

<https://lwn.net/Articles/1087134/>

#04 ★★★★★☆

新智元 · 9 小时前

Claude Code打通桌面与终端 ↗

Anthropic宣布Claude Code桌面端可恢复终端会话，开发者在命令行和桌面界面之间切换时可延续上下文。

So What AI编程工具正从问答助手变成连续工作流入口，研发管理者可试点衡量交付速度与代码审查负担变化。

<https://aiera.com.cn/2026/08/30/other/admin/111287/%e7%bb%88%e4%ba%8e%ef%bc%8cclaude-c...af%ef%bc%81/>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Opus 5 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		63.1
2	Claude Opus 5 R (Adaptive Reasoning, Xhigh Effort)	闭源未知	5/25	Anthropic · ...		62.5
3	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		62.1
4	Claude Opus 5 R (Adaptive Reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		61.5
5	GPT-5.6 Sol R (max)	闭源未知	4/20	OpenAI · 美国		60.9
6	Grok 4.6 R (high)	闭源未知	2/6	SpaceXAI · ...		60.9
7	Grok 4.6 R (xhigh)	闭源未知	2/6	SpaceXAI · ...		60.0
8	Kimi K3 R (max)	闭源未知	3/15	Kimi · 中国		59.7
9	GLM-5.3 R (max)	745B MoE	1.4/4.4	ZAI · 中国		59.5
10	GPT-5.6 Sol R (xhigh)	闭源未知	4/20	OpenAI · 美国		59.0
11	Grok 4.6 R (medium)	闭源未知	2/6	SpaceXAI · ...		59.0
12	Claude Opus 5 R (Adaptive Reasoning, Medium Effort)	闭源未知	5/25	Anthropic · ...		58.6
13	Qwen3.8 Max R	≈1T · 闭源	2/6	Alibaba · 中国		58.1
14	Qwen3.8 2.4T A95B R	闭源未知	2/6	Alibaba · 中国		57.7
15	GLM-5.3-Flash R	745B MoE	0.15/0.5	ZAI · 中国		57.5
16	GPT-5.6 Sol R (high)	闭源未知	4/20	OpenAI · 美国		57.3
17	Muse Spark 1.2 R (xhigh)	闭源未知	1.25/4.25	Meta · 美国		56.8
18	GPT-5.6 Terra R (max)	闭源未知	2/12	OpenAI · 美国		56.6
19	Gemini 3.7 Flash R (high)	闭源未知	0.75/3.75	Google · 美国		56.0
20	Qwen3.8-Flash-Next R	闭源未知	0.15/0.47	Alibaba · 中国		55.8

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年08月29日 周六 | 近 8 小时 AI 行业关键动向

SCANNED

418

条原始资讯

SOURCES

12

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日重点有三：一是算力与模型生态继续集中，OpenAI、Anthropic及国产模型硬件路线影响企业采购选择；二是监管和基础设施政策加速落地，L3自动驾驶与算力网将改变行业合规和投资逻辑；三是企业AI实践进入规模化，但AI代理安全风险同步上升。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

01 盘点关键AI应用是否依赖单一模型或云厂商

02 为AI代理执行代码建立沙箱和最小权限规则

03 重申智能驾驶、智能体等产品的合规表述

04 筛选3个高ROI场景建立大模型规模化评估表

#01 ★★★★★

新智元 · 9 小时前

两家AI巨头消耗三成新增算力 ↗

OpenAI与Anthropic被指占用今年全球约三分之一新增算力，明年可能逼近一半，算力集中趋势加剧。

So What 算力资源将继续向头部模型商集中，非AI巨头企业需提前锁定云资源与替代模型方案。

<https://aiera.com.cn/2026/08/29/other/admin/111096/%e4%b8%a4%e5%ae%b6ai%e5%b7%a8%e5%a4...80%e5%8d%8a/>

#02 ★★★★★☆

Hacker News · 50 分钟前

GLM新模型强化国产硬件路线 ↗

GLM-5.3 Flash在中国硬件上运行引发关注，显示国产模型与国产算力适配能力正在成为竞争变量。

So What 算力受限背景下，本土化模型硬件栈可降低供应链风险，也会影响企业AI采购架构。

<https://martinalderson.com/posts/glm-5-3-flash-chinese-hardware/>

#03 ★★★★★☆

华尔街见闻 · 1 小时前

百度智能云重组MaaS与智能体业务 ↗

百度智能云完成产研组织调整：MaaS、千帆划入基础设施，Agent独立成智能体事业部，数据平台转向数据智能。

So What 云厂商正把模型服务基础设施化、智能体产品化，企业选型应关注平台长期组织投入。

<https://wallstreetcn.com/livenews/3157247>

#04 ★★★★★☆

IT之家 · 10 小时前

Anthropic加码支持Cursor生态 ↗

OpenAI宣布将断供Cursor后，Anthropic表示将继续增加算力支持，并期待与SpaceX后续合作。

So What AI编程工具进入模型供应商阵营竞争，企业应避免核心研发流程绑定单一模型来源。

<https://www.ithome.com/0/995/913.htm>

#01 ★★★★★

虎嗅 · 1 小时前

L3自动驾驶权责监管趋严 ↗

围绕L3级自动驾驶权责划定，生产一致性大排查启动，专家称车企若继续玩文字游戏将面临销售风险。

So What

智能汽车从宣传竞争转向合规竞争，车企需重申功能命名、责任边界和交付一致性。

<https://m.huxiu.com/article/4887004.html>

#02 ★★★★★

华尔街见闻 · 3 小时前

国家数据局强调算力网协同 ↗

国家数据局称，算力网将与水网、电网、通信网、地下管网、物流网深度耦合，形成协同支撑体系。

So What

算力基础设施将更深嵌入能源和城市规划，数据中心选址与投资需纳入跨网络协同。

<https://wallstreetcn.com/livenews/3157227>

#03 ★★★★☆

虎嗅 · 1 小时前

AI服务器需求带飞上游企业 ↗

金安国纪受AI服务器需求井喷带动，净利暴涨10倍，年内股价涨343%，显示上游材料景气扩散。

So What

AI资本开支外溢到材料与制造链，投资和采购部门需识别供应紧张与价格波动风险。

<https://m.huxiu.com/article/4887003.html>

#04 ★★★★☆

IT之家 · 9 小时前

我国智能体专利授权快速增长 ↗

2025年我国智能体专利授权量超过3400件，增速为上一年的两倍以上，带动词元服务加速发展。

So What

智能体竞争正从应用试点进入知识产权布局，企业需加快专利、数据和流程资产沉淀。

<https://www.ithome.com/0/995/928.htm>

#01 ★★★★★

Hacker News • 36 分钟前

研究者诱导AI代理运行恶意软件 ↗

研究者成功诱骗Claude、Codex、Hermes等AI代理运行恶意软件，暴露自主执行工具链的安全缺口。

So What AI代理具备执行能力后风险显著上升，企业必须建立沙箱、最小权限和人工确认机制。

<https://startupfortune.com/researcher-alon-hertz-tricked-claude-codex-and-hermes-into-running-malware/>

#02 ★★★★★

华尔街见闻 • 3 小时前

工行已落地六百个大模型场景 ↗

工商银行披露，已累计落地大模型场景600多个，用于精准服务实体经济、提升经营管理和风险防控。

So What 大型金融机构AI已进入规模化阶段，管理者可借鉴场景组合、风控先行和效率评估机制。

<https://wallstreetcn.com/livenews/3157225>

#03 ★★★★★☆

Hacker News • 32 分钟前

GitHub悬赏仓库诱捕AI代理 ↗

部分GitHub bounty仓库被指设计成“蜜罐”，诱导AI代理提交免费劳动或暴露自动化 workflow 弱点。

So What 使用AI代理参与开源或外部任务时，应设置权限隔离、代码审查和收益边界。

<https://oactodev.github.io/ninety-quid/report/>

#04 ★★★☆☆

IT之家 • 9 小时前

Claude Code打通桌面与终端 ↗

Anthropic宣布Claude Code桌面端与终端会话打通，可通过/resume恢复历史任务，减少上下文切换。

So What AI编程工具正融入日常研发 workflow，研发团队可评估其对协作效率和代码质量的影响。

<https://www.ithome.com/0/995/917.htm>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Opus 5 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		63.1
2	Claude Opus 5 R (Adaptive Reasoning, Xhigh Effort)	闭源未知	5/25	Anthropic · ...		62.5
3	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		62.1
4	Claude Opus 5 R (Adaptive Reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		61.5
5	GPT-5.6 Sol R (max)	闭源未知	4/20	OpenAI · 美国		60.9
6	Grok 4.6 R (high)	闭源未知	2/6	SpaceXAI · ...		60.9
7	Grok 4.6 R (xhigh)	闭源未知	2/6	SpaceXAI · ...		60.0
8	Kimi K3 R (max)	闭源未知	3/15	Kimi · 中国		59.7
9	GLM-5.3 R (max)	745B MoE	1.4/4.4	ZAI · 中国		59.5
10	GPT-5.6 Sol R (xhigh)	闭源未知	4/20	OpenAI · 美国		59.0
11	Grok 4.6 R (medium)	闭源未知	2/6	SpaceXAI · ...		59.0
12	Claude Opus 5 R (Adaptive Reasoning, Medium Effort)	闭源未知	5/25	Anthropic · ...		58.6
13	Qwen3.8 Max R	≈1T · 闭源	2/6	Alibaba · 中国		58.1
14	Qwen3.8 2.4T A95B R	闭源未知	2/6	Alibaba · 中国		57.7
15	GLM-5.3-Flash R	745B MoE	0.15/0.5	ZAI · 中国		57.5
16	GPT-5.6 Sol R (high)	闭源未知	4/20	OpenAI · 美国		57.3
17	Muse Spark 1.2 R (xhigh)	闭源未知	1.25/4.25	Meta · 美国		56.8
18	GPT-5.6 Terra R (max)	闭源未知	2/12	OpenAI · 美国		56.6
19	Gemini 3.7 Flash R (high)	闭源未知	0.75/3.75	Google · 美国		56.0
20	Qwen3.8-Flash-Next R	闭源未知	0.15/0.47	Alibaba · 中国		55.8

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年08月28日 周五 | 近 8 小时 AI 行业关键动向

SCANNED

414

条原始资讯

SOURCES

12

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今天最值得高管关注三件事：一是AI资本继续向OpenAI和通用机器人集中，产业资本正在提前锁定入口；二是算力、晶圆代工等基础设施集中度上升，供应链风险更突出；三是企业Agent落地从功能竞赛转向成本、治理和安全，ROI与权限控制将决定规模化成败。



■ 战略动向 · Strategy	4 33%
■ 行业影响 · Industry	4 33%
■ 管理实践 · Practice	4 33%

ACTION ITEMS · 行动建议

- 01 盘点核心AI供应商融资和锁定风险，准备替代方案
- 02 重算办公与研发AI的Token成本、节省工时和质量指标
- 03 为Agent部署建立最小权限、审计日志和应急关停机制
- 04 评估国产算力与跨区域调度对现有IT预算的影响

#01 ★★★★★

华尔街见闻 · 53 分钟前

Sharpa披露超45亿元融资 ↗

通用机器人公司Sharpa首次公开披露融资，总额超过45亿元，投后估值220亿元，投资方包括阿里、美团、腾讯、京东及红杉中国等。

So What 机器人进入产业资本重仓阶段，供应链、场景和数据入口将加速绑定，制造与服务企业需评估合作窗口。

<https://wallstreetcn.com/livenews/3156642>

#02 ★★★★★

华尔街见闻 · 1 小时前

软银拟再借百亿美元投OpenAI ↗

软银寻求100亿美元贷款，用于OpenAI股权投资相关债务再融资，近期还可能发行最高200亿美元债券支持AI投资。

So What 头部AI资产估值和融资杠杆继续抬升，企业采购与生态合作要警惕供应商资本压力和定价波动。

<https://wallstreetcn.com/livenews/3156602>

#03 ★★★★★☆

新智元 · 9 小时前

MiniMax释放新一轮价格信号 ↗

国内大模型价格战延续，智谱新模型定价降至Opus 4.8约四十分之一，MiniMax同时披露约8亿美元ARR相关进展。

So What 通用模型利润率承压，应用企业可重新议价API成本，但需验证稳定性、合规和服务连续性。

<https://aiera.com.cn/2026/08/28/other/admin/110921/%e5%88%9a%e5%88%9a%ef%bc%8cminimax%...b8%e5%9c%ba/>

#04 ★★★★★☆

IT之家 · 9 小时前

谷歌加速测试Gemini新模型 ↗

谷歌员工已开始测试Gemini 3.8 Flash预览版，显示其以数周节奏迭代模型，以追赶OpenAI和Anthropic。

So What 模型能力与价格周期缩短，企业不宜过早锁死单一模型，应保留多模型路由和替换机制。

<https://www.ithome.com/0/995/594.htm>

#01 ★★★★★

华尔街见闻 · 22 分钟前

全国一体化算力网加快落地 ↗

国家数据局称，20余家算力调度主体入驻全国一体化算力网试验验证平台，已接入145万PFLOPS FP16智能算力。

So What 算力将从分散采购走向调度运营，政企项目可关注跨区域算力成本优化和国产算力适配机会。

<https://wallstreetcn.com/livenews/3156690>

#02 ★★★★★

IT之家 · 9 小时前

台积电晶圆代工份额升至73% ↗

Counterpoint数据显示，2026年二季度全球纯晶圆代工市场同比增长29%，台积电份额达73%，三星约7%，中芯国际第三。

So What AI芯片供应链集中度进一步提高，硬件企业需强化产能锁定、备选工艺和地缘风险预案。

<https://www.ithome.com/0/995/622.htm>

#03 ★★★★☆

虎嗅 · 1 分钟前

AI短剧冲击横店演员就业 ↗

AI短剧快速扩张，在三个月内显著改变横店群演、替身和低成本内容生产链条，部分岗位被虚拟角色与自动化制作替代。

So What 内容行业的低端人力成本优势被削弱，传媒公司应重构IP、制作流程和人才结构。

<https://m.huxiu.com/article/4886426.html>

#04 ★★★★☆

Hacker News · 4 分钟前

美国法院裁定Anthropic胜诉 ↗

美国法官裁定特朗普政府非法惩罚AI公司Anthropic，涉及政府对AI企业供应链限制和行政制裁边界。

So What AI企业与政府采购、国防合作的合规边界仍在形成，跨境业务需持续跟踪政策与诉讼风险。

<https://www.cbsnews.com/news/judge-rules-trump-administration-illegally-punished-ai-firm-anthropic/>

#01 ★★★★★☆

InfoQ · 6 分钟前

千问办公称Token消耗降75% ↗

千问办公通过模型与Agent架构协同，将办公场景Token消耗减少75%，显示办公Agent竞争正转向成本与架构效率。

So What

企业部署办公AI不能只看功能清单，应把Token成本、任务完成率和流程集成纳入ROI评估。

<https://www.infoq.cn/article/70zHFKxwRRGIjB08EUtC>

#02 ★★★★★☆

虎嗅 · 7 分钟前

AI智能体推高网络安全需求 ↗

围绕AI Agent失控和身份安全风险的讨论升温，Okta单日上涨28.63%，CrowdStrike上涨20.5%，资本重新定价安全板块。

So What

Agent规模化部署会放大身份、权限和终端风险，企业应先补齐访问控制、日志审计和应急机制。

<https://m.huxiu.com/article/4886782.html>

#03 ★★★★★☆

InfoQ · 1 小时前

LinkedIn规模化AI代码审查 ↗

LinkedIn自研多智能体AI代码审查平台，强调理解组织代码上下文、按生产级基础设施运营，并减少幻觉和低价值反馈。

So What

研发管理者可把代码审查作为AI落地切口，但必须建设代码上下文、质量指标和人工兜底机制。

<https://www.infoq.cn/article/A0CMcU7UVsMQreKPcK0w>

#04 ★★★★★☆

InfoQ · 3 小时前

Cloudflare推出Agent浏览器引擎 ↗

Cloudflare发布Kitesurf，一款面向AI智能体自动化任务的轻量浏览器引擎，可被Playwright和Puppeteer调用，资源消耗低于完整Chromium。

So What

浏览器自动化正成为Agent基础设施，企业可降低网页任务执行成本，但要同步设计权限和审计。

<https://www.infoq.cn/article/.lDYK.lmiY9vTRSw47t15a>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Opus 5 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		63.1
2	Claude Opus 5 R (Adaptive Reasoning, Xhigh Effort)	闭源未知	5/25	Anthropic · ...		62.5
3	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		62.1
4	Claude Opus 5 R (Adaptive Reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		61.5
5	GPT-5.6 Sol R (max)	闭源未知	4/20	OpenAI · 美国		60.9
6	Grok 4.6 R (high)	闭源未知	2/6	SpaceXAI · ...		60.9
7	Grok 4.6 R (xhigh)	闭源未知	2/6	SpaceXAI · ...		60.0
8	Kimi K3 R (max)	闭源未知	3/15	Kimi · 中国		59.7
9	GLM-5.3 R (max)	745B MoE	1.4/4.4	ZAI · 中国		59.5
10	GPT-5.6 Sol R (xhigh)	闭源未知	4/20	OpenAI · 美国		59.0
11	Grok 4.6 R (medium)	闭源未知	2/6	SpaceXAI · ...		59.0
12	Claude Opus 5 R (Adaptive Reasoning, Medium Effort)	闭源未知	5/25	Anthropic · ...		58.6
13	Qwen3.8 Max R	≈1T · 闭源	2/6	Alibaba · 中国		58.1
14	Qwen3.8 2.4T A95B R	闭源未知	2/6	Alibaba · 中国		57.7
15	GLM-5.3-Flash R	745B MoE	0.15/0.5	ZAI · 中国		57.5
16	GPT-5.6 Sol R (high)	闭源未知	4/20	OpenAI · 美国		57.3
17	Muse Spark 1.2 R (xhigh)	闭源未知	1.25/4.25	Meta · 美国		56.8
18	GPT-5.6 Terra R (max)	闭源未知	2/12	OpenAI · 美国		56.6
19	Gemini 3.7 Flash R (high)	闭源未知	0.75/3.75	Google · 美国		56.0
20	Qwen3.8-Flash-Next R	闭源未知	0.15/0.47	Alibaba · 中国		55.8

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年08月27日 周四 | 近 8 小时 AI 行业关键动向

SCANNED

412

条原始资讯

SOURCES

11

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今天最值得管理层关注三件事：一是英伟达从业绩到潜在收购继续强化AI基础设施控制力；二是存储扩产、五年算力大单显示AI瓶颈转向全栈供给；三是企业落地进入治理阶段，研发、数据与模型服务都需要可靠性和权限体系支撑。



■ 战略动向 · Strategy

4 33%

■ 行业影响 · Industry

4 33%

■ 管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

01 盘点关键AI流程是否单点依赖某一模型服务

02 重算未来12个月算力、存储与云服务预算

03 为AI生成代码制定评审、测试和责任规则

04 评估多模型路由平台的成本与合规收益

#01 ★★★★★

华尔街见闻 · 44 分钟前

日美存储厂商拟投310亿美元扩产 ↗

铠侠与闪迪计划在日本投资超5万亿日元，约310亿美元扩建内存产能，其中1.8万亿日元用于北上新工厂。

So What AI数据中心瓶颈正从GPU扩散到存储与电力配套，算力规划不能只看芯片采购价。

<https://wallstreetcn.com/livenews/3155895>

#02 ★★★★★

TechCrunch · 10 小时前

英伟达据称接近收购Hugging Face ↗

TechCrunch称英伟达拟以129亿美元收购开源AI平台Hugging Face，若落地将把模型社区、开发者入口与GPU生态进一步绑定。

So What AI基础设施可能从芯片向平台入口纵向整合，企业需评估开源模型供应链的中立性与厂商锁定风险。

<https://techcrunch.com/2026/08/26/nvidia-closes-in-on-hugging-face-acquisition/>

#03 ★★★★★☆

华尔街见闻 · 24 分钟前

粤万年青子公司签12.44亿元算力单 ↗

粤万年青控股子公司万宏智算与A公司签署五年服务采购协议，提供GPU算力云服务及运维支持，总价12.44亿元。

So What 国内算力租赁从试点走向长约采购，管理层应重新评估自建、租赁与混合算力的财务边界。

<https://wallstreetcn.com/livenews/3155911>

#04 ★★★★★☆

量子位 · 11 小时前

基元律动融资打造中国版OpenRouter ↗

AI基础设施公司基元律动完成数千万美元融资，推出面向国内市场的大模型聚合与路由平台，被称为“中国版OpenRouter”。

So What 模型调用入口和路由层成为新控制点，企业可用多模型架构降低成本，但需重视计费、合规与稳定性。

<https://www.qbitai.com/2026/08/480079.html>

#01 ★★★★★

华尔街见闻 · 59 分钟前

英伟达季度营收翻倍至962亿美元 ↗

英伟达上季营收962亿美元、同比翻倍并超预期，本季预计首次突破千亿美元，下财年营收指引增长70%。

So What AI资本开支周期仍强劲，但市场预期更高；依赖AI红利的企业需用实际收入兑现估值。

<https://wallstreetcn.com/livenews/3155872>

#02 ★★★★★☆

虎嗅 · 46 分钟前

29位具身智能CEO聚焦泛化路线 ↗

虎嗅采访29位具身智能CEO，围绕机器人泛化能力的实现路径、数据来源、仿真训练与商业落地形成共识与分歧。

So What 具身智能仍未形成单一路线，投资和合作应关注可交付场景，而非只押注通用机器人叙事。

<https://m.huxiu.com/article/4886452.html>

#03 ★★★★★☆

虎嗅 · 50 分钟前

AI正重塑职场新人培养路径 ↗

报道指出AI尚未造成大规模失业，但正在改变年轻人进入职场、获得经验和建立安全感的方式，初级岗位训练价值被压缩。

So What 企业若过度用AI替代初级工作，可能削弱人才梯队；需重设计新人任务、导师制与能力评估。

<https://m.huxiu.com/article/4886448.html>

#04 ★★★★★☆

虎嗅 · 2 小时前

小鹏9亿美元押注人形机器人 ↗

小鹏围绕机器人业务获得9亿美元级别关注，外界关注其汽车制造、自动驾驶数据与供应链能力能否迁移到具身智能。

So What 车企正把智能化能力外溢到机器人赛道，制造业管理者可寻找场景合作，但需警惕量产周期拉长。

<https://m.huxiu.com/article/4886339.html>

#01 ★★★★★☆

InfoQ · 1 小时前

微软发布Azure DevOps远程MCP [↗](#)

微软正式推出Azure DevOps远程MCP服务器，AI助手可通过托管端点访问工作项、PR、代码仓库和流水线。

So What 研发流程将更容易被AI代理接管，CIO应同步建立权限、审计和变更审批边界。

<https://www.infoq.cn/article/SvTBvLjtvGctvWPQRqr7>

#02 ★★★★★☆

新智元 · 9 小时前

Claude单日三次故障暴露依赖风险 [↗](#)

新智元称Claude在8月24日出现三次服务故障，API、App及协作功能均受影响，官方随后多次宣布恢复。

So What 核心流程若单点依赖外部大模型，业务连续性风险上升；应准备多模型切换、降级与人工兜底方案。

<https://aiera.com.cn/2026/08/27/other/admin/110799/claude%e4%b8%80%e5%a4%a93%e5%b4%a9%...93%e7%9e%8e/>

#03 ★★★★★☆

Hacker News · 2 分钟前

小团队讨论LLM时代代码评审 [↗](#)

Hacker News上约3人小型开发团队讨论大量使用LLM后，代码评审如何调整，以兼顾开发速度、质量与责任归属。

So What AI写代码会放大审查压力，技术负责人应把评审重点从语法转向架构、测试覆盖和安全责任。

<https://news.ycombinator.com/item?id=49461811>

#04 ★★★★★☆

InfoQ · 2 小时前

Snowflake推Cortex数据处理方案 [↗](#)

Snowflake展示Cortex AI Functions实践，可将非结构化数据直接引入数据仓库，并通过可复用工作流转为结构化洞察。

So What 企业AI价值不只在聊天界面，数据仓库中的非结构化资产可成为运营分析和自动化的新入口。

<https://www.infoq.cn/article/Xw6Nlqq7N2J0CKA0ehx8>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Opus 5 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		63.1
2	Claude Opus 5 R (Adaptive Reasoning, Xhigh Effort)	闭源未知	5/25	Anthropic · ...		62.5
3	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		62.1
4	Claude Opus 5 R (Adaptive Reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		61.5
5	GPT-5.6 Sol R (max)	闭源未知	4/20	OpenAI · 美国		60.9
6	Grok 4.6 R (high)	闭源未知	2/6	SpaceXAI · ...		60.9
7	Grok 4.6 R (xhigh)	闭源未知	2/6	SpaceXAI · ...		60.0
8	Kimi K3 R (max)	闭源未知	3/15	Kimi · 中国		59.7
9	GLM-5.3 R (max)	745B MoE	1.4/4.4	ZAI · 中国		59.5
10	GPT-5.6 Sol R (xhigh)	闭源未知	4/20	OpenAI · 美国		59.0
11	Grok 4.6 R (medium)	闭源未知	2/6	SpaceXAI · ...		59.0
12	Claude Opus 5 R (Adaptive Reasoning, Medium Effort)	闭源未知	5/25	Anthropic · ...		58.6
13	Qwen3.8 Max R	≈1T · 闭源	2/6	Alibaba · 中国		58.1
14	Qwen3.8 2.4T A95B R	闭源未知	2/6	Alibaba · 中国		57.7
15	GLM-5.3-Flash R	745B MoE	0.15/0.5	ZAI · 中国		57.5
16	GPT-5.6 Sol R (high)	闭源未知	4/20	OpenAI · 美国		57.3
17	Muse Spark 1.2 R (xhigh)	闭源未知	1.25/4.25	Meta · 美国		56.8
18	GPT-5.6 Terra R (max)	闭源未知	2/12	OpenAI · 美国		56.6
19	Gemini 3.7 Flash R (high)	闭源未知	0.75/3.75	Google · 美国		56.0
20	Grok 4.5 R (high)	闭源未知	2/6	SpaceXAI · ...		55.8

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年08月26日 周三 | 近 8 小时 AI 行业关键动向

SCANNED

413

条原始资讯

SOURCES

12

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今天最值得管理层关注三件事：模型厂商商业化和出海开始有真实订单与分成模式；Agent 正从聊天工具变成流程执行者，芯片、机器人和软件分工都可能重排；端侧AI与安全治理同步升温，企业要更早设权限、审计和回滚机制。



■ 战略动向 · Strategy	4 33%
■ 行业影响 · Industry	4 33%
■ 管理实践 · Practice	4 33%

ACTION ITEMS · 行动建议

- 01 盘点可外包给模型或云的工作流，优先筛选出海业务
- 02 对高风险系统设人工复核、灰度发布和一键回滚
- 03 重新测算算力、存储与电力成本，更新明年预算
- 04 为IM、客服和浏览器代理补齐权限与审计策略

#01 ★★★★★

华尔街见闻 · 14 分钟前

工业富联CPO样机交货，ASIC出货翻三倍 ↗

工业富联披露，CPO全光交换机样机已交货，并协同全球客户验证；上半年ASIC AI机柜出货量同比增3倍，ASIC CPU服务器增2.5倍。

So What 算力硬件仍处高景气，但竞争已转向交付、验证和产能，供应链绑定更关键。

<https://wallstreetcn.com/livenews/3155163>

#02 ★★★★★

IT之家 · 9 小时前

月之暗面洽谈Kimi K3云托管分成 ↗

据路透，月之暗面正与微软、亚马逊、谷歌谈Kimi K3云托管的营收分成，若落地将形成中国模型厂商借美国云出海的新样板。

So What 中国大模型出海开始走“模型+云”合作路线，收入分成与合规条款将成谈判重点。

<https://www.ithome.com/0/994/602.htm>

#03 ★★★★★

IT之家 · 9 小时前

DeepSeek前7个月营收近4.75亿元 ↗

The Information称，DeepSeek今年前7个月营收约4.75亿元，已接近去年全年水平的10倍，显示头部模型产品仍在快速商业化。

So What 模型厂商不再只拼参数，商业化速度和现金流开始决定行业排名与融资议价。

<https://www.ithome.com/0/994/574.htm>

#04 ★★★★★☆

华尔街见闻 · 1 小时前

阿里千问办公国际版开启公测 ↗

阿里巴巴Agent产品千问办公国际版QwenWork开启公测，海外个人和企业可通过官网体验，网页版和PC客户端已开放，面向全球布局。

So What 国内模型厂商正把产品、品牌和渠道一起出海，海外合规与销售体系要同步跟上。

<https://wallstreetcn.com/livenews/3155098>

#01 ★★★★★

新智元 · 9 小时前

中国AI突破造芯方法论，Agent接管芯片设计 ↗

新智元称，中国AI正把Agent军团引入芯片设计全流程，目标是递归自我改进式协同，进一步压缩设计与验证周期。

So What 芯片设计正在被AI重写，能否用Agent缩短研发周期，将直接影响算力供给和半导体分工。

<https://aiera.com.cn/2026/08/26/other/admin/110583/%e4%b8%ad%e5%9b%bdai%e7%aa%81%e7%a0...a1%e5%85%a8/>

#02 ★★★★★☆

新智元 · 9 小时前

Claude改报错引发三星芯片验证失误 ↗

有工程师用Claude改报错时把红灯改成黄灯，三星芯片验证中还出现多次失误，说明AI辅助代码在高风险场景仍可能放大缺陷。

So What 关键系统不能把AI当自动驾驶，必须保留人工复核、测试门禁和责任归属。

<https://aiera.com.cn/2026/08/26/other/admin/110715/%e8%ae%a9claude%e6%94%b9%e6%8a%a5%e...87%e9%aa%8c/>

#03 ★★★★★☆

新智元 · 9 小时前

AI调用AI成趋势，token用量达5.2倍 ↗

研究称，AI开始替人类调用AI，OpenRouter上智能体token用量已达人类的5.2倍，流量结构正从“人用模型”转向“模型用模型”。

So What 企业要预判调用量和算力账单变化，Agent越多，基础设施、计费和监控模型越要重做。

<https://aiera.com.cn/2026/08/26/other/admin/110666/ai%e5%bc%80%e5%a7%8b%e6%9b%bf%e4%ba...-2%e5%80%8d/>

#04 ★★★★★☆

量子位 · 11 小时前

宇树智元共享机器人模型亮相 ↗

量子位称，宇树与智元展示了共用机器人基础模型的神秘Demo，10分钟一镜到底，显示具身智能平台化正在提速。

So What 机器人竞争可能从单机性能转向底层模型与数据复用，平台型玩家会有规模优势。

<https://www.qbitai.com/2026/08/479634.html>

#01 ★★★★★☆

InfoQ · 2 小时前

WhatsApp测试端侧AI反诈，无需上云 ↗

WhatsApp正测试端侧机器学习反诈，消息无需上传云端即可识别诈骗，主打隐私保护和本地分析。

So What 安全与隐私可以兼得的方案，会影响企业对IM、客服和协同工具的选型。

<https://www.infoq.cn/article/wAVLMqVg7FqPjXAYFDjC>

#02 ★★★★★☆

InfoQ · 7 小时前

Agentic AI时代来临，企业流程将被重构 ↗

InfoQ称，Agentic AI正从被动助手变成独立行动者，已开始重塑购物、供应链、门店运营和制造环节的企业运作方式。

So What 流程自动化将从“单点提效”升级为“端到端重构”，组织分工和KPI都要重新设计。

<https://www.infoq.cn/article/8ouuK09WuWA7Up35W9vb>

#03 ★★★★★☆

IT之家 · 9 小时前

ChatGPT云端浏览器新增登录任务 ↗

OpenAI为ChatGPT云端浏览器加入登录任务能力，遇到登录页可直接输入账号密码，密码不保存，但Cookie会持续到会话过期。

So What AI代理开始能处理真实交易流程，企业需提前管理账号权限、审计日志和会话风险。

<https://www.ithome.com/0/994/581.htm>

#04 ★★★★★☆

InfoQ · 1 小时前

工厂老兵用端侧AI跑出报价智能体 ↗

一位工厂老兵在AMD锐龙AI Max+ 395上做出工业报价智能体，用AI改造非标制造报价流程，突出端侧算力的落地性。

So What 中小制造企业不一定先上云，本地化终端可能更快带来ROI和流程改造。

<https://www.infoq.cn/article/RJDrRaDC1drafw0Kvoki>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Opus 5 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		63.1
2	Claude Opus 5 R (Adaptive Reasoning, Xhigh Effort)	闭源未知	5/25	Anthropic · ...		62.5
3	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		62.1
4	Claude Opus 5 R (Adaptive Reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		61.5
5	GPT-5.6 Sol R (max)	闭源未知	4/20	OpenAI · 美国		60.9
6	Grok 4.6 R (high)	闭源未知	2/6	SpaceXAI · ...		60.9
7	Grok 4.6 R (xhigh)	闭源未知	2/6	SpaceXAI · ...		60.0
8	Kimi K3 R (max)	闭源未知	3/15	Kimi · 中国		59.7
9	GLM-5.3 R (max)	745B MoE	1.4/4.4	ZAI · 中国		59.5
10	GPT-5.6 Sol R (xhigh)	闭源未知	4/20	OpenAI · 美国		59.0
11	Grok 4.6 R (medium)	闭源未知	2/6	SpaceXAI · ...		59.0
12	Claude Opus 5 R (Adaptive Reasoning, Medium Effort)	闭源未知	5/25	Anthropic · ...		58.6
13	Qwen3.8 Max R	≈1T · 闭源	2/6	Alibaba · 中国		58.1
14	Qwen3.8 2.4T A95B R	闭源未知	2/6	Alibaba · 中国		57.7
15	GPT-5.6 Sol R (high)	闭源未知	4/20	OpenAI · 美国		57.3
16	Muse Spark 1.2 R (xhigh)	闭源未知	1.25/4.25	Meta · 美国		56.8
17	GPT-5.6 Terra R (max)	闭源未知	2/12	OpenAI · 美国		56.6
18	Gemini 3.7 Flash R (high)	闭源未知	0.75/3.75	Google · 美国		56.0
19	Grok 4.5 R (high)	闭源未知	2/6	SpaceXAI · ...		55.8
20	GPT-5.6 Sol R (medium)	闭源未知	4/20	OpenAI · 美国		55.6

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年08月25日 周二 | 近 8 小时 AI 行业关键动向

SCANNED

404

条原始资讯

SOURCES

12

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今天最值得管理者关注三件事：一是AI开源生态与基础模型层可能被资本和算力巨头重塑；二是能源、音乐、法律等行业监管和成本约束加速显现；三是企业落地AI的重点正从“买模型工具”转向成本治理、流程改造和责任边界设计。



■ 战略动向 · Strategy	4 33%
■ 行业影响 · Industry	4 33%
■ 管理实践 · Practice	4 33%

ACTION ITEMS · 行动建议

- 01 盘点关键AI供应商依赖，评估开源平台变化影响
- 02 重算AI服务器和云推理预算，提前锁定资源价格
- 03 为法律、内容、研发等高风险场景制定人工复核规则
- 04 梳理AI编程全流程瓶颈，不只考核代码生成量

#01 ★★★★★

新智元 · 9 小时前

Hugging Face探索出售 ↗

最重要的AI开源平台Hugging Face据称正接触潜在买家，估值可能达到130亿美元以上，约870亿元人民币。

So What 开源生态入口可能被巨头或资本重塑，企业需评估模型、数据集和部署链路的供应商锁定风险。

<https://aiera.com.cn/2026/08/25/other/admin/110508/%e7%aa%81%e5%8f%91%ef%bc%81hugging-...bf%e5%85%83/>

#02 ★★★★★

新智元 · 9 小时前

英伟达拟投六十亿美元做开源模型 ↗

外媒称英伟达计划斥资60亿美元打造顶级开源权重AI模型，显示其不再满足于仅提供算力硬件。

So What 算力厂商向模型层上探，可能改变基础模型议价格局，企业采购需重新比较芯片、云和模型捆绑方案。

<https://aiera.com.cn/2026/08/25/other/admin/110460/%e8%80%81%e9%bb%84%e6%96%a5%e8%b5%8...8b%ef%bc%81/>

#03 ★★★★★☆

量子位 · 10 小时前

家用机器人公司半年融资十亿元 ↗

未来不远机器人半年完成3轮融资、总额约10亿元，字节、汇川等入股，产品已卖到500个家庭。

So What 家庭场景机器人从概念进入小规模验证，消费硬件、物业与服务企业可提前布局试点和渠道合作。

<https://www.qbitai.com/2026/08/479132.html>

#04 ★★★★★☆

量子位 · 11 小时前

AI科研从任务走向项目制 ↗

紫东太初提出AI4S进入“项目时代”，强调AI科研能力从单点Task工具升级为可承接Project的系统。

So What 科研与研发管理将从买工具转向建流程平台，研发密集型企业应重构实验、数据和项目管理体系。

<https://www.qbitai.com/2026/08/479096.html>

#01 ★★★★★

华尔街见闻 · 2 小时前

一带一路拟设AI能源工作组 ↗

国家能源局拟在“一带一路”能源合作框架下新设“人工智能+能源”工作组，推进能源转型与绿色算力合作。

So What

AI与能源基础设施协同上升为多边议题，能源、算力和出海企业应关注政策窗口与跨境项目机会。

<https://wallstreetcn.com/livenews/3154401>

#02 ★★★★★☆

Hacker News · 1 小时前

荷兰律师因AI幻觉引文被罚 ↗

荷兰一名律师因使用AI生成的虚假法律引用被罚2300欧元，凸显专业服务领域的AI幻觉责任问题。

So What

高风险岗位不能把AI输出直接作为事实依据，企业应明确人工复核、责任归属和可追溯记录要求。

<https://nltimes.nl/2026/08/24/dutch-lawyer-fined-eu2300-using-ai-hallucinated-citation>

#03 ★★★★★☆

新智元 · 9 小时前

内存涨价推高AI服务器成本 ↗

报道称搭载英伟达AI芯片的服务器将涨价，部分配置涨幅超过15%，主要受内存价格上涨影响。

So What

AI基础设施成本可能继续上行，企业应提前锁定关键资源，重新测算训练、推理和私有化部署ROI。

<https://aiera.com.cn/2026/08/25/other/admin/110493/%e8%8b%b1%e4%bc%9f%e8%be%be%e9%83%b...b7%e8%b6%85/>

#04 ★★★★★☆

IT之家 · 9 小时前

澳洲纯AI歌曲禁入官方榜 ↗

澳大利亚唱片业协会决定禁止完全由AI生成的歌曲进入官方排行榜，以回应生成式AI对音乐人权益的冲击。

So What

内容行业的AI标注、版权和分账规则正在收紧，平台和品牌方需建立AI生成内容合规审核机制。

<https://www.ithome.com/0/994/026.htm>

#01 ★★★★★☆

虎嗅 · 1 小时前

Claude Code强调产品减法 ↗

Claude Code负责人认为，模型变强后仍设计复杂工作流是在“假装做产品”，AI产品应不断做减法。

So What

企业落地AI不宜堆叠流程和按钮，应围绕真实任务缩短路径，用模型能力替代不必要的人工编排。

<https://m.huxiu.com/article/4885785.html>

#02 ★★★★★☆

华尔街见闻 · 1 小时前

阿里云沙箱快照开始商业计费 ↗

阿里云云沙箱Snapshot将开启商业化计费，支持运行中沙箱全状态快照、秒级恢复和克隆，面向长任务Agent。

So What

Agent规模化运行的成本模型更清晰，IT负责人需把会话恢复、冷启动和资源复用纳入预算管理。

<https://wallstreetcn.com/livenews/3154420>

#03 ★★★★★☆

虎嗅 · 2 小时前

AI编程落地遭遇现实流程墙 ↗

文章指出代码生成正在变便宜，但需求澄清、系统集成、测试发布和组织协作仍是AI Coding的主要瓶颈。

So What

研发提效不能只采购编码工具，还要改造需求、测试、代码审查和发布流程，否则ROI会被流程损耗吞噬。

<https://m.huxiu.com/article/4885784.html>

#04 ★★★★★☆

IT之家 · 8 小时前

千问接入阿里云Token Plan ↗

阿里云Token Plan接入千问App及PC端，用户绑定API Key后可调用订阅额度，支持Qwen3.8-Max等模型。

So What

模型使用从开发接口延伸到办公端，企业可统一额度和账号管理，减少个人分散采购带来的成本失控。

<https://www.ithome.com/0/994/095.htm>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Opus 5 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		63.1
2	Claude Opus 5 R (Adaptive Reasoning, Xhigh Effort)	闭源未知	5/25	Anthropic · ...		62.5
3	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		62.1
4	Claude Opus 5 R (Adaptive Reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		61.5
5	GPT-5.6 Sol R (max)	闭源未知	4/20	OpenAI · 美国		60.9
6	Grok 4.6 R (high)	闭源未知	2/6	SpaceXAI · ...		60.9
7	Grok 4.6 R (xhigh)	闭源未知	2/6	SpaceXAI · ...		60.0
8	Kimi K3 R (max)	闭源未知	3/15	Kimi · 中国		59.7
9	GLM-5.3 R (max)	745B MoE	1.4/4.4	ZAI · 中国		59.5
10	GPT-5.6 Sol R (xhigh)	闭源未知	4/20	OpenAI · 美国		59.0
11	Grok 4.6 R (medium)	闭源未知	2/6	SpaceXAI · ...		59.0
12	Claude Opus 5 R (Adaptive Reasoning, Medium Effort)	闭源未知	5/25	Anthropic · ...		58.6
13	Qwen3.8 Max R	≈1T · 闭源	2/6	Alibaba · 中国		58.1
14	Qwen3.8 2.4T A95B R	闭源未知	2/6	Alibaba · 中国		57.7
15	GPT-5.6 Sol R (high)	闭源未知	4/20	OpenAI · 美国		57.3
16	Muse Spark 1.2 R (xhigh)	闭源未知	1.25/4.25	Meta · 美国		56.8
17	GPT-5.6 Terra R (max)	闭源未知	2/12	OpenAI · 美国		56.6
18	Gemini 3.7 Flash R (high)	闭源未知	0.75/3.75	Google · 美国		56.0
19	Grok 4.5 R (high)	闭源未知	2/6	SpaceXAI · ...		55.8
20	GPT-5.6 Sol R (medium)	闭源未知	4/20	OpenAI · 美国		55.6

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年08月24日 周一 | 近 8 小时 AI 行业关键动向

SCANNED

341

条原始资讯

SOURCES

11

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今天最值得管理者关注的有三点：资本继续大规模押注AI基础设施和具身智能，但市场已开始严格检验模型公司的商业回报；小米、阿里等巨头通过芯片、算力和全栈能力强化控制力；办公AI则从单点工具竞争转向统一入口、团队协作与治理体系，企业应同步评估投入回报和组织适配。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

01 盘点现有AI项目的收入贡献、节省工时与使用成本，淘汰无法量化回报的试点

02 为办公AI采购建立任务级验收表，纳入准确率、权限、数据隔离和错误追责

03 评估核心供应商的模型、芯片和算力自研比例，制定替代供应与迁移预案

04 选择一个低风险高频场景测试具身智能，先验证订单、交付和售后能力

#01 ★★★★★

华尔街见闻 · 2 小时前

阿里配售八百亿港元加码全栈AI ↗

阿里完成800亿港元新股配售，所得款项100%用于投资全栈AI能力；配售获近3倍超额认购，主权及长线基金认购比例超过40%。

So What 大型资本正用真金白银押注AI基础设施。企业需重新评估算力、模型和数据投入的长期竞争门槛，避免只做轻量应用跟随。

<https://wallstreetcn.com/livenews/3153690>

#02 ★★★★★☆

华尔街见闻 · 1 小时前

Harvey基于Kimi K3推出法律专用模型 ↗

美国法律AI独角兽Harvey基于月之暗面的开放权重模型Kimi K3，通过后训练开发法律专用模型Tenet，国产模型首次进入美国头部垂直AI训练体系。

So What 模型能力与行业数据、流程的组合价值正在上升，底层模型不再必然决定最终优势。企业应加强领域数据治理和后训练能力建设。

<https://wallstreetcn.com/livenews/3153727>

#03 ★★★★★☆

华尔街见闻 · 2 小时前

小米三款玄戒芯片覆盖终端与智驾 ↗

小米发布玄戒O3、O100和D100三款芯片，分别覆盖终端SoC、AI加速和智能驾驶；O100带宽达1.22TB/s，D100采用3nm工艺。

So What 头部硬件企业正从单点芯片自研转向全栈布局。产业链企业要判断客户是否会提高自研比例，并提前调整合作、供应和产品定位。

<https://wallstreetcn.com/livenews/3153684>

#04 ★★★★★☆

量子位 · 9 小时前

中诚华隆发布推理芯片及万卡集群 ↗

中诚华隆发布HL200推理芯片及超节点集群，提出从单芯片到万卡集群的体系化方案，主攻国产推理算力规模化落地。

So What 推理基础设施竞争将从单颗芯片转向集群效率、软件生态和交付能力。采购方应以端到端单位成本和稳定性评估供应商。

<https://www.qhitai.com/2026/08/478469.html>

#01 ★★★★★☆

虎嗅 · 1 小时前

融资资金与人才加速转向具身智能 ↗

候选信息显示，半年内机器人领域融资超过935亿元，资金和人才从自动驾驶等方向持续涌向具身智能，行业进入高投入扩张阶段。

So What 具身智能可能成为下一轮产业资源争夺点，但融资热度不等于商业成熟。管理者应区分真实订单、交付能力与概念性估值。

<https://m.huxiu.com/article/4885504.html>

#02 ★★★★★☆

IT之家 · 8 小时前

数据中心扩张挤压美国住房建设用工 ↗

美国数据中心建设吸收大量建筑工人，成屋签约销售量降至三年来低位，7月新屋建设创三年半新低，AI基础设施扩张产生劳动力挤出效应。

So What AI投资会外溢至能源、地产和劳动力市场，形成新的成本与政策约束。企业选址和扩产时需把区域人才、能源及审批纳入模型。

<https://www.ithome.com/0/993/599.htm>

#03 ★★★★★☆

华尔街见闻 · 1 小时前

港股大模型概念股集体下挫 ↗

港股大模型概念股持续走弱，智谱盘中跌超11%，MINIMAX盘中跌超10%，市场对模型公司的估值、变现和投入回报重新定价。

So What 资本市场正在从讲能力转向看收入和现金流。AI业务负责人需建立可审计的客户留存、使用成本和毛利指标，避免估值预期脱离经营结果。

<https://wallstreetcn.com/livenews/3153723>

#04 ★★★★★☆

新智元 · 4 小时前

启元两款人形机器人开启公开预订 ↗

上纬新材旗下启元机器人启动Q1、T1两款消费级人形机器人公开预订，资本市场随之上涨，显示具身智能正从展示走向商业化验证。

So What 消费级机器人开始进入需求测试期，渠道、售后和安全责任将成为关键门槛。相关企业可先从高频、低风险场景验证真实支付意愿。

<https://aiea.com.cn/2026/08/24/other/admin/110437/%e5%bc%80%e7%9b%98%e6%b6%a8%e9%80%b7%e8%ba%ab/>

#01 ★★★★★

华尔街见闻 · 52 分钟前

字节整合TRAE扣子打造豆包工作 ↗

字节将TRAE、扣子团队整体并入豆包体系，整合TRAE Work、扣子与豆包工作能力；TRAE IDE和CLI继续作为编程产品线发展。

So What 办公AI竞争将从单工具功能转向统一入口、账号和工作流。企业采购应减少孤立试点，优先评估跨部门协同、权限和数据闭环。

<https://wallstreetcn.com/livenews/3153756>

#02 ★★★★★

InfoQ · 1 小时前

AgentCore为多智能体引入持久计算 ↗

亚马逊Bedrock AgentCore推出持久计算能力，支持多个AI智能体共同运行于一台EC2实例，面向多智能体协作提供持续运行环境。

So What 多智能体部署开始进入资源调度和运行治理阶段。企业需提前规划隔离、故障恢复、成本归属和权限边界，避免实验系统直接演变为生产风险。

<https://www.infoq.cn/article/2IBWc7BuB2qoGao5t1QT>

#03 ★★★★★

钛媒体 · 8 小时前

五款AI办公助手实测暴露落地差异 ↗

钛媒体对五款AI办公助手开展万字实测，围绕实际使用效果比较产品能力，反映办公AI在任务完成质量和场景适配上的明显差异。

So What 办公助手的采购价值不能只看模型榜单或演示效果。管理者应以真实岗位任务、节省工时、错误率和数据权限设计验收标准。

<https://www.tmtpost.com/8113654.html>

#04 ★★★★★

新智元 · 8 小时前

Anthropic公开Claude员工入职培训课程 ↗

Anthropic上线Claude Academy，公开其员工入职培训课程，将AI工具使用与组织内部培训体系结合，提供企业推广AI能力的参考样本。

So What AI普及的瓶颈正从工具可用性转向员工能力与流程制度。企业可把培训绑定具体岗位任务和产出指标，避免培训完成却没有业务采用。

<https://aieca.com.cn/2026/08/24/other/admin/110412/%e5%88%9a%e5%88%9a%ef%bc%8canthropi...86%ef%bc%81/>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Opus 5 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		63.1
2	Claude Opus 5 R (Adaptive Reasoning, Xhigh Effort)	闭源未知	5/25	Anthropic · ...		62.5
3	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		62.1
4	Claude Opus 5 R (Adaptive Reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		61.5
5	GPT-5.6 Sol R (max)	闭源未知	5/30	OpenAI · 美国		60.9
6	Grok 4.6 R (high)	闭源未知	2/6	SpaceXAI · ...		60.9
7	Grok 4.6 R (xhigh)	闭源未知	2/6	SpaceXAI · ...		60.0
8	Kimi K3 R (max)	闭源未知	3/15	Kimi · 中国		59.7
9	GLM-5.3 R (max)	745B MoE	1.4/4.4	ZAI · 中国		59.5
10	GPT-5.6 Sol R (xhigh)	闭源未知	5/30	OpenAI · 美国		59.0
11	Grok 4.6 R (medium)	闭源未知	2/6	SpaceXAI · ...		59.0
12	Claude Opus 5 R (Adaptive Reasoning, Medium Effort)	闭源未知	5/25	Anthropic · ...		58.6
13	Qwen3.8 Max R	≈1T · 闭源	2/6	Alibaba · 中国		58.1
14	Qwen3.8 2.4T A95B R	闭源未知	2/6	Alibaba · 中国		57.7
15	GPT-5.6 Sol R (high)	闭源未知	5/30	OpenAI · 美国		57.3
16	Muse Spark 1.2 R (xhigh)	闭源未知	1.25/4.25	Meta · 美国		56.8
17	GPT-5.6 Terra R (max)	闭源未知	2/12	OpenAI · 美国		56.6
18	Gemini 3.7 Flash R (high)	闭源未知	0.75/3.75	Google · 美国		56.0
19	Grok 4.5 R (high)	闭源未知	2/6	SpaceXAI · ...		55.8
20	GPT-5.6 Sol R (medium)	闭源未知	5/30	OpenAI · 美国		55.6

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>