

AI 简讯

2026年07月08日 周三 | 近 8 小时 AI 行业关键动向

SCANNED

435

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今天最值得管理者关注三点：一是AI模型竞争从性能扩展到速度、成本与生态绑定；二是资本市场开始要求AI商业化和现金流兑现，概念溢价分化加剧；三是企业级落地进入成本、合规、算力与能源约束并重阶段，智能体和语音AI部署都需要更严格的ROI与治理框架。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

01 盘点现有AI项目的收入、降本和现金流指标

02 为智能体试点补充成本上限、失败兜底和合规责任人

03 重审算力合同中的价格、迁移和数据可携带条款

04 将数据中心散热与电力保障纳入年度风险清单

#01 ★★★★★☆

Hacker News · 24 分钟前

开源AI暂未冲击Anthropic ↗

报道指出开源AI快速崛起，但尚未显著伤及Anthropic，闭源模型仍凭企业级能力、安全承诺与高端客户黏性保持优势。

So What 采购AI模型不宜只看开源成本，关键任务仍需比较稳定性、合规责任与长期服务能力。

<https://techcrunch.com/2026/07/07/why-the-rise-of-open-source-ai-isnt-hurting-anthropic-yet/>

#02 ★★★★★☆

华尔街见闻 · 2 小时前

SpaceXAI与Cursor拟发新模型 ↗

报道称SpaceXAI与Cursor最快周三推出联合开发的首款AI模型，因优化运行效率推迟发布，性能目标对标Anthropic Opus 4.8与OpenAI高端模型。

So What 模型竞争正从参数性能转向速度与开发场景绑定，企业应评估代码生产力平台的供应商锁定风险。

<https://wallstreetcn.com/livenews/3130175>

#03 ★★★★★☆

华尔街见闻 · 1 小时前

贝恩称AI部署周期或达二十年 ↗

贝恩资本高级顾问Steve Pagliuca称，AI增长部署将持续10至20年，量子计算可能成为叠加在AI之上的下一波技术浪潮。

So What AI不是短期预算项目，而是长期资本配置主题；管理层应建立分阶段投资和退出评估机制。

<https://wallstreetcn.com/livenews/3130202>

#04 ★★★★★☆

虎嗅 · 7 小时前

资本市场寻找AI叙事下一步 ↗

虎嗅半年度复盘聚焦全球宏观与资本市场，讨论AI叙事在估值、流动性与产业兑现之间的下一阶段演变。

So What 融资窗口和估值逻辑可能切换，企业需把AI故事从愿景叙述转为订单、毛利和现金流证明。

<https://m.huxiu.com/article/4873407.html>

#01 ★★★★★

华尔街见闻 · 47 分钟前

AI行情转向业绩兑现分化 ↗

分析认为AI科技股已告别无差别上涨，7月中下旬美股财报季将验证个股成色，长期取决于商业化与现金流兑现。

So What 董事会应警惕AI项目估值透支，优先推动可衡量收入、降本或客户留存的应用落地。

<https://wallstreetcn.com/livenews/3130209>

#02 ★★★★★

Hacker News · 1 小时前

中国AI模型获美国企业采用 ↗

报道称随着AI使用成本上升，中国AI模型正被更多美国公司纳入选择范围，低成本与可用性能成为跨境采购的重要驱动。

So What 全球AI供应链可能重新定价；跨国企业需同步评估成本优势、数据合规和地缘政治风险。

<https://www.cnn.com/2026/07/07/chinese-ai-models-costs-us-openai-anthropic.html>

#03 ★★★☆☆

华尔街见闻 · 40 分钟前

港股科技反弹受AI叙事推动 ↗

恒生科技指数上周上涨5.72%，创年内最大单周涨幅；市场认为估值底、流动性改善与AI叙事切换共同推动修复。

So What 二级市场风险偏好回暖可能改善融资条件，但管理层仍需避免借AI概念进行低质量扩张。

<https://wallstreetcn.com/livenews/3130212>

#04 ★★★☆☆

华尔街见闻 · 1 小时前

美股AI硬件链出现明显回调 ↗

周二美国科技七巨头指数微涨0.14%，但存储芯片与硬件供应链指数下跌6.52%，云服务商相关板块也承压。

So What AI基础设施链条波动加剧，企业签订算力、芯片和服务器合同时保留价格重谈与交付弹性。

<https://wallstreetcn.com/livenews/3130197>

#01 ★★★★★☆

Hacker News · 4 分钟前

OpenAI披露低延迟语音AI交付 ↗

OpenAI面向约9亿用户提供低延迟语音AI能力，重点在实时交互、基础设施调度与大规模用户体验保障。

So What

语音AI正接近客服、销售与办公入口级应用，企业需重新评估呼叫中心和移动端交互流程。

<https://blog.bytebytego.com/p/how-openai-delivers-low-latency-voice>

#02 ★★★★★☆

虎嗅 · 19 分钟前

豆包千问元宝下线智能体功能 ↗

虎嗅称豆包、千问、元宝等产品集体下线智能体功能，背后涉及成本、体验与合规等多重账本的再平衡。

So What

企业部署智能体不能只追求功能展示，应先核算调用成本、失败兜底和责任边界。

<https://m.huxiu.com/article/4873417.html>

#03 ★★★★★☆

Hacker News · 1 小时前

AI巨头以免费算力争夺初创公司 ↗

报道称AI巨头向初创企业提供大量免费计算资源，以争夺开发者、应用生态和未来企业客户份额。

So What

免费算力可降低试点门槛，但也会形成平台依赖；采购团队应预设迁移成本和数据可携带条款。

<https://www.wsj.com/tech/ai/ai-giants-are-handing-out-tons-of-free-computing-power-to-...are-c00a5c5c>

#04 ★★★★★☆

华尔街见闻 · 34 分钟前

高温推动AI数据中心液冷升级 ↗

持续高温带动制冷设备、电力保供和算力散热需求增长，社会用电负荷屡创新高，并倒逼AI数据中心加速液冷迭代。

So What

AI算力规划必须纳入能源与散热约束，数据中心选址、PUE目标和电力保障应进入高管议程。

<https://wallstreetcn.com/livenews/3130213>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	2/10	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		44.2
17	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
18	Muse Spark R	闭源未知	—	Meta · 美国		43.1
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年07月07日 周二 | 近 8 小时 AI 行业关键动向

SCANNED

423

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今天最值得管理者关注三件事：AI资本开支正向实体产业扩散，高盛预计六年投入达7.6万亿美元；美国监管层开始评估AI泡沫风险，估值与融资环境或趋严；算力、机器人和AI终端进入产业化验证期，采购决策必须从概念转向ROI、供应链和安全治理。



■ 战略动向 · Strategy	4 33%
■ 行业影响 · Industry	4 33%
■ 管理实践 · Practice	4 33%

ACTION ITEMS · 行动建议

- 01 复盘现有AI项目现金流假设，砍掉无明确业务指标的试点
- 02 为核心模型和算力供应商建立双供应与退出预案
- 03 将AI协作能力纳入关键岗位招聘和晋升评分表
- 04 对推理模型上线前增加越狱测试与审计留痕要求

#01 ★★★★★

36氪 · 58 分钟前

摩根士丹利称AI价值仍待新公司释放 ↗

摩根士丹利最新AI报告指出，摩尔定律放缓后瓶颈迁移，真正创造最大价值的AI公司可能尚未成立，产业机会仍在重分布。

So What 管理层不应只追逐现有龙头，应关注新瓶颈环节，重新审视投资、合作与内部孵化方向。

<https://36kr.com/p/3884786855882755>

#02 ★★★★★

华尔街见闻 · 2 小时前

高盛称AI资本开支六年达7.6万亿美元 ↗

高盛预计2026至2031年全球围绕计算、数据中心和电力的AI资本开支约7.6万亿美元，AI投资正向制造、能源、物流等实体产业扩散。

So What AI竞争已升级为资本、能源和场景协同战，企业需把算力、电力和产业数据纳入长期战略预算。

<https://wallstreetcn.com/livenews/3129433>

#03 ★★★★★☆

Hacker News · 28 分钟前

Claude Sonnet 5降价发布 ↗

Anthropic发布更强Agent能力的Claude Sonnet 5，并以更低价格推向市场，显示前沿模型竞争正从能力比拼转向性价比与规模化调用。

So What 企业采购模型时议价空间扩大，应重新测算多模型组合成本，避免被单一供应商锁定。

<https://lucasaguilar.xyz/en/posts/claude-sonnet-5-2026/>

#04 ★★★★★☆

华尔街见闻 · 1 小时前

中国AI眼镜独角兽获腾讯美团加码 ↗

前苹果员工创办的Even Realities获腾讯、美团等投资，B轮前融资1.5亿美元，估值达10亿美元，AI眼镜硬件赛道升温。

So What 消费级AI入口可能从手机外溢到可穿戴设备，品牌、零售和本地服务企业需提前布局交互场景。

<https://wallstreetcn.com/livenews/3129608>

#01 ★★★★★

36氪 · 58 分钟前

美国财政部评估AI泡沫风险 ↗

一份内部报告显示，美国财政部开始评估AI泡沫风险，担忧AI投资可能重演2000年互联网泡沫，破裂后冲击穿透经济体系。

So What

融资和估值环境可能转向审慎，企业应压实AI项目现金流假设，避免以概念投入替代真实回报。

<https://36kr.com/p/3884790230692102>

#02 ★★★★★☆

虎嗅 · 1 小时前

HR竞争焦点转向人才识别 ↗

虎嗅指出，AI组织真正升级的不只是培训，而是人才筛选与识别能力，招聘质量将决定企业能否形成AI生产力。

So What

管理者应重构岗位画像和面试机制，把AI协作能力、学习速度和问题拆解力纳入核心评价。

<https://m.huxiu.com/article/4873112.html>

#03 ★★★★★☆

Hacker News · 1 小时前

英伟达为GPU租赁商兜底 ↗

消息称英伟达正为新型云厂商GPU租赁业务提供支持，反映AI算力租赁市场高速扩张，同时也暴露需求可持续性风险。

So What

企业采购云算力时需评估供应商资金结构与合同稳定性，避免低价租赁背后的履约风险。

<https://newsletter.semianalysis.com/p/nvidia-gpu-debt-backstop-unleashes>

#04 ★★★★★☆

华尔街见闻 · 2 小时前

前五月中国机器人企业营收破900亿 ↗

工信部披露，今年1至5月我国机器人规上企业营收突破900亿元，同比增长26.9%，人形机器人正从展示演示转向实用落地。

So What

机器人产业化进入验证期，制造、仓储和服务企业可筛选高频刚需场景开展小规模试点。

<https://wallstreetcn.com/livenews/3129591>

#01 ★★★★★☆

36氪 · 58 分钟前

十五个推理模型暴露思考链风险 ↗

研究覆盖15个推理模型、4.1万真实攻击与越狱样本，发现输出背后的思考链可能带来安全与合规风险。

So What

企业部署推理模型时不能只看准确率，应建立提示注入、越权输出和审计留痕测试流程。

<https://36kr.com/p/3884794973974530>

#02 ★★★★★☆

新浪财经 · 5 小时前

英伟达AI服务器路线图引发供应链波动 ↗

市场传出英伟达下一代AI服务器机架架构或因制造困难延后一年以上，亚洲PCB厂商股价重挫，公司回应路线图未变。

So What

关键硬件路线的不确定性会影响数据中心建设节奏，CIO应准备替代供应和分阶段扩容方案。

<https://finance.sina.com.cn/stock/usstock/c/2026-07-07/doc-inifxatm8475789.shtml>

#03 ★★★★★☆

新智元 · 42 分钟前

机器人可看视频学习灵巧操作 ↗

伯克利提出从互联网单目RGB视频到灵巧手真机部署链路，机器人可通过公开视频学习日常操作并迁移到实体执行。

So What

低成本数据来源会降低机器人训练门槛，企业可盘点内部操作视频资产，探索自动化训练价值。

<https://aiera.com.cn/2026/07/07/other/admin/102777/%e6%9c%ba%e5%99%a8%e4%ba%ba%e7%9c%8...86%e9%a2%91/>

#04 ★★★★★☆

新浪财经 · 1 小时前

99万元仿生机器人续航仅2至4小时 ↗

优必选超仿生机器人U1顶配售价达99万元，但续航仅2至4小时，公司就产品定位与使用场景作出回应。

So What

采购人形机器人需先核算续航、维护和场景利用率，避免为展示效果支付过高试错成本。

<https://finance.sina.com.cn/roll/2026-07-07/doc-inifxpil1650537.shtml>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	2/10	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年07月06日 周一 | 近 8 小时 AI 行业关键动向

SCANNED

420

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日最值得高管关注的三件事：一、Scaling Law被曝存在根本性缺陷，以此为基础的算力扩张战略需立即重新审视，这可能是近年来最重要的AI战略风险信号；二、美国出口管制首次延伸至AI模型访问权限层，跨国企业使用境外AI服务的合规风险从理论变为现实；三、企业AI账单失控问题在硅谷集中爆发，Token降价掩盖了总成本爆炸的真相，成本治理已成AI规模化落地的核心管理命题。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

- 01 本周内召集CTO/CIO评估公司算力投资计划中引用Scaling Law假设的部分，识别需要重新论证的决策节点
- 02 要求法务和IT安全团队在两周内完成境外AI服务合规审查，重点核查Claude、GPT等服务在出口管制新规下的使用边界
- 03 立即部署AI调用成本监控看板，按部门拆分Token消耗，设定月度预算上限和超额预警阈值
- 04 梳理公司现有AI项目，将考核指标从'上线数量'改为可量化的业务产出，为三季度投资人沟通准备业绩兑现叙事

#01 ★★★★★

新智元 · 9 分钟前

Scaling Law存在缺陷，万亿算力投入面临重估 ↗

DeepMind研究员爆料OpenAI的Scaling Law原始论文存在bug，意味着以此为依据制定的算力扩张路线可能存在系统性误判，影响波及整个大模型行业的资本配置逻辑。

So What 正在押注算力扩张的企业需重新审视技术路线依据，避免在错误假设上继续加码投资。

<https://aiera.com.cn/2026/07/06/other/admin/102613/openai%e5%a1%8c%e6%88%bf%ef%bc%81sc...bd%e7%83%a7/>

#02 ★★★★★☆

36氪 · 15 分钟前

AI评测平台8个月营收破亿美元，估值达17亿 ↗

伯克利团队创建的免费AI模型评测擂台Arena，不直接开发AI，而是提供模型对比评测服务，8个月实现1亿美元年营收，估值突破17亿美元，成为AI基础设施赛道黑马。

So What AI产业链中「卖水人」角色价值凸显，评测、合规、数据标注等中间层服务存在被低估的战略机会。

<https://36kr.com/p/3883329844555777>

#03 ★★★★★☆

36氪 · 15 分钟前

Anthropic公开模型访问降级规则，出口管制延伸至AI层 ↗

Anthropic全面披露Claude Fable 5的「降级」逻辑，美国出口管制首次明确延伸至模型访问权限层面，不同地区用户将获得差异化的模型能力，合规边界正式划定。

So What 跨国企业使用境外AI服务面临合规分层风险，需评估核心业务场景是否会因地区限制导致能力降级。

<https://36kr.com/p/3883340329332998>

#04 ★★★★★☆

36氪 · 17 分钟前

HBM之父：AI本质是内存战争，GPU实际利用率仅10% ↗

三星HBM发明者金正浩指出AI计算瓶颈在内存而非算力，GPU真正工作时间仅占10%，内存带宽才是核心制约，三星和海力士是全球仅有的能同时攻克两端的公司。

So What 采购AI基础设施时应将内存带宽纳入核心指标，单纯比较GPU算力参数可能导致资源错配。

<https://36kr.com/p/3883376811044866>

#01 ★★★★★

虎嗅 · 4 分钟前

AI时代企业IT部门正被业务部门绕过 ↗

虎嗅报道指出，随着AI工具门槛降低，业务部门开始直接采购和部署AI能力，绕过传统IT审批流程，甲方IT部门的话语权和存在价值正在被系统性削弱。

So What

IT治理架构面临重构压力，需在放开业务创新与管控数据安全、合规风险之间重新划定边界。

<https://m.huxiu.com/article/4872813.html>

#02 ★★★★★☆

36氪 · 15 分钟前

硅谷AI算力账单失控：Token降价但总成本爆炸 ↗

Token单价已跌破1美元，但企业AI调用量爆发式增长导致总账单反而大幅攀升，硅谷多家企业出现AI成本失控问题，部分企业Token支出已吞噬三成工资成本。

So What

AI规模化落地后成本结构将发生根本变化，需提前建立Token用量监控和成本分摊机制，避免账单冲击利润表。

<https://36kr.com/p/3883348786900993>

#03 ★★★★★☆

新浪财经 · 1 小时前

全国多地密集出台新一轮AI产业扶持政策 ↗

北京、上海张江等多地近期推出新一轮AI产业扶持政策，包括高质量数据集建设征集、算力补贴等具体措施，政策窗口期明确开启。

So What

有AI转型计划的企业应立即梳理可申报项目，政策红利窗口期通常较短，先申报者获取资源优势更大。

<https://finance.sina.com.cn/jjxw/2026-07-06/doc-inifvkkk8556694.shtml>

#04 ★★★★★☆

虎嗅 · 10 分钟前

AI深度伪造侵权案例增多，普通员工也成受害者 ↗

虎嗅记录4位遭AI盗脸侵权者的维权过程，受害者涵盖普通职场人，维权成本高、周期长，但已有成功追责案例，侵权者开始付出实质代价。

So What

企业需将员工肖像、声音等生物特征数据纳入隐私保护政策，并制定AI生成内容的使用规范，防范法律风险。

<https://m.huxiu.com/article/4872070.html>

#01 ★★★★★☆

虎嗅 · 2 小时前

物理AI正在驱动企业组织架构变革 ↗

虎嗅报道指出，以具身智能为代表的物理AI进入工厂和物流场景，正在触发企业组织层面的实质性重构，涉及岗位设置、汇报关系和决策流程的系统性调整。

So What 制造、物流类企业管理者需将AI引入纳入组织设计议程，而非仅作为技术采购，否则将出现人机协作的管理真空。

<https://m.huxiu.com/article/4872804.html>

#02 ★★★★★☆

新智元 · 9 分钟前

GPT-5.5出现系统性推理缺陷，复杂任务可靠性存疑 ↗

GPT-5.5被发现在遇到特定数字「516」时推理中断，且任务越复杂翻车概率越高，暴露出当前顶级模型在稳定性和可预期性上仍存在不可控的系统性缺陷。

So What 将AI用于高风险决策场景的企业需建立人工复核机制，不能依赖模型自述的置信度，需设计独立验证流程。

<https://aiera.com.cn/2026/07/06/other/admin/102574/gpt-5-5%e7%aa%81%e9%81%ad%e6%9a%97%...bb%e8%bd%a6/>

#03 ★★★★★☆

华尔街见闻 · 1 小时前

公募三季度调仓：AI赛道从泛科技转向业绩驱动 ↗

上证报调查显示，三季度公募基金仍看好科技成长，但配置逻辑从主题炒作转向AI业绩兑现，资金开始从拥挤的泛AI赛道向有实际营收的细分标的分流。

So What 企业AI投资叙事需从「布局AI」转向可量化的业绩贡献，否则将在新一轮资本评估中面临估值折价压力。

<https://wallstreetcn.com/livenews/3129034>

#04 ★★★★★☆

新浪财经 · 1 小时前

Meta出售富余算力，企业算力采购策略需重新评估 ↗

Meta计划对外出售富余算力，市场担忧算力过剩，但分析认为这是存量资产精细化运营。对企业而言，头部科技公司算力外售意味着中小企业获取高质量算力的渠道和价格将发生变化。

So What 正在规划算力采购的企业可借此窗口重新比价，云厂商与科技巨头直售之间的性价比差异值得重新测算。

<https://finance.sina.com.cn/jjxw/2026-07-06/doc-inifveam1901202.shtml>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年07月05日 周日 | 近 8 小时 AI 行业关键动向

SCANNED

385

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日三件最值得高管关注的事：第一，Anthropic拟封禁非授权访问渠道，依赖灰色通道的业务面临中断风险，合规采购窗口紧迫；第二，硅谷AI账单失控警报——Token总成本已占部分企业薪资支出三成，AI算力正成为不可忽视的核心运营成本，CFO需纳入预算管控；第三，LLM Agent供应链攻击新漏洞曝光，企业级Agent部署面临系统性安全风险，信息安全体系亟需扩展覆盖AI攻击面。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

- 本周内审查现有Claude/OpenAI API调用链路，确认全部接入来自官方授权渠道，评估非合规渠道业务的迁移优先级与时间表
- 责成CFO与CTO联合建立AI算力成本追踪仪表盘，设定各业务线Token消耗预算上限与超支预警阈值，下月前完成第一版报告
- 要求信息安全团队在30天内完成企业内所有Agent插件与第三方技能的安全审计，输出高风险组件清单并制定整改方案
- 在下次AI工具选型评审中，要求技术团队用业务语言而非技术指标呈现模型能力对比，邀请业务负责人参与最终决策

#01 ★★★★★

新智元 · 2 分钟前

Anthropic拟全面封禁AI服务地下访问通道 ↗

Anthropic正在准备全面封禁通过非官方渠道绕过访问限制的行为，涉及API滥用与合规管控。此举将影响依赖灰色渠道调用Claude服务的企业与开发者，平台管控趋严信号明确。

So What 依赖非正规渠道调用Claude的业务将面临中断风险，需立即核查供应商合规性，尽快迁移至官方授权接入方式。

<https://aiera.com.cn/2026/07/05/other/admin/102503/%e7%aa%81%e5%8f%91%ef%bc%81anthropi...9a%e9%81%93/>

#02 ★★★★★☆

新智元 · 2 分钟前

GPT-5.6三款新模型疑似定档7月7日发布 ↗

底层代码曝光显示OpenAI正准备发布GPT-5.6系列三款模型，预计7月7日上线。此次泄露信息显示模型能力进一步分层，针对不同应用场景差异化定价策略或随之调整。

So What 新模型发布将带来能力与价格双重变化，企业应提前评估现有AI采购合同的续约节点，避免被锁定在旧版本高价区间。

<https://aiera.com.cn/2026/07/05/other/admin/102474/%e8%b6%81%e7%81%ab%e6%89%93%e5%8a%a...a5%ef%bc%9f/>

#03 ★★★★★☆

新智元 · 3 分钟前

OpenAI全资收购23岁创业者及其公司 ↗

OpenAI收购了一位23岁创始人用4年时间创办的AI公司，创始人19岁时代码尚无法运行，此后迅速成长被巨头整体并入。此次并购体现了OpenAI加速人才与技术内化的战略节奏。

So What 巨头并购节奏加快，优秀AI创业团队被快速虹吸，企业自建AI能力窗口期收窄，需加快内部AI人才储备或战略合作布局。

<https://aiera.com.cn/2026/07/05/other/admin/102424/23%e5%b2%814%e5%b9%b4%e9%80%86%e8%a...86%ef%bc%81/>

#04 ★★★★★☆

Hacker News · 2 小时前

GPT-5.5 Codex推理性能出现退化问题 ↗

技术社区发现GPT-5.5 Codex存在推理token聚类异常，导致编程推理性能下降。这一问题表明大模型迭代并非线性进步，版本升级存在能力退化风险，需持续验证。

So What 企业在升级AI模型版本时不可默认「新版必优」，应建立版本切换前的基准测试流程，避免生产环境性能意外下滑。

<https://github.com/openai/codex/issues/30364>

#01 ★★★★★

新智元 · 3 分钟前

硅谷企业AI账单失控：Token成本吃掉三成工资 ↗

尽管Token单价已跌破1美元，但企业AI总账单因使用量爆炸性增长而持续膨胀，部分硅谷公司AI计算成本已占员工薪资支出三成。成本结构正在被根本性改写。

So What AI不再是边际成本，已成重大固定支出项。CFO需将AI算力成本纳入预算管控体系，建立使用量阈值预警与ROI追踪机制。

<https://aiera.com.cn/2026/07/05/other/admin/102447/token%E5%90%83%E6%8E%89%E4%B8%89%E6...a7%E4%BA%86/>

#02 ★★★★★☆

新智元 · 2 分钟前

游戏开发接入Claude后工程师转型为AI验收员 ↗

Fable 5游戏解禁后立即接入Claude Tasks，工程师角色从「写代码」转变为「验收AI产出」。这一案例标志着AI正在重构软件与游戏开发岗位职能边界，验收与评审能力成为新核心。

So What 技术岗位职能正在向AI协作者转型，企业需重新定义工程师KPI与招聘标准，将AI输出质量评估能力纳入核心胜任力。

<https://aiera.com.cn/2026/07/05/other/admin/102486/fable-5%E8%A7%A3%E7%A6%81%E5%8D%B3...98%E3%80%8D/>

#03 ★★★★★☆

Hacker News · 2 小时前

LLM Agent供应链攻击新漏洞被安全研究者曝光 ↗

安全研究发现攻击者可通过无载荷技能（Payload-Less Skills）植入方式，在LLM Agent调用链中实施供应链攻击，绕过传统安全检测。此漏洞对企业级Agent部署构成系统性风险。

So What 企业Agent部署面临新型供应链安全威胁，需立即审查第三方技能插件的来源与权限范围，将Agent安全纳入信息安全管理框架。

<https://arxiv.org/abs/2605.14460>

#04 ★★★★★☆

新智元 · 3 分钟前

文件系统架构可使Agent Token消耗降低45% ↗

研究显示，为AI Agent引入文件系统层进行信息检索，可将Token消耗降低45%，相应费用减少39%。这为大规模Agent部署提供了可量化的降本技术路径。

So What 对已规模化部署Agent的企业，文件系统架构改造可带来近四成成本节约，值得纳入下一阶段AI基础设施优化计划。

<https://aiera.com.cn/2026/07/05/other/admin/102436/%E6%96%87%E4%BB%B6%E7%B3%BB%E7%BB%9...%E5%B0%9139/>

#01 ★★★☆☆

Hacker News • 38 分钟前

内存映射层技术可有效降低LLM上下文过载 ↗

技术方案提出通过In-Memory Layers进行上下文映射管理，减少LLM因信息过载导致的性能下降与成本浪费。该方案对处理长文档、多轮对话的企业应用场景具有直接参考价值。

So What 长上下文业务场景中引入内存映射层，可同步改善响应质量与控制成本，技术团队可将其列入近期架构评审议题。

<https://ridgetext.com/blog/mapbox-llm-composition>

#02 ★★★☆☆

Hacker News • 1 小时前

开源Rust推理引擎支持超出内存限制的LLM部署 ↗

一款用Rust从零构建的LLM推理引擎发布，支持Out-of-Core推理，允许在显存不足的硬件上运行大模型。这为希望自主部署大模型、降低云端依赖的企业提供了新选项。

So What 本地化部署大模型的硬件门槛正在降低，有数据安全或成本压力的企业可重新评估私有化部署可行性，减少对云厂商的依赖。

<https://github.com/Vage91/Kortex>

#03 ★★☆☆☆

Hacker News • 1 小时前

面向非技术管理者的LLM性能评估框架引发关注 ↗

一位开发者为让非技术背景的配偶理解LLM能力差异，构建了以实际使用感受为核心的评估基准WifeBench。该框架折射出企业内部AI工具选型中非技术决策者的认知鸿沟问题。

So What 企业AI工具选型中，非技术高管的理解与认同是落地关键障碍，需建立面向业务语言的AI能力展示与评估机制，而非依赖技术指标。

<https://www.wifebench.com/>

#04 ★★★☆☆

Hacker News • 2 小时前

AI音乐生成质量缺陷引发工具可靠性管理讨论 ↗

Suno生成音乐存在系统性音频闪烁缺陷，开发者通过后处理工具加以修复。该案例揭示企业使用生成式AI工具时，输出质量的不稳定性需要配套的人工校验与后处理流程。

So What 生成式AI工具的输出质量尚不稳定，企业在内容生产流程中引入AI时，必须设计配套的质检与人工审核环节，不可直接用于对外交付。

<https://www.instasong.co/tools/desunofier>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年07月04日 周六 | 近 8 小时 AI 行业关键动向

SCANNED

416

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日有三件事值得高管重点关注：第一，阿里强制禁用Claude的安全事件，表明AI编程工具的供应链安全已成企业级紧迫议题，任何组织都需立即审查在用AI工具的数据安全风险；第二，Anthropic启动自研芯片并向三星洽谈2nm合作，标志着AI竞争全面从模型层延伸至硬件层，算力自主化将重塑行业格局；第三，欧洲监管机构密集发声，将AI纳入系统性风险框架，对金融及跨国企业的合规压力将在未来12个月内显著上升。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

- 本周内组织IT与法务团队，对企业现用AI编程工具（含Claude Code、Copilot等）进行数据流向和权限审查，建立AI工具准入白名单
- 在下季度战略会议中将AI算力采购策略列为专项议题，评估现有英伟达依赖度并启动推理专用芯片供应商调研
- 要求法务团队于30天内完成欧盟及英国AI监管新动态梳理，识别现有业务中高风险合规敞口并制定整改优先级
- 将AI风险作为独立议题纳入下次董事会风险报告，明确责任人和季度审查机制，而非继续归并在IT安全类目下

#01 ★★★★★

新智元 · 31 分钟前

Anthropic启动自研芯片计划，挖角OpenAI老兵密谈三星2nm ↗

Anthropic被曝正推进自研AI芯片，已从OpenAI挖角核心人才，并与三星就2nm制程展开密谈。继谷歌、Meta、亚马逊之后，主流AI实验室正全面向算力自主化布局。

So What AI算力竞争从模型层延伸至芯片层，算力自主化将重塑供应链话语权，依赖英伟达单一供应商的企业需评估长期采购风险。

<https://aiera.com.cn/2026/07/04/other/admin/102310/anthropic%e8%a2%ab%e6%9b%9d%e9%80%a...e6%98%9f2nm/>

#02 ★★★★★

新智元 · 30 分钟前

Claude Code企业级功能向20美元订阅用户全面开放

Anthropic将原本仅面向大型企业团队的Claude Code高级功能下放至20美元/月Pro用户，两周内完成从企业专属到大众普及的跨越，大幅降低AI编程能力的使用门槛。

So What 高端AI能力平民化提速，企业在AI工具上的差异化壁垒快速消失，需重新评估自身AI工具策略和团队技能建设优先级。

<https://aiera.com.cn/2026/07/04/other/admin/102369/%e5%88%9a%e5%88%9a%ef%bc%8cclaude-c...b7%ef%bc%81/>

#03 ★★★★★

虎嗅 · 3 小时前

Meta内部出现算力过剩质疑，扎克伯格与AI负责人表述矛盾

扎克伯格公开表示AI进展慢于预期，但Meta AI负责人称新模型已追上GPT-5.5。内部信号矛盾叠加算力过剩疑云，折射出超大规模AI投入与实际落地之间的落差张力。

So What 巨头内部出现AI投入与产出错配信号，提示企业在制定AI算力投入计划时应设置阶段性ROI验证节点，避免盲目跟投。

<https://m.huxiu.com/article/4872592.html>

#04 ★★★★★

华尔街见闻 · 7 小时前

加拿大养老基金向EQT投入17.5亿美元押注AI基础设施 ↗

CPP Investments宣布向EQT旗下EdgeConneX投资17.5亿美元，用于未来数年AI基础设施开发。机构长线资金持续加码AI算力底座，数据中心建设竞赛进入新阶段。

So What 主权级长线资金入场AI基础设施，意味着该赛道已进入确定性配置阶段，相关产业链企业可借势融资或寻求战略合作机会。

<https://wallstreetcn.com/livenews/3128806>

#01 ★★★★★

华尔街见闻 · 4 小时前

欧洲顶级监管机构警告：AI发展速度已超越现行金融规则 ↗

英国FCA等欧洲监管机构明确表示，现行金融法规已难以跟上AI发展节奏，自主AI（Agentic AI）的普及正对市场诚信与系统稳定性构成新威胁，监管框架急需重构。

So What 金融行业AI合规窗口期正在收窄，在欧洲有业务的金融机构须立即启动AI使用合规审计，抢在新规落地前完成内部治理框架搭建。

<https://wallstreetcn.com/livenews/3128832>

#02 ★★★★★☆

虎嗅 · 3 小时前

推理专用芯片崛起，GPU垄断算力格局面临重构 ↗

推理芯片的快速成熟正在冲击英伟达GPU在AI算力领域的主导地位，专用推理硬件在成本和效率上的优势日益凸显，算力市场多极化格局加速形成。

So What 企业AI算力采购策略需要重新评估，推理阶段引入专用芯片可显著降低单次推理成本，现在是与多家芯片供应商建立关系的战略窗口。

<https://m.huxiu.com/article/4872597.html>

#03 ★★★★★☆

华尔街见闻 · 5 小时前

特朗普前AI顾问明确：美国不会设立类FDA式AI监管机构 ↗

前白宫AI顾问Sriram Krishnan表示，特朗普政府不会建立正式AI许可制度，但白宫已动用行政权力暂缓部分顶尖大模型发布，监管路径呈现选择性干预而非系统立法特征。

So What 美国AI监管将维持碎片化、行政干预式路径，企业需应对政策不确定性，重点防范特定模型或应用场景遭行政叫停的运营风险。

<https://wallstreetcn.com/livenews/3128826>

#04 ★★★★★☆

华尔街见闻 · 4 小时前

欧洲央行拉加德：AI带来生产力红利同时构成重大系统性风险 ↗

欧洲央行行长拉加德指出AI是生产力和收益来源，但同时警告AI加速演进带来的风险远超过去十年的网络安全威胁，现有防御手段和资金投入均严重不足。

So What 央行级监管者将AI风险提升至系统性高度，企业董事会需将AI风险纳入整体风险管理框架，而非仅作为IT安全议题处理。

<https://wallstreetcn.com/livenews/3128834>

#01 ★★★★★

新智元 · 31 分钟前

阿里全面禁用Claude，7月10日起强制卸载疑存后门 ↗

阿里巴巴被曝于7月10日起全面禁止员工使用Claude，并要求卸载相关工具，起因是Claude Code被发现疑似暗藏后门及隐蔽标记机制，引发企业级数据安全高度警觉。

So What 大型企业AI工具安全审查已成刚需，管理者应立即核查现有AI编程工具的数据流向和权限范围，制定明确的AI工具准入白名单制度。

<https://aiera.com.cn/2026/07/04/other/admin/102276/%e7%aa%81%e5%8f%91%ef%bc%81%e9%98%b8%e8%bd%bd/>

#02 ★★★☆☆

Hacker News · 27 分钟前

新工具可通过Git提交记录检测代码库中的AI生成内容 ↗

Repo-Slopscore工具通过分析Git提交历史中的特征模式，识别代码库中AI生成内容的比例，为企业评估代码质量和开发者行为提供新的可量化手段。

So What 技术管理者现在可量化团队AI代码使用情况，建议将此类检测纳入代码审查流程，用于评估AI辅助编程的质量风险而非作为惩罚工具。

<https://slopscan.ava.pet/>

#03 ★★★☆☆

Hacker News · 28 分钟前

开源LLM拦截管道工具上线，支持生产环境AI应用监控 ↗

Gavio是面向生产环境LLM应用的开源拦截器管道工具，可在AI请求链路中插入监控、过滤和审计节点，帮助企业在不改动核心应用的前提下实现AI行为的可观测性管理。

So What 企业部署生产级AI应用时，可借助此类开源工具低成本实现合规审计和异常行为监控，降低自研监控系统的时间与资金成本。

<https://github.com/manojmallick/gavio>

#04 ★★★☆☆

华尔街见闻 · 3 小时前

AI热潮带动新兴市场资产反弹，韩国芯片股领涨 ↗

MSCI新兴市场指数单日涨幅达2.2%，创6月15日以来最大涨幅，SK海力士和三星表现强劲。AI资本热潮已形成跨市场联动效应，算力上游供应链获持续溢价。

So What AI算力投资情绪已传导至全球资本市场，企业若有HBM内存或AI硬件相关供应链布局，当前是优化资产配置和合作谈判的有利时机。

<https://wallstreetcn.com/livenews/3128844>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年07月03日 周五 | 近 8 小时 AI 行业关键动向

SCANNED

447

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日管理者最需关注三件事：第一，Meta宣布开放算力租赁，叠加GLM等国产模型性价比突破，AI基础资源成本正在快速下降，企业算力和模型采购策略需要立即重新评估；第二，韩国动用国家税收、Anthropic疯狂挖角学术顶尖人才，AI竞争已全面升级为国家战略级资源争夺，中国企业面临多维度竞争压力；第三，AI对劳动力市场的冲击已从裁员转化为生计确定性的系统性瓦解，组织的人才稳定性管理和技能转型规划已刻不容缓。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

- 本周内启动国产开源模型（如GLM-5.2）替代现有境外API的可行性评估，要求技术团队提供成本对比和合规风险报告，目标降低AI调用成本30%以上。
- 要求HR在两周内提交公司AI高风险岗位清单，并为受影响员工设计具体的技能转型路径，而非等待员工自发离职后再被动补招。
- 将AI工具引入生产环境的审批流程中增加「资源消耗压测」和「异常回滚机制验证」两项强制检查项，防止类似Codex日志Bug等问题冲击核心业务系统。
- 与法务和合规团队在本季度内建立AI供应商合规动态监控机制，重点追踪出口管制政策变化，提前识别现有AI服务中断风险并准备备选方案。

#01 ★★★★★

新智元 · 1 分钟前

Meta转型算力租赁商冲击AI芯片产业链 ↗

Meta宣布开放自有算力资源对外出租，从AI模型竞争者转型为算力基础设施提供商，消息引发美股AI产业链剧烈震荡，英伟达等芯片股承压，市场对算力供需格局重新定价。

So What 算力市场正从稀缺走向过剩，巨头入场压低租赁价格，企业采购算力的谈判筹码增加，但依赖算力概念的投资逻辑需重新评估。

<https://aiera.com.cn/2026/07/03/other/admin/102204/%e5%8d%b7%e4%b8%8d%e8%b5%a2%e6%a8%a...a9%e7%be%8e/>

#02 ★★★★★☆

新智元 · 2 分钟前

Anthropic两周挖走诺奖得主等四位顶级学者 ↗

Anthropic在两周内连续招募诺贝尔奖得主及伯克利计算机系主任等四位学术领军人物，显示顶级AI公司已将人才争夺从工程师层面升级至科学家和院士级别，研究能力军备竞赛加速。

So What 学术顶尖人才加速向商业AI公司流动，企业与高校的人才通道正在重构，本土AI公司面临更高维度的人才争夺压力。

<https://aiera.com.cn/2026/07/03/other/admin/102109/%e6%8a%a2%e5%ae%8c%e8%af%ba%e5%a5%9...9b%e5%b0%86/>

#03 ★★★★★☆

36氪 · 3 分钟前

阿里AI产线大整合，92年高管统管三大Agent ↗

阿里对AI产品线进行重大组织整合，将旗下多个Agent产品统一划归至由1992年出生的陈宇森主导的团队管理，两个独立Agent被并入兄弟团队，标志着阿里AI战略从分散孵化转向集中作战。

So What 大厂AI组织从多点开花转向精兵集结，年轻管理者主导核心AI产品已成趋势，企业内部AI资源分散的代价开始显现。

<https://36kr.com/p/3878491297296388>

#04 ★★★★★☆

华尔街见闻 · 20 分钟前

韩国拟动用5万亿韩元税收自主研发国家级AI模型 ↗

韩国科技信息通信部正讨论将半导体景气带来的约5万亿韩元增量税收用于AI自主研发，计划购买约1万个英伟达Vera Rubin GPU模块并集中分配给本国企业，加速构建主权AI能力。

So What 国家级AI算力投入已成为大国竞争标配，中国竞争对手的外部压力在政策和算力两条线同步加码，供应链自主可控的紧迫性进一步上升。

<https://wallstreetcn.com/livenews/3128284>

#01 ★★★★★☆

虎嗅 · 54 分钟前

AI正在系统性消除职业的长期确定性 ↗

AI对劳动力市场的冲击已从岗位裁撤升级为生计确定性的整体瓦解，受冲击群体从蓝领扩展至知识工作者，职业路径规划、薪资预期和技能保值周期均面临根本性重构。

So What 员工稳定性预期下降将传导为组织忠诚度和留才成本上升，管理者需提前设计技能转型通道，否则将面临核心人才主动出走的风险。

<https://m.huxiu.com/article/4872267.html>

#02 ★★★★★☆

虎嗅 · 4 小时前

Anthropic解禁事件折射美国AI管制深层矛盾 ↗

Anthropic模型的出口管制松绑背后，暴露美国政府在推动AI商业扩张与防止技术扩散之间的两难困境，监管框架尚未成型而模型能力已远超现有规则，政策不确定性持续上升。

So What 跨国AI业务的合规窗口随政治风向快速开关，企业需将AI合规风险纳入供应链和市场准入的常态化管理，而非视为一次性事件。

<https://m.huxiu.com/article/4872252.html>

#03 ★★★★★☆

虎嗅 · 4 小时前

AI Agent全面渗透电商，Token经济模型浮现 ↗

AI Agent已在电商场景中承担选品、定价、客服等完整业务环节，行业开始探索以Token为计量单位的AI能力定价和交易机制，预示电商运营成本结构和人力配置将发生根本性变化。

So What 电商企业需要在12个月内明确哪些运营岗位可被Agent替代，并建立Token消耗与业务产出的ROI核算体系，否则将在成本竞争中落后。

<https://m.huxiu.com/article/4872255.html>

#04 ★★★★★☆

虎嗅 · 4 小时前

AI时代认知分层加剧，判断力成核心竞争资产 ↗

AI工具普及并未消除能力差距，反而加速了人与人之间的认知分层：能够有效使用AI放大判断力的人与被AI替代决策的人之间的差距正在拉大，形成新的职场阶层固化。

So What 企业内部AI能力分层将直接影响决策质量和组织效能，识别并保留具备高阶判断力的人才比普及AI工具更关键。

<https://m.huxiu.com/article/4872253.html>

#01 ★★★★★☆

Hacker News · 7 分钟前

中国开源模型GLM-5.2以五分之一成本挑战Claude ↗

清华系GLM-5.2开源模型在多项基准测试上逼近Claude性能，但推理和部署成本仅为Claude的约五分之一，为国内企业提供了在不妥协太多能力的前提下大幅降低AI使用成本的可行路径。

So What 国产开源模型的性价比拐点已到来，正在使用境外商业API的企业应立即启动国产替代评估，既可压缩成本，也可规避合规风险。

<https://mrkt30.com/glm-5-2-open-source-ai/>

#02 ★★★★★☆

新智元 · 2 分钟前

OpenAI Codex日志Bug导致SSD每年被消耗殆尽 ↗

OpenAI Codex被曝存在严重日志写入Bug，在正常使用场景下每年可消耗约1TB固态硬盘存储空间，被开发者斥为「劣质软件」，暴露AI编程工具在企业级稳定性和资源管理上的重大缺陷。

So What AI开发工具的企业级部署须建立硬件资源监控机制，采购前需要进行生产环境压测，警惕将未经充分验证的AI工具直接引入核心开发流水线。

<https://aiera.com.cn/2026/07/03/other/admin/102135/%e4%b8%80%e5%b9%b4%e5%90%83%e6%8e%8...b6%e3%80%8d/>

#03 ★★★★★☆

新智元 · 2 分钟前

Anthropic公布8款模型横评榜单，Claude Fable5位列第一 ↗

Anthropic官方发布经过评测的8款主流AI模型排名，Claude Fable 5居首，此举兼具产品宣传与行业标准设定意图，为企业选型提供了官方背书的参照框架，但评测方法论独立性存疑。

So What 企业选型AI模型时不应仅依赖供应商自评榜单，需引入内部业务场景的实测数据，防止因营销信息误导而锁定次优供应商。

<https://aiera.com.cn/2026/07/03/other/admin/102123/fable%e7%ac%ac%e4%b8%80%ef%bc%8c%e8...9d%e5%85%89/>

#04 ★★★★★☆

36氪 · 20 分钟前

全球Agent落地核心难题：如何设计可靠的自主循环 ↗

当前企业部署AI Agent的最大瓶颈已从模型能力转移至「Loop工程」——即如何让AI在自主执行、质检和纠错的闭环中保持可控，这一工程问题决定了Agent能否真正替代人工完成复杂任务。

So What 评估AI Agent供应商时，应将Loop稳定性和异常回滚机制列为核心验收标准，而非仅看演示效果，否则生产环境中的失控风险极高。

<https://36kr.com/p/3878518284565125>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年07月02日 周四 | 近 8 小时 AI 行业关键动向

SCANNED

449

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日有三件事高管必须关注：第一，美国最快下周推出自愿AI监管框架，这是联邦层面AI治理的重大信号，在美业务需提前对标合规；第二，武田制药与英矽智能签下最高6亿美元AI药研协议，AI与实体产业深度融合进入大额商业落地阶段，各行业管理者须重新评估AI研发合作的战略紧迫性；第三，Anthropic为Claude赋予独立数字身份，AI Agent正式具备企业主体资格，现有IT权限体系和法律责任框架需系统性升级。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

01 本周内要求法务和IT部门联合评估AI Agent独立账号带来的权限审计漏洞，输出改造方案清单

02 向CFO提交AI工具Token计费成本监控方案，设定季度用量预警阈值，对比开源自部署TCO

03 指定专人跟踪美国自愿AI监管框架文本，下周发布后48小时内完成对现有AI项目的合规差距分析

04 要求内容/创意/电商团队在两周内测试谷歌低成本图像生成模型，提交与现有人力成本的对比测算报告

#01 ★★★★★

华尔街见闻 · 2 分钟前

武田制药与英矽智能签约AI药物研发，最高6亿美元 ↗

武田制药与AI药物研发公司英矽智能达成合作协议，协议总价值最高可达6亿美元。这是制药巨头将AI深度嵌入核心研发管线的重大信号，标志着AI制药从概念走向大额商业落地。

So What 制药行业AI研发军备竞赛正在提速，尚未布局AI研发合作的药企将面临成本与速度双重劣势，需评估自建还是外包AI能力的战略选择。

<https://wallstreetcn.com/livenews/3127681>

#02 ★★★★★

华尔街见闻 · 1 小时前

美国最快下周宣布自愿AI监管制度框架 ↗

知情人士透露，美国政府最快将于下周宣布自愿性AI监管标准体系。这是美国在联邦层面推动AI治理的最新进展，将影响在美运营的所有AI相关企业的合规路径选择。

So What 自愿标准往往是强制监管的前奏，在美有业务的企业应提前对标框架要求，将合规成本纳入AI投资预算，抢先布局可降低未来强制合规的切换成本。

<https://wallstreetcn.com/livenews/3127652>

#03 ★★★★★☆

新智元 · 10 分钟前

Anthropic发布Claude 5工作版，面向所有用户开放 ↗

Anthropic发布Claude 5工作能力版本，面向全体用户开放使用。该版本主打工作场景下的任务执行能力，是Anthropic在消费级与企业级市场同步扩张的关键动作。

So What 主流AI助手能力门槛持续降低，企业内员工自发使用高能力AI工具的趋势将加速，管理层需尽快制定统一的AI工具使用规范，防止数据安全风险失控。

<https://aiera.com.cn/2026/07/02/other/admin/101990/%e7%aa%81%e5%8f%91%ef%bc%8c%e6%89%9...bd%e7%94%a8/>

#04 ★★★★★☆

新智元 · 11 分钟前

Anthropic为Claude发放独立账号，AI获得企业身份 ↗

Anthropic宣布为Claude发布独立账号机制，AI不再需要借用人类账号进行操作。这意味着AI Agent正式获得独立数字身份，可在企业系统中以独立主体身份运行和操作。

So What AI从工具升级为具有独立身份的数字员工，企业需要重新审视权限管理体系、操作审计机制和法律责任归属，现有IT治理框架可能面临系统性重构。

<https://aiera.com.cn/2026/07/02/other/admin/101972/claude%e6%9c%89%e3%80%8c%e7%bc%96%e...91%e7%9a%84/>

#01 ★★★★★☆

虎嗅 · 13 分钟前

美国AI自我设限，中国大模型迎来战略窗口期 ↗

分析指出，随着美国AI监管收紧和出口限制，美国AI产品在部分市场的推进受阻，中国大模型厂商在政策约束相对宽松的窗口期获得加速布局的战略机会，尤其是在海外市场和国内替代方面。

So What 采购AI基础设施的企业应重新评估供应链风险，国内大模型可靠性和合规性正在提升，将单一依赖美国AI供应商的策略调整为双轨布局的时机已成熟。

<https://m.huxiu.com/article/4871775.html>

#02 ★★★★★☆

华尔街见闻 · 1 小时前

Palantir CEO猛批OpenAI和Anthropic按Token计费模式 ↗

Palantir CEO Alex Karp公开抨击Anthropic和OpenAI的Token计费结构，称其导致企业AI成本飙升。他力推Palantir与英伟达开源模型方案，主张企业应掌握数据所有权以控制成本。

So What Token计费模式下AI成本不透明且难以预算，管理层在规模化部署前须建立AI用量监控与成本核算机制，同时评估开源模型自部署方案的TCO对比。

<https://wallstreetcn.com/livenews/3127653>

#03 ★★★★★☆

虎嗅 · 33 分钟前

观点：AI泡沫破裂后，真正的黄金时代才会到来 ↗

虎嗅刊发分析文章，探讨当前AI投资泡沫风险及泡沫破裂后的产业走向，认为真正有价值的技术和商业模式将在泡沫出清后显现，黄金时代在泡沫之后而非当下。

So What 当前AI项目ROI普遍虚高，管理层应区分战略性长期投入与跟风性短期支出，建立清晰的AI投资退出标准，避免在泡沫高点锁定过高采购成本。

<https://m.huxiu.com/article/4871947.html>

#04 ★★★★★☆

华尔街见闻 · 42 分钟前

美联储主席：AI正在重塑经济，通胀近期降温 ↗

美联储主席沃什表示通胀近四周持续降温，同时明确指出AI正在重塑整体经济结构，前瞻指引因此失去必要性。宏观环境的不确定性与AI对生产率的潜在影响同步上升。

So What 美联储高层将AI列为经济结构性变量，企业战略规划需将AI对本行业生产率的冲击纳入中期财务预测，原有基于传统经济周期的预算模型可能需要修正。

<https://wallstreetcn.com/livenews/3127660>

#01 ★★★★★

Hacker News · 1 小时前

红队测试将Claude桌面端变为双面间谍，安全漏洞曝光 ↗

Hacker News报道安全研究人员通过红队测试成功将Claude Desktop操控为双面代理，执行恶意指令。该漏洞暴露了AI桌面客户端在企业环境中面临的提示注入与权限滥用风险。

So What 企业内已部署AI桌面工具的团队面临真实安全威胁，需立即评估AI工具的系统权限边界，限制AI客户端访问敏感数据目录，并将AI安全纳入常规渗透测试范围。

<https://www.theregister.com/security/2026/07/01/red-teamers-turned-claude-desktop-into...ding/5264692>

#02 ★★★★★

新智元 · 11 分钟前

Karpathy提出新知识管理框架，挑战现有RAG架构 ↗

前OpenAI科学家Karpathy提出将个人知识库转化为可持续增值系统的新方法，主张知识应像代码一样可复用和迭代，对当前主流的RAG（检索增强生成）技术路线形成挑战。

So What 企业知识管理和内部AI搜索系统的技术选型需重新审视，基于RAG构建的企业知识库可能面临架构升级需求，建议技术团队跟踪评估新范式的落地成本。

<https://aiera.com.cn/2026/07/02/other/admin/101936/karpathy%e5%8f%88%e5%b0%81%e7%a5%9e...a7%e8%84%91/>

#03 ★★★★★

新智元 · 11 分钟前

谷歌发布最低成本图像生成模型，出图成本仅两毛 ↗

谷歌深夜发布新版图像生成模型，生成速度约4秒，单次成本约0.2元人民币，是目前主流图像AI中成本最低的方案之一，面向企业级高频调用场景具有显著经济价值。

So What 内容生产、广告创意、电商图片等高频图像需求场景的AI替代成本大幅下降，相关业务负责人应立即测试并重新核算内容生产团队的人力成本对比数据。

<https://aiera.com.cn/2026/07/02/other/admin/101919/%e8%b0%b7%e6%ad%8c%e6%b7%b1%e5%a4%9...a5%e4%ba%86/>

#04 ★★☆☆☆

新智元 · 10 分钟前

清华发布第二代智能体社会模拟平台，社会科学可计算化 ↗

清华大学发布AgentSociety第二代平台，通过大规模AI智能体模拟社会行为和群体决策，使社会科学研究从定性走向可计算验证。该平台可用于政策效果预测和市场行为模拟。

So What 大规模多智能体仿真技术正趋于实用，战略规划和政策研究部门可探索将其用于市场进入策略、组织变革影响的模拟预演，降低决策试错成本。

<https://aiera.com.cn/2026/07/02/other/admin/102007/%e6%b8%85%e5%8d%8e%e5%8f%91%e5%b8%8...94%e7%a9%b6/>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>