

# AI 简讯

2026年07月06日 周一 | 近 8 小时 AI 行业关键动向

SCANNED

421

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

## EXECUTIVE SUMMARY · 执行摘要

今日最值得高管关注的三件事：第一，Scaling Law核心论文被指存在bug，若属实将动摇千亿级算力投资的理论基础，所有正在规划大规模算力采购的企业需立即暂停决策等待验证；第二，美国出口管制首次延伸至AI模型访问层，Anthropic公开分级管控规则，跨国运营企业面临新的合规风险盲区；第三，硅谷AI账单失控现象与国内AI资本市场从概念驱动转向业绩驱动同步发生，意味着AI投入必须在本季度拿出可量化ROI数据，否则将同时面临内部预算削减和外部估值压缩的双重压力。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

## ACTION ITEMS · 行动建议

01 本周内召集CTO与CFO核查现有算力采购合同中与Scaling Law挂钩的技术假设，评估若该理论失效的最坏情景敞口

02 要求法务部门在72小时内梳理公司在美国AI服务（尤其Claude/OpenAI）上的访问权限，识别跨境合规风险点并制定备用方案

03 向各业务线发出指令：提交AI工具调用量与实际业务产出的月度对比报告，对ROI低于设定阈值的项目启动30天改善或停止程序

04 联系北京/上海当地政府产业部门，确认本轮AI数据集建设补贴的申报截止时间与企业资质要求，安排专人负责申报

#01 ★★★★★

新智元 · 1 分钟前

## Scaling Law存在重大缺陷，万亿算力投入面临重估 ↗

DeepMind研究员披露OpenAI Scaling Law原始论文存在bug，引发业界对「堆算力=堆智能」路线的根本质疑。若缺陷属实，当前基于该理论指导的千亿美元算力投资逻辑将面临重新审视。

**So What** 正在或计划大规模采购算力的企业须暂缓决策，等待学界对该缺陷的验证结论，避免押注失效技术路线造成战略损失。

<https://aiera.com.cn/2026/07/06/other/admin/102613/openai%e5%a1%8c%e6%88%bf%ef%bc%81sc...bd%e7%83a7/>

#02 ★★★★★☆

36氪 · 7 分钟前

## AI评测平台8个月营收破亿美元，「卖水」模式估值17亿 ↗

伯克利团队创办的AI模型评测擂台Arena不直接造模型，依靠提供免费测评服务积累流量，再向企业收费，8个月实现年化营收1亿美元，估值超17亿美元，成为AI基础设施中 fastest 盈利的细分赛道之一。

**So What** AI价值链中，评测与标准制定方的议价权正在急速上升；企业可评估是否借助第三方评测平台替代内部模型选型成本，同时警惕评测结果被商业利益扭曲的风险。

<https://36kr.com/p/388332984455777>

#03 ★★★★★☆

36氪 · 7 分钟前

## Anthropic公开AI模型访问分级管控规则，出口管制延伸至模型层 ↗

Anthropic全面披露Claude Fable 5「降级」逻辑，将用户请求分为四种处置方式，同时美国出口管制首次将管控范围从芯片延伸至模型访问权限，开创AI服务层监管先例。

**So What** 跨国业务中使用美国AI模型的企业须立即评估合规风险，特别是涉及敏感行业或特定国家的访问请求，可能面临服务中断或法律责任。

<https://36kr.com/p/3883340329332998>

#04 ★★★★★☆

36氪 · 9 分钟前

## HBM之父：AI本质是内存问题，GPU真实算力利用率仅10% ↗

三星HBM发明人金正浩指出，AI计算瓶颈在内存带宽而非算力，当前GPU实际工作时间不足10%，大量算力被内存读写阻塞浪费。三星与海力士是全球仅有的能同时攻克算力与内存的公司。

**So What** 采购算力时不应只看GPU参数，需重新核查内存带宽配置；当前大量算力闲置意味着优化架构可能比继续扩容更具ROI。

<https://36kr.com/p/3883376811044866>

#01 ★★★★★☆

虎嗅 · 3 分钟前

## AI深度伪造侵权普遍化，个人维权成本与路径已现雏形 ↗

虎嗅记录4名被AI盗脸受害者的抗争过程，揭示AI生成内容的侵权已从明星延伸至普通人，维权路径极度不畅，但部分案例通过平台投诉与法律施压已获赔偿，形成可复用经验。

**So What** 品牌与高管形象均面临被AI伪造用于诈骗或声誉攻击的风险，企业需尽快建立肖像权保护预案和员工教育机制。

<https://m.huxiu.com/article/4872070.html>

#02 ★★★★★☆

虎嗅 · 1 小时前

## 物理AI驱动企业组织架构出现结构性变革 ↗

虎嗅文章指出，以具身智能和物理AI为代表的技术落地，正倒逼企业在研发、生产、运营层面重组职能边界，传统组织架构中的中间管理层面职责重新定义，部分企业已启动组织试验。

**So What** 管理者需提前规划：哪些中间层职能将被物理AI替代，如何重新设计汇报链路与激励结构，避免变革滞后于技术部署节奏。

<https://m.huxiu.com/article/4872804.html>

#03 ★★★★★☆

新浪财经 · 1 小时前

## 全国多地密集出台新一轮AI产业扶持政策 ↗

北京启动2026年第三批AI赋能新型工业化高质量数据集建设单位征集，上海张江等多地同步推出AI产业专项政策，政府对AI落地应用的补贴与资质认定进入新一轮窗口期。

**So What** 企业可立即梳理自身AI项目是否符合各地申报条件，本轮政策重点在数据集与工业化应用，制造业与数据密集型企业优先受益。

<https://finance.sina.com.cn/jjxw/2026-07-06/doc-inifvkkk8556694.shtml>

#04 ★★★★★☆

虎嗅 · 7 小时前

## 中美AI教育路线严重分化，中国家长疯狂加码美国富人却撤退 ↗

中国家庭将AI教育视为竞争工具大力投入，而美国高收入群体正逆向选择减少AI依赖、回归人文教育。这一分化折射出两国精英阶层对AI时代人才核心竞争力的根本性判断差异。

**So What** 企业人才战略需重新定义「AI时代核心竞争力」：是工具驾驭能力还是人类独有的判断力？这将影响招聘标准与内部培训资源配置方向。

<https://m.huxiu.com/article/4872798.html>

#01 ★★★★★☆

36氪 · 8 分钟前

### 硅谷AI账单失控：Token单价暴跌但总成本持续爆炸 ↗

Token调用单价已跌至不足1美元，但企业实际AI支出不降反升，原因是调用量增速远超降价幅度。部分团队AI成本已吃掉三成薪资预算，形成「越用越贵」的反直觉困局。

**So What** 立即审计各业务线AI调用量与实际产出比，设置成本上限与ROI门槛，防止AI工具滥用蚕食利润；需建立AI支出的精细化管控流程。

<https://36kr.com/p/3883348786900993>

#02 ★★★★★☆

新浪财经 · 40 分钟前

### AI科技股剧烈震荡，机构对三季度定价逻辑出现重大分歧 ↗

A股AI板块上周大幅调整，券商策略对三季度走势出现明显分歧，多数机构认为7月业绩兑现情况将成为估值重定价核心依据，从「概念驱动」转向「业绩驱动」拐点已至。

**So What** 持有AI上市公司股权或正在融资的企业，需尽快准备可量化的AI业务收入数据，市场对「讲故事」的容忍度正在快速收窄。

<https://finance.sina.com.cn/tech/2026-07-06/doc-inifvkki1791883.shtml>

#03 ★★★★★☆

华尔街见闻 · 48 分钟前

### 公募基金开始撤出拥挤AI赛道，资金向业绩兑现方向迁移 ↗

上半年200余只科技主题基金净值翻倍后，机构止盈压力显现，三季度公募资金开始从泛AI赛道向低估值蓝筹与消费方向分流，科技赛道交易拥挤度风险达到历史级别。

**So What** 依赖资本市场融资的AI企业须警惕估值回调周期，优先锁定长线战略投资者；正在考虑上市或定增的企业需重新评估发行时间窗口。

<https://wallstreetcn.com/livenews/3129039>

#04 ★★★★★☆

新浪财经 · 1 小时前

### Meta出售富余算力，应被解读为资产精细化运营而非过剩信号 ↗

Meta计划开放闲置算力租赁，市场误读为算力过剩。分析指出这是大型企业将存量基础设施资产化的合理商业行为，类似亚马逊AWS的起源逻辑，并非行业需求见顶。

**So What** 企业自建算力资源时可同步规划租赁变现路径；短期内可借机以更低价格从Meta等巨头租用算力，优化AI基础设施成本结构。

<https://finance.sina.com.cn/jjxw/2026-07-06/doc-inifveam1901202.shtml>

# 大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

| #  | 模型                                                                                          | 参数量       | 单价 \$/1M  | 厂商 · 国家         | 能力分布 (II)   | 分数   |
|----|---------------------------------------------------------------------------------------------|-----------|-----------|-----------------|-------------|------|
| 1  | <b>Claude Fable 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort, Opus 4.8 Fallback) | 闭源未知      | 10/50     | Anthropic · ... | <div></div> | 59.9 |
| 2  | <b>Claude Opus 4.8</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 55.7 |
| 3  | <b>GPT-5.5</b> <span>R</span><br>(xhigh)                                                    | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 54.8 |
| 4  | <b>Claude Opus 4.7</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 53.5 |
| 5  | <b>Claude Sonnet 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 3/15      | Anthropic · ... | <div></div> | 53.4 |
| 6  | <b>GPT-5.5</b> <span>R</span><br>(high)                                                     | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 53.1 |
| 7  | <b>GLM-5.2</b> <span>R</span><br>(max)                                                      | 745B MoE  | 1.4/4.4   | Z AI · 中国       | <div></div> | 51.1 |
| 8  | <b>GPT-5.5</b> <span>R</span><br>(medium)                                                   | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 50.4 |
| 9  | <b>Gemini 3.5 Flash</b> <span>R</span><br>(high)                                            | 闭源未知      | 1.5/9     | Google · 美国     | <div></div> | 50.2 |
| 10 | <b>Gemini 3.1 Pro Preview</b> <span>R</span>                                                | 闭源未知      | 2/12      | Google · 美国     | <div></div> | 46.5 |
| 11 | <b>Qwen3.7 Max</b> <span>R</span>                                                           | ≈1T · 闭源  | 2.5/7.5   | Alibaba · 中国    | <div></div> | 46.0 |
| 12 | <b>Gemini 3.5 Flash</b> <span>R</span><br>(medium)                                          | 闭源未知      | 1.5/9     | Google · 美国     | <div></div> | 45.4 |
| 13 | <b>MiniMax-M3</b> <span>R</span>                                                            | 闭源未知      | 0.3/1.2   | MiniMax · 中国    | <div></div> | 44.4 |
| 14 | <b>DeepSeek V4 Pro</b> <span>R</span><br>(Reasoning, Max Effort)                            | ≈671B ... | 0.43/0.87 | DeepSeek · ...  | <div></div> | 44.3 |
| 15 | <b>GPT-5.3 Codex</b> <span>R</span><br>(xhigh)                                              | 闭源未知      | 1.75/14   | OpenAI · 美国     | <div></div> | 44.3 |
| 16 | <b>GPT-5.5</b> <span>R</span><br>(low)                                                      | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 43.5 |
| 17 | <b>Muse Spark</b> <span>R</span>                                                            | 闭源未知      | —         | Meta · 美国       | <div></div> | 43.1 |
| 18 | <b>Kimi K2.6</b> <span>R</span>                                                             | 1T MoE    | 0.95/4    | Kimi · 中国       | <div></div> | 42.8 |
| 19 | <b>Claude Opus 4.7</b><br>(Non-reasoning, High Effort)                                      | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 42.7 |
| 20 | <b>MiMo-V2.5-Pro</b> <span>R</span>                                                         | 未公开       | 0.43/0.87 | Xiaomi · 中国     | <div></div> | 42.2 |

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

# AI 简讯

2026年07月05日 周日 | 近 8 小时 AI 行业关键动向

SCANNED

385

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

## EXECUTIVE SUMMARY · 执行摘要

今日三件最值得高管关注的事：第一，Anthropic拟封禁非授权访问渠道，依赖灰色通道的业务面临中断风险，合规采购窗口紧迫；第二，硅谷AI账单失控警报——Token总成本已占部分企业薪资支出三成，AI算力正成为不可忽视的核心运营成本，CFO需纳入预算管控；第三，LLM Agent供应链攻击新漏洞曝光，企业级Agent部署面临系统性安全风险，信息安全体系亟需扩展覆盖AI攻击面。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

## ACTION ITEMS · 行动建议

- 本周内审查现有Claude/OpenAI API调用链路，确认全部接入来自官方授权渠道，评估非合规渠道业务的迁移优先级与时间表
- 责成CFO与CTO联合建立AI算力成本追踪仪表盘，设定各业务线Token消耗预算上限与超支预警阈值，下月前完成第一版报告
- 要求信息安全团队在30天内完成企业内所有Agent插件与第三方技能的安全审计，输出高风险组件清单并制定整改方案
- 在下次AI工具选型评审中，要求技术团队用业务语言而非技术指标呈现模型能力对比，邀请业务负责人参与最终决策

#01 ★★★★★

新智元 · 2 分钟前

## Anthropic拟全面封禁AI服务地下访问通道 ↗

Anthropic正在准备全面封禁通过非官方渠道绕过访问限制的行为，涉及API滥用与合规管控。此举将影响依赖灰色渠道调用Claude服务的企业与开发者，平台管控趋严信号明确。

**So What** 依赖非正规渠道调用Claude的业务将面临中断风险，需立即核查供应商合规性，尽快迁移至官方授权接入方式。

<https://aiera.com.cn/2026/07/05/other/admin/102503/%e7%aa%81%e5%8f%91%ef%bc%81anthropi...9a%e9%81%93/>

#02 ★★★★★☆

新智元 · 2 分钟前

## GPT-5.6三款新模型疑似定档7月7日发布 ↗

底层代码曝光显示OpenAI正准备发布GPT-5.6系列三款模型，预计7月7日上线。此次泄露信息显示模型能力进一步分层，针对不同应用场景差异化定价策略或随之调整。

**So What** 新模型发布将带来能力与价格双重变化，企业应提前评估现有AI采购合同的续约节点，避免被锁定在旧版本高价区间。

<https://aiera.com.cn/2026/07/05/other/admin/102474/%e8%b6%81%e7%81%ab%e6%89%93%e5%8a%a...a5%ef%bc%9f/>

#03 ★★★★★☆

新智元 · 3 分钟前

## OpenAI全资收购23岁创业者及其公司 ↗

OpenAI收购了一位23岁创始人用4年时间创办的AI公司，创始人19岁时代码尚无法运行，此后迅速成长被巨头整体并入。此次并购体现了OpenAI加速人才与技术内化的战略节奏。

**So What** 巨头并购节奏加快，优秀AI创业团队被快速虹吸，企业自建AI能力窗口期收窄，需加快内部AI人才储备或战略合作布局。

<https://aiera.com.cn/2026/07/05/other/admin/102424/23%e5%b2%814%e5%b9%b4%e9%80%86%e8%a...86%ef%bc%81/>

#04 ★★★★★☆

Hacker News · 2 小时前

## GPT-5.5 Codex推理性能出现退化问题 ↗

技术社区发现GPT-5.5 Codex存在推理token聚类异常，导致编程推理性能下降。这一问题表明大模型迭代并非线性进步，版本升级存在能力退化风险，需持续验证。

**So What** 企业在升级AI模型版本时不可默认「新版必优」，应建立版本切换前的基准测试流程，避免生产环境性能意外下滑。

<https://github.com/openai/codex/issues/30364>

#01 ★★★★★

新智元 · 3 分钟前

## 硅谷企业AI账单失控：Token成本吃掉三成工资 ↗

尽管Token单价已跌破1美元，但企业AI总账单因使用量爆炸性增长而持续膨胀，部分硅谷公司AI计算成本已占员工薪资支出三成。成本结构正在被根本性改写。

**So What** AI不再是边际成本，已成重大固定支出项。CFO需将AI算力成本纳入预算管控体系，建立使用量阈值预警与ROI追踪机制。

<https://aiera.com.cn/2026/07/05/other/admin/102447/token%E5%90%83%E6%8E%89%E4%B8%89%E6...a7%E4%BA%86/>

#02 ★★★★★☆

新智元 · 2 分钟前

## 游戏开发接入Claude后工程师转型为AI验收员 ↗

Fable 5游戏解禁后立即接入Claude Tasks，工程师角色从「写代码」转变为「验收AI产出」。这一案例标志着AI正在重构软件与游戏开发岗位职能边界，验收与评审能力成为新核心。

**So What** 技术岗位职能正在向AI协作者转型，企业需重新定义工程师KPI与招聘标准，将AI输出质量评估能力纳入核心胜任力。

<https://aiera.com.cn/2026/07/05/other/admin/102486/fable-5%E8%A7%A3%E7%A6%81%E5%8D%B3...98%E3%80%8D/>

#03 ★★★★★☆

Hacker News · 2 小时前

## LLM Agent供应链攻击新漏洞被安全研究者曝光 ↗

安全研究发现攻击者可通过无载荷技能（Payload-Less Skills）植入方式，在LLM Agent调用链中实施供应链攻击，绕过传统安全检测。此漏洞对企业级Agent部署构成系统性风险。

**So What** 企业Agent部署面临新型供应链安全威胁，需立即审查第三方技能插件的来源与权限范围，将Agent安全纳入信息安全管理框架。

<https://arxiv.org/abs/2605.14460>

#04 ★★★★★☆

新智元 · 3 分钟前

## 文件系统架构可使Agent Token消耗降低45% ↗

研究显示，为AI Agent引入文件系统层进行信息检索，可将Token消耗降低45%，相应费用减少39%。这为大规模Agent部署提供了可量化的降本技术路径。

**So What** 对已规模化部署Agent的企业，文件系统架构改造可带来近四成成本节约，值得纳入下一阶段AI基础设施优化计划。

<https://aiera.com.cn/2026/07/05/other/admin/102436/%E6%96%87%E4%BB%B6%E7%B3%BB%E7%BB%9...%E5%B0%9139/>

#01 ★★★☆☆

Hacker News • 38 分钟前

## 内存映射层技术可有效降低LLM上下文过载 ↗

技术方案提出通过In-Memory Layers进行上下文映射管理，减少LLM因信息过载导致的性能下降与成本浪费。该方案对处理长文档、多轮对话的企业应用场景具有直接参考价值。

**So What** 长上下文业务场景中引入内存映射层，可同步改善响应质量与控制成本，技术团队可将其列入近期架构评审议题。

<https://ridgetext.com/blog/mapbox-llm-composition>

#02 ★★★☆☆

Hacker News • 1 小时前

## 开源Rust推理引擎支持超出内存限制的LLM部署 ↗

一款用Rust从零构建的LLM推理引擎发布，支持Out-of-Core推理，允许在显存不足的硬件上运行大模型。这为希望自主部署大模型、降低云端依赖的企业提供了新选项。

**So What** 本地化部署大模型的硬件门槛正在降低，有数据安全或成本压力的企业可重新评估私有化部署可行性，减少对云厂商的依赖。

<https://github.com/Vage91/Kortex>

#03 ★★☆☆☆

Hacker News • 1 小时前

## 面向非技术管理者的LLM性能评估框架引发关注 ↗

一位开发者为让非技术背景的配偶理解LLM能力差异，构建了以实际使用感受为核心的评估基准WifeBench。该框架折射出企业内部AI工具选型中非技术决策者的认知鸿沟问题。

**So What** 企业AI工具选型中，非技术高管的理解与认同是落地关键障碍，需建立面向业务语言的AI能力展示与评估机制，而非依赖技术指标。

<https://www.wifebench.com/>

#04 ★★★☆☆

Hacker News • 2 小时前

## AI音乐生成质量缺陷引发工具可靠性管理讨论 ↗

Suno生成音乐存在系统性音频闪烁缺陷，开发者通过后处理工具加以修复。该案例揭示企业使用生成式AI工具时，输出质量的不稳定性需要配套的人工校验与后处理流程。

**So What** 生成式AI工具的输出质量尚不稳定，企业在内容生产流程中引入AI时，必须设计配套的质检与人工审核环节，不可直接用于对外交付。

<https://www.instasong.co/tools/desunofier>

# 大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

| #  | 模型                                                                                          | 参数量       | 单价 \$/1M  | 厂商 · 国家         | 能力分布 (II)              | 分数   |
|----|---------------------------------------------------------------------------------------------|-----------|-----------|-----------------|------------------------|------|
| 1  | <b>Claude Fable 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort, Opus 4.8 Fallback) | 闭源未知      | 10/50     | Anthropic · ... | <div><div></div></div> | 59.9 |
| 2  | <b>Claude Opus 4.8</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div><div></div></div> | 55.7 |
| 3  | <b>GPT-5.5</b> <span>R</span><br>(xhigh)                                                    | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 54.8 |
| 4  | <b>Claude Opus 4.7</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div><div></div></div> | 53.5 |
| 5  | <b>Claude Sonnet 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 3/15      | Anthropic · ... | <div><div></div></div> | 53.4 |
| 6  | <b>GPT-5.5</b> <span>R</span><br>(high)                                                     | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 53.1 |
| 7  | <b>GLM-5.2</b> <span>R</span><br>(max)                                                      | 745B MoE  | 1.4/4.4   | Z AI · 中国       | <div><div></div></div> | 51.1 |
| 8  | <b>GPT-5.5</b> <span>R</span><br>(medium)                                                   | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 50.4 |
| 9  | <b>Gemini 3.5 Flash</b> <span>R</span><br>(high)                                            | 闭源未知      | 1.5/9     | Google · 美国     | <div><div></div></div> | 50.2 |
| 10 | <b>Gemini 3.1 Pro Preview</b> <span>R</span>                                                | 闭源未知      | 2/12      | Google · 美国     | <div><div></div></div> | 46.5 |
| 11 | <b>Qwen3.7 Max</b> <span>R</span>                                                           | ≈1T · 闭源  | 2.5/7.5   | Alibaba · 中国    | <div><div></div></div> | 46.0 |
| 12 | <b>Gemini 3.5 Flash</b> <span>R</span><br>(medium)                                          | 闭源未知      | 1.5/9     | Google · 美国     | <div><div></div></div> | 45.4 |
| 13 | <b>MiniMax-M3</b> <span>R</span>                                                            | 闭源未知      | 0.3/1.2   | MiniMax · 中国    | <div><div></div></div> | 44.4 |
| 14 | <b>DeepSeek V4 Pro</b> <span>R</span><br>(Reasoning, Max Effort)                            | ≈671B ... | 0.43/0.87 | DeepSeek · ...  | <div><div></div></div> | 44.3 |
| 15 | <b>GPT-5.3 Codex</b> <span>R</span><br>(xhigh)                                              | 闭源未知      | 1.75/14   | OpenAI · 美国     | <div><div></div></div> | 44.3 |
| 16 | <b>GPT-5.5</b> <span>R</span><br>(low)                                                      | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 43.5 |
| 17 | <b>Muse Spark</b> <span>R</span>                                                            | 闭源未知      | —         | Meta · 美国       | <div><div></div></div> | 43.1 |
| 18 | <b>Kimi K2.6</b> <span>R</span>                                                             | 1T MoE    | 0.95/4    | Kimi · 中国       | <div><div></div></div> | 42.8 |
| 19 | <b>Claude Opus 4.7</b><br>(Non-reasoning, High Effort)                                      | 闭源未知      | 5/25      | Anthropic · ... | <div><div></div></div> | 42.7 |
| 20 | <b>MiMo-V2.5-Pro</b> <span>R</span>                                                         | 未公开       | 0.43/0.87 | Xiaomi · 中国     | <div><div></div></div> | 42.2 |

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

# AI 简讯

2026年07月04日 周六 | 近 8 小时 AI 行业关键动向

SCANNED

416

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

## EXECUTIVE SUMMARY · 执行摘要

今日有三件事值得高管重点关注：第一，阿里强制禁用Claude的安全事件，表明AI编程工具的供应链安全已成企业级紧迫议题，任何组织都需立即审查在用AI工具的数据安全风险；第二，Anthropic启动自研芯片并向三星洽谈2nm合作，标志着AI竞争全面从模型层延伸至硬件层，算力自主化将重塑行业格局；第三，欧洲监管机构密集发声，将AI纳入系统性风险框架，对金融及跨国企业的合规压力将在未来12个月内显著上升。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

## ACTION ITEMS · 行动建议

- 本周内组织IT与法务团队，对企业现用AI编程工具（含Claude Code、Copilot等）进行数据流向和权限审查，建立AI工具准入白名单
- 在下季度战略会议中将AI算力采购策略列为专项议题，评估现有英伟达依赖度并启动推理专用芯片供应商调研
- 要求法务团队于30天内完成欧盟及英国AI监管新动态梳理，识别现有业务中高风险合规敞口并制定整改优先级
- 将AI风险作为独立议题纳入下次董事会风险报告，明确责任人和季度审查机制，而非继续归并在IT安全类目下

#01 ★★★★★

新智元 · 31 分钟前

## Anthropic启动自研芯片计划，挖角OpenAI老兵密谈三星2nm ↗

Anthropic被曝正推进自研AI芯片，已从OpenAI挖角核心人才，并与三星就2nm制程展开密谈。继谷歌、Meta、亚马逊之后，主流AI实验室正全面向算力自主化布局。

**So What** AI算力竞争从模型层延伸至芯片层，算力自主化将重塑供应链话语权，依赖英伟达单一供应商的企业需评估长期采购风险。

<https://aiera.com.cn/2026/07/04/other/admin/102310/anthropic%e8%a2%ab%e6%9b%9d%e9%80%a...e6%98%9f2nm/>

#02 ★★★★★

新智元 · 30 分钟前

## Claude Code企业级功能向20美元订阅用户全面开放

Anthropic将原本仅面向大型企业团队的Claude Code高级功能下放至20美元/月Pro用户，两周内完成从企业专属到大众普及的跨越，大幅降低AI编程能力的使用门槛。

**So What** 高端AI能力平民化提速，企业在AI工具上的差异化壁垒快速消失，需重新评估自身AI工具策略和团队技能建设优先级。

<https://aiera.com.cn/2026/07/04/other/admin/102369/%e5%88%9a%e5%88%9a%ef%bc%8cclaude-c...b7%ef%bc%81/>

#03 ★★★★★

虎嗅 · 3 小时前

## Meta内部出现算力过剩质疑，扎克伯格与AI负责人表述矛盾

扎克伯格公开表示AI进展慢于预期，但Meta AI负责人称新模型已追上GPT-5.5。内部信号矛盾叠加算力过剩疑云，折射出超大规模AI投入与实际落地之间的落差张力。

**So What** 巨头内部出现AI投入与产出错配信号，提示企业在制定AI算力投入计划时应设置阶段性ROI验证节点，避免盲目跟投。

<https://m.huxiu.com/article/4872592.html>

#04 ★★★★★

华尔街见闻 · 7 小时前

## 加拿大养老基金向EOT投入17.5亿美元押注AI基础设施

CPP Investments宣布向EQT旗下EdgeConneX投资17.5亿美元，用于未来数年AI基础设施开发。机构长线资金持续加码AI算力底座，数据中心建设竞赛进入新阶段。

**So What** 主权级长线资金入场AI基础设施，意味着该赛道已进入确定性配置阶段，相关产业链企业可借势融资或寻求战略合作机会。

<https://wallstreetcn.com/livenews/3128806>

#01 ★★★★★

华尔街见闻 · 4 小时前

## 欧洲顶级监管机构警告：AI发展速度已超越现行金融规则 ↗

英国FCA等欧洲监管机构明确表示，现行金融法规已难以跟上AI发展节奏，自主AI（Agentic AI）的普及正对市场诚信与系统稳定性构成新威胁，监管框架急需重构。

**So What** 金融行业AI合规窗口期正在收窄，在欧洲有业务的金融机构须立即启动AI使用合规审计，抢在新规落地前完成内部治理框架搭建。

<https://wallstreetcn.com/livenews/3128832>

#02 ★★★★★☆

虎嗅 · 3 小时前

## 推理专用芯片崛起，GPU垄断算力格局面临重构 ↗

推理芯片的快速成熟正在冲击英伟达GPU在AI算力领域的主导地位，专用推理硬件在成本和效率上的优势日益凸显，算力市场多极化格局加速形成。

**So What** 企业AI算力采购策略需要重新评估，推理阶段引入专用芯片可显著降低单次推理成本，现在是与多家芯片供应商建立关系的战略窗口。

<https://m.huxiu.com/article/4872597.html>

#03 ★★★★★☆

华尔街见闻 · 5 小时前

## 特朗普前AI顾问明确：美国不会设立类FDA式AI监管机构 ↗

前白宫AI顾问Sriram Krishnan表示，特朗普政府不会建立正式AI许可制度，但白宫已动用行政权力暂缓部分顶尖大模型发布，监管路径呈现选择性干预而非系统立法特征。

**So What** 美国AI监管将维持碎片化、行政干预式路径，企业需应对政策不确定性，重点防范特定模型或应用场景遭行政叫停的运营风险。

<https://wallstreetcn.com/livenews/3128826>

#04 ★★★★★☆

华尔街见闻 · 4 小时前

## 欧洲央行拉加德：AI带来生产力红利同时构成重大系统性风险 ↗

欧洲央行行长拉加德指出AI是生产力和收益来源，但同时警告AI加速演进带来的风险远超过去十年的网络安全威胁，现有防御手段和资金投入均严重不足。

**So What** 央行级监管者将AI风险提升至系统性高度，企业董事会需将AI风险纳入整体风险管理框架，而非仅作为IT安全议题处理。

<https://wallstreetcn.com/livenews/3128834>

#01 ★★★★★

新智元 · 31 分钟前

## 阿里全面禁用Claude，7月10日起强制卸载疑存后门 ↗

阿里巴巴被曝于7月10日起全面禁止员工使用Claude，并要求卸载相关工具，起因是Claude Code被发现疑似暗藏后门及隐蔽标记机制，引发企业级数据安全高度警觉。

**So What** 大型企业AI工具安全审查已成刚需，管理者应立即核查现有AI编程工具的数据流向和权限范围，制定明确的AI工具准入白名单制度。

<https://aiera.com.cn/2026/07/04/other/admin/102276/%e7%aa%81%e5%8f%91%ef%bc%81%e9%98%b8%e8%bd%bd/>

#02 ★★★☆☆

Hacker News · 27 分钟前

## 新工具可通过Git提交记录检测代码库中的AI生成内容 ↗

Repo-Slopscore工具通过分析Git提交历史中的特征模式，识别代码库中AI生成内容的比例，为企业评估代码质量和开发者行为提供新的可量化手段。

**So What** 技术管理者现在可量化团队AI代码使用情况，建议将此类检测纳入代码审查流程，用于评估AI辅助编程的质量风险而非作为惩罚工具。

<https://slopscan.ava.pet/>

#03 ★★★☆☆

Hacker News · 28 分钟前

## 开源LLM拦截管道工具上线，支持生产环境AI应用监控 ↗

Gavio是面向生产环境LLM应用的开源拦截器管道工具，可在AI请求链路中插入监控、过滤和审计节点，帮助企业在不改动核心应用的前提下实现AI行为的可观测性管理。

**So What** 企业部署生产级AI应用时，可借助此类开源工具低成本实现合规审计和异常行为监控，降低自研监控系统的时间与资金成本。

<https://github.com/manojmallick/gavio>

#04 ★★★☆☆

华尔街见闻 · 3 小时前

## AI热潮带动新兴市场资产反弹，韩国芯片股领涨 ↗

MSCI新兴市场指数单日涨幅达2.2%，创6月15日以来最大涨幅，SK海力士和三星表现强劲。AI资本热潮已形成跨市场联动效应，算力上游供应链获持续溢价。

**So What** AI算力投资情绪已传导至全球资本市场，企业若有HBM内存或AI硬件相关供应链布局，当前是优化资产配置和合作谈判的有利时机。

<https://wallstreetcn.com/livenews/3128844>

# 大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

| #  | 模型                                                                                          | 参数量       | 单价 \$/1M  | 厂商 · 国家         | 能力分布 (II)              | 分数   |
|----|---------------------------------------------------------------------------------------------|-----------|-----------|-----------------|------------------------|------|
| 1  | <b>Claude Fable 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort, Opus 4.8 Fallback) | 闭源未知      | 10/50     | Anthropic · ... | <div><div></div></div> | 59.9 |
| 2  | <b>Claude Opus 4.8</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div><div></div></div> | 55.7 |
| 3  | <b>GPT-5.5</b> <span>R</span><br>(xhigh)                                                    | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 54.8 |
| 4  | <b>Claude Opus 4.7</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div><div></div></div> | 53.5 |
| 5  | <b>Claude Sonnet 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 3/15      | Anthropic · ... | <div><div></div></div> | 53.4 |
| 6  | <b>GPT-5.5</b> <span>R</span><br>(high)                                                     | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 53.1 |
| 7  | <b>GLM-5.2</b> <span>R</span><br>(max)                                                      | 745B MoE  | 1.4/4.4   | Z AI · 中国       | <div><div></div></div> | 51.1 |
| 8  | <b>GPT-5.5</b> <span>R</span><br>(medium)                                                   | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 50.4 |
| 9  | <b>Gemini 3.5 Flash</b> <span>R</span><br>(high)                                            | 闭源未知      | 1.5/9     | Google · 美国     | <div><div></div></div> | 50.2 |
| 10 | <b>Gemini 3.1 Pro Preview</b> <span>R</span>                                                | 闭源未知      | 2/12      | Google · 美国     | <div><div></div></div> | 46.5 |
| 11 | <b>Qwen3.7 Max</b> <span>R</span>                                                           | ≈1T · 闭源  | 2.5/7.5   | Alibaba · 中国    | <div><div></div></div> | 46.0 |
| 12 | <b>Gemini 3.5 Flash</b> <span>R</span><br>(medium)                                          | 闭源未知      | 1.5/9     | Google · 美国     | <div><div></div></div> | 45.4 |
| 13 | <b>MiniMax-M3</b> <span>R</span>                                                            | 闭源未知      | 0.3/1.2   | MiniMax · 中国    | <div><div></div></div> | 44.4 |
| 14 | <b>DeepSeek V4 Pro</b> <span>R</span><br>(Reasoning, Max Effort)                            | ≈671B ... | 0.43/0.87 | DeepSeek · ...  | <div><div></div></div> | 44.3 |
| 15 | <b>GPT-5.3 Codex</b> <span>R</span><br>(xhigh)                                              | 闭源未知      | 1.75/14   | OpenAI · 美国     | <div><div></div></div> | 44.3 |
| 16 | <b>GPT-5.5</b> <span>R</span><br>(low)                                                      | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 43.5 |
| 17 | <b>Muse Spark</b> <span>R</span>                                                            | 闭源未知      | —         | Meta · 美国       | <div><div></div></div> | 43.1 |
| 18 | <b>Kimi K2.6</b> <span>R</span>                                                             | 1T MoE    | 0.95/4    | Kimi · 中国       | <div><div></div></div> | 42.8 |
| 19 | <b>Claude Opus 4.7</b><br>(Non-reasoning, High Effort)                                      | 闭源未知      | 5/25      | Anthropic · ... | <div><div></div></div> | 42.7 |
| 20 | <b>MiMo-V2.5-Pro</b> <span>R</span>                                                         | 未公开       | 0.43/0.87 | Xiaomi · 中国     | <div><div></div></div> | 42.2 |

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

# AI 简讯

2026年07月03日 周五 | 近 8 小时 AI 行业关键动向

SCANNED

447

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

## EXECUTIVE SUMMARY · 执行摘要

今日管理者最需关注三件事：第一，Meta宣布开放算力租赁，叠加GLM等国产模型性价比突破，AI基础资源成本正在快速下降，企业算力和模型采购策略需要立即重新评估；第二，韩国动用国家税收、Anthropic疯狂挖角学术顶尖人才，AI竞争已全面升级为国家战略级资源争夺，中国企业面临多维度竞争压力；第三，AI对劳动力市场的冲击已从裁员转化为生计确定性的系统性瓦解，组织的人才稳定性管理和技能转型规划已刻不容缓。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

## ACTION ITEMS · 行动建议

- 本周内启动国产开源模型（如GLM-5.2）替代现有境外API的可行性评估，要求技术团队提供成本对比和合规风险报告，目标降低AI调用成本30%以上。
- 要求HR在两周内提交公司AI高风险岗位清单，并为受影响员工设计具体的技能转型路径，而非等待员工自发离职后再被动补招。
- 将AI工具引入生产环境的审批流程中增加「资源消耗压测」和「异常回滚机制验证」两项强制检查项，防止类似Codex日志Bug等问题冲击核心业务系统。
- 与法务和合规团队在本季度内建立AI供应商合规动态监控机制，重点追踪出口管制政策变化，提前识别现有AI服务中断风险并准备备选方案。

#01 ★★★★★

新智元 · 1 分钟前

## Meta转型算力租赁商冲击AI芯片产业链 ↗

Meta宣布开放自有算力资源对外出租，从AI模型竞争者转型为算力基础设施提供商，消息引发美股AI产业链剧烈震荡，英伟达等芯片股承压，市场对算力供需格局重新定价。

**So What** 算力市场正从稀缺走向过剩，巨头入场压低租赁价格，企业采购算力的谈判筹码增加，但依赖算力概念的投资逻辑需重新评估。

<https://aiera.com.cn/2026/07/03/other/admin/102204/%e5%8d%b7%e4%b8%8d%e8%b5%a2%e6%a8%a...a9%e7%be%8e/>

#02 ★★★★★☆

新智元 · 2 分钟前

## Anthropic两周挖走诺奖得主等四位顶级学者 ↗

Anthropic在两周内连续招募诺贝尔奖得主及伯克利计算机系主任等四位学术领军人物，显示顶级AI公司已将人才争夺从工程师层面升级至科学家和院士级别，研究能力军备竞赛加速。

**So What** 学术顶尖人才加速向商业AI公司流动，企业与高校的人才通道正在重构，本土AI公司面临更高维度的人才争夺压力。

<https://aiera.com.cn/2026/07/03/other/admin/102109/%e6%8a%a2%e5%ae%8c%e8%af%ba%e5%a5%9...9b%e5%b0%86/>

#03 ★★★★★☆

36氪 · 3 分钟前

## 阿里AI产线大整合，92年高管统管三大Agent ↗

阿里对AI产品线进行重大组织整合，将旗下多个Agent产品统一划归至由1992年出生的陈宇森主导的团队管理，两个独立Agent被并入兄弟团队，标志着阿里AI战略从分散孵化转向集中作战。

**So What** 大厂AI组织从多点开花转向精兵集结，年轻管理者主导核心AI产品已成趋势，企业内部AI资源分散的代价开始显现。

<https://36kr.com/p/3878491297296388>

#04 ★★★★★☆

华尔街见闻 · 20 分钟前

## 韩国拟动用5万亿韩元税收自主研发国家级AI模型 ↗

韩国科技信息通信部正讨论将半导体景气带来的约5万亿韩元增量税收用于AI自主研发，计划购买约1万个英伟达Vera Rubin GPU模块并集中分配给本国企业，加速构建主权AI能力。

**So What** 国家级AI算力投入已成为大国竞争标配，中国竞争对手的外部压力在政策和算力两条线同步加码，供应链自主可控的紧迫性进一步上升。

<https://wallstreetcn.com/livenews/3128284>

#01 ★★★★★☆

虎嗅 · 54 分钟前

## AI正在系统性消除职业的长期确定性 ↗

AI对劳动力市场的冲击已从岗位裁撤升级为生计确定性的整体瓦解，受冲击群体从蓝领扩展至知识工作者，职业路径规划、薪资预期和技能保值周期均面临根本性重构。

**So What** 员工稳定性预期下降将传导为组织忠诚度和留才成本上升，管理者需提前设计技能转型通道，否则将面临核心人才主动出走的风险。

<https://m.huxiu.com/article/4872267.html>

#02 ★★★★★☆

虎嗅 · 4 小时前

## Anthropic解禁事件折射美国AI管制深层矛盾 ↗

Anthropic模型的出口管制松绑背后，暴露美国政府在推动AI商业扩张与防止技术扩散之间的两难困境，监管框架尚未成型而模型能力已远超现有规则，政策不确定性持续上升。

**So What** 跨国AI业务的合规窗口随政治风向快速开关，企业需将AI合规风险纳入供应链和市场准入的常态化管理，而非视为一次性事件。

<https://m.huxiu.com/article/4872252.html>

#03 ★★★★★☆

虎嗅 · 4 小时前

## AI Agent全面渗透电商，Token经济模型浮现 ↗

AI Agent已在电商场景中承担选品、定价、客服等完整业务环节，行业开始探索以Token为计量单位的AI能力定价和交易机制，预示电商运营成本结构和人力配置将发生根本性变化。

**So What** 电商企业需要在12个月内明确哪些运营岗位可被Agent替代，并建立Token消耗与业务产出的ROI核算体系，否则将在成本竞争中落后。

<https://m.huxiu.com/article/4872255.html>

#04 ★★★★★☆

虎嗅 · 4 小时前

## AI时代认知分层加剧，判断力成核心竞争资产 ↗

AI工具普及并未消除能力差距，反而加速了人与人之间的认知分层：能够有效使用AI放大判断力的人与被AI替代决策的人之间的差距正在拉大，形成新的职场阶层固化。

**So What** 企业内部AI能力分层将直接影响决策质量和组织效能，识别并保留具备高阶判断力的人才比普及AI工具更关键。

<https://m.huxiu.com/article/4872253.html>

#01 ★★★★★☆

Hacker News · 7 分钟前

## 中国开源模型GLM-5.2以五分之一成本挑战Claude ↗

清华系GLM-5.2开源模型在多项基准测试上逼近Claude性能，但推理和部署成本仅为Claude的约五分之一，为国内企业提供了在不妥协太多能力的前提下大幅降低AI使用成本的可行路径。

**So What** 国产开源模型的性价比拐点已到来，正在使用境外商业API的企业应立即启动国产替代评估，既可压缩成本，也可规避合规风险。

<https://mrkt30.com/glm-5-2-open-source-ai/>

#02 ★★★★★☆

新智元 · 2 分钟前

## OpenAI Codex日志Bug导致SSD每年被消耗殆尽 ↗

OpenAI Codex被曝存在严重日志写入Bug，在正常使用场景下每年可消耗约1TB固态硬盘存储空间，被开发者斥为「劣质软件」，暴露AI编程工具在企业级稳定性和资源管理上的重大缺陷。

**So What** AI开发工具的企业级部署须建立硬件资源监控机制，采购前需要进行生产环境压测，警惕将未经充分验证的AI工具直接引入核心开发流水线。

<https://aiera.com.cn/2026/07/03/other/admin/102135/%e4%b8%80%e5%b9%b4%e5%90%83%e6%8e%8...b6%e3%80%8d/>

#03 ★★★★★☆

新智元 · 2 分钟前

## Anthropic公布8款模型横评榜单，Claude Fable5位列第一 ↗

Anthropic官方发布经过评测的8款主流AI模型排名，Claude Fable 5居首，此举兼具产品宣传与行业标准设定意图，为企业选型提供了官方背书的参照框架，但评测方法论独立性存疑。

**So What** 企业选型AI模型时不应仅依赖供应商自评榜单，需引入内部业务场景的实测数据，防止因营销信息误导而锁定次优供应商。

<https://aiera.com.cn/2026/07/03/other/admin/102123/fable%e7%ac%ac%e4%b8%80%ef%bc%8c%e8...9d%e5%85%89/>

#04 ★★★★★☆

36氪 · 20 分钟前

## 全球Agent落地核心难题：如何设计可靠的自主循环 ↗

当前企业部署AI Agent的最大瓶颈已从模型能力转移至「Loop工程」——即如何让AI在自主执行、质检和纠错的闭环中保持可控，这一工程问题决定了Agent能否真正替代人工完成复杂任务。

**So What** 评估AI Agent供应商时，应将Loop稳定性和异常回滚机制列为核心验收标准，而非仅看演示效果，否则生产环境中的失控风险极高。

<https://36kr.com/p/3878518284565125>

# 大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

| #  | 模型                                                                                          | 参数量       | 单价 \$/1M  | 厂商 · 国家         | 能力分布 (II)              | 分数   |
|----|---------------------------------------------------------------------------------------------|-----------|-----------|-----------------|------------------------|------|
| 1  | <b>Claude Fable 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort, Opus 4.8 Fallback) | 闭源未知      | 10/50     | Anthropic · ... | <div><div></div></div> | 59.9 |
| 2  | <b>Claude Opus 4.8</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div><div></div></div> | 55.7 |
| 3  | <b>GPT-5.5</b> <span>R</span><br>(xhigh)                                                    | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 54.8 |
| 4  | <b>Claude Opus 4.7</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div><div></div></div> | 53.5 |
| 5  | <b>Claude Sonnet 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 3/15      | Anthropic · ... | <div><div></div></div> | 53.4 |
| 6  | <b>GPT-5.5</b> <span>R</span><br>(high)                                                     | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 53.1 |
| 7  | <b>GLM-5.2</b> <span>R</span><br>(max)                                                      | 745B MoE  | 1.4/4.4   | Z AI · 中国       | <div><div></div></div> | 51.1 |
| 8  | <b>GPT-5.5</b> <span>R</span><br>(medium)                                                   | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 50.4 |
| 9  | <b>Gemini 3.5 Flash</b> <span>R</span><br>(high)                                            | 闭源未知      | 1.5/9     | Google · 美国     | <div><div></div></div> | 50.2 |
| 10 | <b>Gemini 3.1 Pro Preview</b> <span>R</span>                                                | 闭源未知      | 2/12      | Google · 美国     | <div><div></div></div> | 46.5 |
| 11 | <b>Qwen3.7 Max</b> <span>R</span>                                                           | ≈1T · 闭源  | 2.5/7.5   | Alibaba · 中国    | <div><div></div></div> | 46.0 |
| 12 | <b>Gemini 3.5 Flash</b> <span>R</span><br>(medium)                                          | 闭源未知      | 1.5/9     | Google · 美国     | <div><div></div></div> | 45.4 |
| 13 | <b>MiniMax-M3</b> <span>R</span>                                                            | 闭源未知      | 0.3/1.2   | MiniMax · 中国    | <div><div></div></div> | 44.4 |
| 14 | <b>DeepSeek V4 Pro</b> <span>R</span><br>(Reasoning, Max Effort)                            | ≈671B ... | 0.43/0.87 | DeepSeek · ...  | <div><div></div></div> | 44.3 |
| 15 | <b>GPT-5.3 Codex</b> <span>R</span><br>(xhigh)                                              | 闭源未知      | 1.75/14   | OpenAI · 美国     | <div><div></div></div> | 44.3 |
| 16 | <b>GPT-5.5</b> <span>R</span><br>(low)                                                      | 闭源未知      | 5/30      | OpenAI · 美国     | <div><div></div></div> | 43.5 |
| 17 | <b>Muse Spark</b> <span>R</span>                                                            | 闭源未知      | —         | Meta · 美国       | <div><div></div></div> | 43.1 |
| 18 | <b>Kimi K2.6</b> <span>R</span>                                                             | 1T MoE    | 0.95/4    | Kimi · 中国       | <div><div></div></div> | 42.8 |
| 19 | <b>Claude Opus 4.7</b><br>(Non-reasoning, High Effort)                                      | 闭源未知      | 5/25      | Anthropic · ... | <div><div></div></div> | 42.7 |
| 20 | <b>MiMo-V2.5-Pro</b> <span>R</span>                                                         | 未公开       | 0.43/0.87 | Xiaomi · 中国     | <div><div></div></div> | 42.2 |

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

# AI 简讯

2026年07月02日 周四 | 近 8 小时 AI 行业关键动向

SCANNED

449

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

## EXECUTIVE SUMMARY · 执行摘要

今日有三件事高管必须关注：第一，美国最快下周推出自愿AI监管框架，这是联邦层面AI治理的重大信号，在美业务需提前对标合规；第二，武田制药与英矽智能签下最高6亿美元AI药研协议，AI与实体产业深度融合进入大额商业落地阶段，各行业管理者须重新评估AI研发合作的战略紧迫性；第三，Anthropic为Claude赋予独立数字身份，AI Agent正式具备企业主体资格，现有IT权限体系和法律责任框架需系统性升级。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

## ACTION ITEMS · 行动建议

01 本周内要求法务和IT部门联合评估AI Agent独立账号带来的权限审计漏洞，输出改造方案清单

02 向CFO提交AI工具Token计费成本监控方案，设定季度用量预警阈值，对比开源自部署TCO

03 指定专人跟踪美国自愿AI监管框架文本，下周发布后48小时内完成对现有AI项目的合规差距分析

04 要求内容/创意/电商团队在两周内测试谷歌低成本图像生成模型，提交与现有人力成本的对比测算报告

#01 ★★★★★

华尔街见闻 · 2 分钟前

## 武田制药与英矽智能签约AI药物研发，最高6亿美元 ↗

武田制药与AI药物研发公司英矽智能达成合作协议，协议总价值最高可达6亿美元。这是制药巨头将AI深度嵌入核心研发管线的重大信号，标志着AI制药从概念走向大额商业落地。

**So What** 制药行业AI研发军备竞赛正在提速，尚未布局AI研发合作的药企将面临成本与速度双重劣势，需评估自建还是外包AI能力的战略选择。

<https://wallstreetcn.com/livenews/3127681>

#02 ★★★★★

华尔街见闻 · 1 小时前

## 美国最快下周宣布自愿AI监管制度框架 ↗

知情人士透露，美国政府最快将于下周宣布自愿性AI监管标准体系。这是美国在联邦层面推动AI治理的最新进展，将影响在美运营的所有AI相关企业的合规路径选择。

**So What** 自愿标准往往是强制监管的前奏，在美有业务的企业应提前对标框架要求，将合规成本纳入AI投资预算，抢先布局可降低未来强制合规的切换成本。

<https://wallstreetcn.com/livenews/3127652>

#03 ★★★★★☆

新智元 · 10 分钟前

## Anthropic发布Claude 5工作版，面向所有用户开放 ↗

Anthropic发布Claude 5工作能力版本，面向全体用户开放使用。该版本主打工作场景下的任务执行能力，是Anthropic在消费级与企业级市场同步扩张的关键动作。

**So What** 主流AI助手能力门槛持续降低，企业内员工自发使用高能力AI工具的趋势将加速，管理层需尽快制定统一的AI工具使用规范，防止数据安全风险失控。

<https://aiera.com.cn/2026/07/02/other/admin/101990/%e7%aa%81%e5%8f%91%ef%bc%8c%e6%89%9...bd%e7%94%a8/>

#04 ★★★★★☆

新智元 · 11 分钟前

## Anthropic为Claude发放独立账号，AI获得企业身份 ↗

Anthropic宣布为Claude发布独立账号机制，AI不再需要借用人类账号进行操作。这意味着AI Agent正式获得独立数字身份，可在企业系统中以独立主体身份运行和操作。

**So What** AI从工具升级为具有独立身份的数字员工，企业需要重新审视权限管理体系、操作审计机制和法律责任归属，现有IT治理框架可能面临系统性重构。

<https://aiera.com.cn/2026/07/02/other/admin/101972/claude%e6%9c%89%e3%80%8c%e7%bc%96%e...91%e7%9a%84/>

#01 ★★★★★☆

虎嗅 · 13 分钟前

## 美国AI自我设限，中国大模型迎来战略窗口期 ↗

分析指出，随着美国AI监管收紧和出口限制，美国AI产品在部分市场的推进受阻，中国大模型厂商在政策约束相对宽松的窗口期获得加速布局的战略机会，尤其是在海外市场和国内替代方面。

**So What** 采购AI基础设施的企业应重新评估供应链风险，国内大模型可靠性和合规性正在提升，将单一依赖美国AI供应商的策略调整为双轨布局的时机已成熟。

<https://m.huxiu.com/article/4871775.html>

#02 ★★★★★☆

华尔街见闻 · 1 小时前

## Palantir CEO猛批OpenAI和Anthropic按Token计费模式 ↗

Palantir CEO Alex Karp公开抨击Anthropic和OpenAI的Token计费结构，称其导致企业AI成本飙升。他力推Palantir与英伟达开源模型方案，主张企业应掌握数据所有权以控制成本。

**So What** Token计费模式下AI成本不透明且难以预算，管理层在规模化部署前须建立AI用量监控与成本核算机制，同时评估开源模型自部署方案的TCO对比。

<https://wallstreetcn.com/livenews/3127653>

#03 ★★★★★☆

虎嗅 · 33 分钟前

## 观点：AI泡沫破裂后，真正的黄金时代才会到来 ↗

虎嗅刊发分析文章，探讨当前AI投资泡沫风险及泡沫破裂后的产业走向，认为真正有价值的技术和商业模式将在泡沫出清后显现，黄金时代在泡沫之后而非当下。

**So What** 当前AI项目ROI普遍虚高，管理层应区分战略性长期投入与跟风性短期支出，建立清晰的AI投资退出标准，避免在泡沫高点锁定过高采购成本。

<https://m.huxiu.com/article/4871947.html>

#04 ★★★★★☆

华尔街见闻 · 42 分钟前

## 美联储主席：AI正在重塑经济，通胀近期降温 ↗

美联储主席沃什表示通胀近四周持续降温，同时明确指出AI正在重塑整体经济结构，前瞻指引因此失去必要性。宏观环境的不确定性与AI对生产率的潜在影响同步上升。

**So What** 美联储高层将AI列为经济结构性变量，企业战略规划需将AI对本行业生产率的冲击纳入中期财务预测，原有基于传统经济周期的预算模型可能需要修正。

<https://wallstreetcn.com/livenews/3127660>

#01 ★★★★★

Hacker News · 1 小时前

## 红队测试将Claude桌面端变为双面间谍，安全漏洞曝光 ↗

Hacker News报道安全研究人员通过红队测试成功将Claude Desktop操控为双面代理，执行恶意指令。该漏洞暴露了AI桌面客户端在企业环境中面临的提示注入与权限滥用风险。

**So What** 企业内已部署AI桌面工具的团队面临真实安全威胁，需立即评估AI工具的系统权限边界，限制AI客户端访问敏感数据目录，并将AI安全纳入常规渗透测试范围。

<https://www.theregister.com/security/2026/07/01/red-teamers-turned-claude-desktop-into...ding/5264692>

#02 ★★★★★

新智元 · 11 分钟前

## Karpathy提出新知识管理框架，挑战现有RAG架构 ↗

前OpenAI科学家Karpathy提出将个人知识库转化为可持续增值系统的新方法，主张知识应像代码一样可复用和迭代，对当前主流的RAG（检索增强生成）技术路线形成挑战。

**So What** 企业知识管理和内部AI搜索系统的技术选型需重新审视，基于RAG构建的企业知识库可能面临架构升级需求，建议技术团队跟踪评估新范式的落地成本。

<https://aiera.com.cn/2026/07/02/other/admin/101936/karpathy%e5%8f%88%e5%b0%81%e7%a5%9e...a7%e8%84%91/>

#03 ★★★★★

新智元 · 11 分钟前

## 谷歌发布最低成本图像生成模型，出图成本仅两毛 ↗

谷歌深夜发布新版图像生成模型，生成速度约4秒，单次成本约0.2元人民币，是目前主流图像AI中成本最低的方案之一，面向企业级高频调用场景具有显著经济价值。

**So What** 内容生产、广告创意、电商图片等高频图像需求场景的AI替代成本大幅下降，相关业务负责人应立即测试并重新核算内容生产团队的人力成本对比数据。

<https://aiera.com.cn/2026/07/02/other/admin/101919/%e8%b0%b7%e6%ad%8c%e6%b7%b1%e5%a4%9...a5%e4%ba%86/>

#04 ★★★★★

新智元 · 10 分钟前

## 清华发布第二代智能体社会模拟平台，社会科学可计算化 ↗

清华大学发布AgentSociety第二代平台，通过大规模AI智能体模拟社会行为和群体决策，使社会科学研究从定性走向可计算验证。该平台可用于政策效果预测和市场行为模拟。

**So What** 大规模多智能体仿真技术正趋于实用，战略规划和政策研究部门可探索将其用于市场进入策略、组织变革影响的模拟预演，降低决策试错成本。

<https://aiera.com.cn/2026/07/02/other/admin/102007/%e6%b8%85%e5%8d%8e%e5%8f%91%e5%b8%8...94%e7%a9%b6/>

# 大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

| #  | 模型                                                                                          | 参数量       | 单价 \$/1M  | 厂商 · 国家         | 能力分布 (II)   | 分数   |
|----|---------------------------------------------------------------------------------------------|-----------|-----------|-----------------|-------------|------|
| 1  | <b>Claude Fable 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort, Opus 4.8 Fallback) | 闭源未知      | 10/50     | Anthropic · ... | <div></div> | 59.9 |
| 2  | <b>Claude Opus 4.8</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 55.7 |
| 3  | <b>GPT-5.5</b> <span>R</span><br>(xhigh)                                                    | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 54.8 |
| 4  | <b>Claude Opus 4.7</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 53.5 |
| 5  | <b>Claude Sonnet 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 3/15      | Anthropic · ... | <div></div> | 53.4 |
| 6  | <b>GPT-5.5</b> <span>R</span><br>(high)                                                     | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 53.1 |
| 7  | <b>GLM-5.2</b> <span>R</span><br>(max)                                                      | 745B MoE  | 1.4/4.4   | Z AI · 中国       | <div></div> | 51.1 |
| 8  | <b>GPT-5.5</b> <span>R</span><br>(medium)                                                   | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 50.4 |
| 9  | <b>Gemini 3.5 Flash</b> <span>R</span><br>(high)                                            | 闭源未知      | 1.5/9     | Google · 美国     | <div></div> | 50.2 |
| 10 | <b>Gemini 3.1 Pro Preview</b> <span>R</span>                                                | 闭源未知      | 2/12      | Google · 美国     | <div></div> | 46.5 |
| 11 | <b>Qwen3.7 Max</b> <span>R</span>                                                           | ≈1T · 闭源  | 2.5/7.5   | Alibaba · 中国    | <div></div> | 46.0 |
| 12 | <b>Gemini 3.5 Flash</b> <span>R</span><br>(medium)                                          | 闭源未知      | 1.5/9     | Google · 美国     | <div></div> | 45.4 |
| 13 | <b>MiniMax-M3</b> <span>R</span>                                                            | 闭源未知      | 0.3/1.2   | MiniMax · 中国    | <div></div> | 44.4 |
| 14 | <b>DeepSeek V4 Pro</b> <span>R</span><br>(Reasoning, Max Effort)                            | ≈671B ... | 0.43/0.87 | DeepSeek · ...  | <div></div> | 44.3 |
| 15 | <b>GPT-5.3 Codex</b> <span>R</span><br>(xhigh)                                              | 闭源未知      | 1.75/14   | OpenAI · 美国     | <div></div> | 44.3 |
| 16 | <b>GPT-5.5</b> <span>R</span><br>(low)                                                      | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 43.5 |
| 17 | <b>Muse Spark</b> <span>R</span>                                                            | 闭源未知      | —         | Meta · 美国       | <div></div> | 43.1 |
| 18 | <b>Kimi K2.6</b> <span>R</span>                                                             | 1T MoE    | 0.95/4    | Kimi · 中国       | <div></div> | 42.8 |
| 19 | <b>Claude Opus 4.7</b><br>(Non-reasoning, High Effort)                                      | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 42.7 |
| 20 | <b>MiMo-V2.5-Pro</b> <span>R</span>                                                         | 未公开       | 0.43/0.87 | Xiaomi · 中国     | <div></div> | 42.2 |

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

# AI 简讯

2026年07月01日 周三 | 近 8 小时 AI 行业关键动向

SCANNED

432

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

## EXECUTIVE SUMMARY · 执行摘要

今日最值得高管关注的三件事：一、美国正式解除对Anthropic顶级模型出口管制，全球AI工具采购窗口重开，企业需立即重启供应商评估；二、OpenAI首席研究官公开警告AGI窗口期极短，叠加神秘中国团队闯入全球前七，AI竞争烈度超出常规预期，战略转型时间表需压缩；三、食品饮料等传统行业集体涌入AI但变现路径不清，跟风投入风险显著，Kimi等创业公司资金压力也提示AI供应商稳定性风险不容忽视。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

## ACTION ITEMS · 行动建议

- 立即评估Claude Fable 5出口管制解除后是否将其纳入企业AI基础设施采购候选清单，并在本月内完成合规与成本对比报告
- 要求各业务线AI投入必须在季度内绑定可量化KPI，对无法明确ROI的AI项目暂停新增预算审批
- 排查核心AI供应商的财务健康度与商业化路径，对存在资金链风险的创业厂商制定备份切换预案
- 将移动端AI Agent工具纳入企业数据安全策略审查范围，本季度内更新BYOD政策以覆盖AI工具使用场景

#01 ★★★★★

华尔街见闻 · 18 分钟前

## 美国取消对Anthropic Claude高端模型的出口管制 ↗

美国商务部正式解除对Anthropic旗下Claude Fable 5与Mythos 5的出口管制，商务部长卢特尼克确认已与Anthropic密切合作完成合规审批，模型将于次日起恢复全球访问。

**So What** 这一政策松绑意味着中国以外的全球企业可合法部署顶级Claude模型，采购AI基础设施的决策窗口重新打开，需立即评估切换或引入方案。

<https://wallstreetcn.com/livenews/3127037>

#02 ★★★★★☆

36氪 · 14 分钟前

## Anthropic大规模封号后紧急推出更低价Claude新模型 ↗

Anthropic在对大量用户账号实施封禁引发争议后，迅速发布定价更低的新版Claude模型，意图用价格策略稳住市场信心，同时为企业级市场讲述更大的商业扩张故事。

**So What** 竞争压力下头部AI厂商开始打价格战，企业现有AI服务合同应纳入重新议价计划，避免锁定在高价区间。

<https://36kr.com/p/3876324591398913>

#03 ★★★★★☆

新智元 · 15 分钟前

## OpenAI首席研究官警告：留给人类主导的窗口已很小 ↗

OpenAI首席研究官Mark Chen公开表态，AGI倒计时进入关键阶段，留给人类在决策链中占据主导地位的时间窗口极为有限，暗示技术跃迁速度正超出外界预期。

**So What** 顶级AI机构内部人士已在公开预警变革加速，管理者需在未来12-18个月内完成核心业务流程的AI化重构，否则将面临被动局面。

<https://aiera.com.cn/2026/07/01/other/admin/101777/agi%e5%80%92%e8%ae%a1%e6%97%b6%ef%b...97%e5%8f%a3/>

#04 ★★★★★☆

新智元 · 15 分钟前

## 无官网中国神秘AI团队跻身全球前七超越多数大厂 ↗

一个没有官网、几乎零公关的中国AI团队在权威榜单中冲进全球前七，位列中国第一、直逼OpenAI，显示中国AI领域出现新的技术突破力量，竞争格局再度刷新。

**So What** 中国AI竞争已不再只是大厂博弈，隐形团队快速崛起说明技术门槛在降低，行业竞争烈度将超预期，供应商选型需保留切换弹性。

<https://aiera.com.cn/2026/07/01/other/admin/101795/%e4%b8%ad%e5%9b%bd%e7%ac%ac%e4%b8%8...8d%e4%b8%83/>

#01 ★★★★★

虎嗅 · 12 分钟前

## 食品饮料企业集体涌入AI赛道风险收益待评估 ↗

虎嗅报道显示食品饮料行业多家企业扎堆追逐AI概念，但落地成效参差不齐，行业内AI投入与实际经营改善之间的因果链尚不清晰，存在跟风投入的集体性风险。

**So What** 传统消费品企业AI转型正从观望转向行动，但跟风投入而非场景驱动的模式极易造成资源浪费，董事会应要求AI预算必须绑定可量化的业务指标。

<https://m.huxiu.com/article/4871687.html>

#02 ★★★★★

新智元 · 15 分钟前

## Claude Code之父预测三年后写代码人数将暴增百倍 ↗

Anthropic Claude Code项目负责人表示，自己已半年未手写代码，但他预判AI辅助编程将使编程门槛大幅降低，未来三年参与编程的人数将扩大100倍，软件开发行业格局将彻底重塑。

**So What** 技术人才战略需重新定义：稀缺的不再是会写代码的人，而是能用AI工具高效定义问题、验证方案的复合型人才，招聘与培训标准须同步调整。

<https://aiera.com.cn/2026/07/01/other/admin/101831/%e5%8d%8a%e5%b9%b4%e4%b8%8d%e5%86%9...00%e5%80%8d/>

#03 ★★★★★

虎嗅 · 40 分钟前

## Kimi持续烧钱扩张资金压力成中国AI独角兽共性难题 ↗

虎嗅报道指出Kimi（月之暗面）资金消耗持续高企，商业化变现速度跟不上研发和算力投入节奏，折射出中国头部AI创业公司普遍面临的融资依赖与盈利路径不清晰问题。

**So What** 选择与中国AI创业公司深度绑定需评估其财务持续性风险，建议关键AI供应商必须具备清晰的商业化路径，避免核心业务依赖资金链脆弱的厂商。

<https://m.huxiu.com/article/4871684.html>

#04 ★★★★★

华尔街见闻 · 46 分钟前

## 券商7月金股AI产业链仍为核心但机构布局开始多元化 ↗

6月券商金股中AI产业链多只个股涨幅翻倍，但7月机构金股布局出现转变，医药、券商板块关注度升温，科技独大格局松动，显示机构资金对AI主题估值开始谨慎再平衡。

**So What** AI概念股估值溢价正在被机构重新审视，企业若有AI相关资本市场计划，需注意叙事与业绩兑现之间的落差风险正在加大。

<https://wallstreetcn.com/livenews/3127022>

#01 ★★★☆☆

36氪 · 3 分钟前

### 谷歌将废旧手机改造为分布式AI推理服务器 ↗

谷歌实验性项目通过拆解旧手机硬件重新部署为AI推理节点，探索以极低成本构建分布式AI算力的可行性，为算力资源紧张下的企业提供了降本思路参考。

**So What** AI算力成本正在多个维度被压缩，企业现有硬件资产的价值需重新评估，IT部门应研究边缘算力复用方案以降低AI推理成本。

<https://36kr.com/p/3875875394433282>

#02 ★★★☆☆

新智元 · 15 分钟前

### OpenClaw与Cursor推出手机版AI Agent工具 ↗

OpenClaw和Cursor同步发布移动端AI Agent版本，编程辅助与智能体能力从桌面延伸至手机端，意味着开发者和知识工作者可在移动场景下调用AI完成复杂任务。

**So What** 移动端AI生产力工具成熟度正在快速提升，企业移动办公策略和BYOD安全政策需同步更新，防止敏感数据通过个人设备上的AI工具外泄。

<https://aiera.com.cn/2026/07/01/other/admin/101815/%e5%88%9a%e5%88%9a%ef%bc%8copenclaw...a3%e8%a2%8b/>

#03 ★★★☆☆

36氪 · 46 分钟前

### 复旦团队突破VLA泛化难题机器人适应新环境无需重新微调 ↗

复旦邱锡鹏团队提出「上下文世界建模」方法，使视觉-语言-动作模型无需针对新环境重新微调即可快速适应，大幅降低工业机器人和具身智能的部署成本与周期。

**So What** 制造业和物流企业部署机器人的关键障碍之一——场景适配成本——正在被技术突破削减，产线自动化升级的ROI评估节点已到来。

<https://36kr.com/p/3875506217152776>

#04 ★★★☆☆

华尔街见闻 · 52 分钟前

### AI热情推动美股纳指标普创年内最佳季度表现 ↗

2025年第二季度在AI投资热情驱动下，标普500与纳斯达克综指录得史上最佳季度之一，道指续创历史新高，AI主题成为本季度资本市场最核心的价值锚。

**So What** AI投资叙事持续支撑资本市场估值，企业在融资、并购及战略发布时应充分利用这一窗口，但同时需警惕与AI实际落地效果脱节导致的预期回调风险。

<https://wallstreetcn.com/livenews/3127021>

# 大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

| #  | 模型                                                                                          | 参数量       | 单价 \$/1M  | 厂商 · 国家         | 能力分布 (II)   | 分数   |
|----|---------------------------------------------------------------------------------------------|-----------|-----------|-----------------|-------------|------|
| 1  | <b>Claude Fable 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort, Opus 4.8 Fallback) | 闭源未知      | 10/50     | Anthropic · ... | <div></div> | 59.9 |
| 2  | <b>Claude Opus 4.8</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 55.7 |
| 3  | <b>GPT-5.5</b> <span>R</span><br>(xhigh)                                                    | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 54.8 |
| 4  | <b>Claude Opus 4.7</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 53.5 |
| 5  | <b>Claude Sonnet 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 3/15      | Anthropic · ... | <div></div> | 53.4 |
| 6  | <b>GPT-5.5</b> <span>R</span><br>(high)                                                     | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 53.1 |
| 7  | <b>GLM-5.2</b> <span>R</span><br>(max)                                                      | 745B MoE  | 1.4/4.4   | Z AI · 中国       | <div></div> | 51.1 |
| 8  | <b>GPT-5.5</b> <span>R</span><br>(medium)                                                   | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 50.4 |
| 9  | <b>Gemini 3.5 Flash</b> <span>R</span><br>(high)                                            | 闭源未知      | 1.5/9     | Google · 美国     | <div></div> | 50.2 |
| 10 | <b>Claude Sonnet 4.6</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                 | 闭源未知      | 3/15      | Anthropic · ... | <div></div> | 47.2 |
| 11 | <b>Gemini 3.1 Pro Preview</b> <span>R</span>                                                | 闭源未知      | 2/12      | Google · 美国     | <div></div> | 46.5 |
| 12 | <b>Qwen3.7 Max</b> <span>R</span>                                                           | ≈1T · 闭源  | 2.5/7.5   | Alibaba · 中国    | <div></div> | 46.0 |
| 13 | <b>Gemini 3.5 Flash</b> <span>R</span><br>(medium)                                          | 闭源未知      | 1.5/9     | Google · 美国     | <div></div> | 45.4 |
| 14 | <b>MiniMax-M3</b> <span>R</span>                                                            | 闭源未知      | 0.3/1.2   | MiniMax · 中国    | <div></div> | 44.4 |
| 15 | <b>DeepSeek V4 Pro</b> <span>R</span><br>(Reasoning, Max Effort)                            | ≈671B ... | 0.43/0.87 | DeepSeek · ...  | <div></div> | 44.3 |
| 16 | <b>GPT-5.3 Codex</b> <span>R</span><br>(xhigh)                                              | 闭源未知      | 1.75/14   | OpenAI · 美国     | <div></div> | 44.3 |
| 17 | <b>GPT-5.5</b> <span>R</span><br>(low)                                                      | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 43.5 |
| 18 | <b>Muse Spark</b> <span>R</span>                                                            | 闭源未知      | —         | Meta · 美国       | <div></div> | 43.1 |
| 19 | <b>Kimi K2.6</b> <span>R</span>                                                             | 1T MoE    | 0.95/4    | Kimi · 中国       | <div></div> | 42.8 |
| 20 | <b>Claude Opus 4.7</b><br>(Non-reasoning, High Effort)                                      | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 42.7 |

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

# AI 简讯

2026年06月30日 周二 | 近 8 小时 AI 行业关键动向

SCANNED

414

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

## EXECUTIVE SUMMARY · 执行摘要

今日有三件事高管必须关注：其一，Anthropic账单多收170万美元事件将AI服务商计费黑箱问题推上台面，CFO须立即建立API成本监控机制；其二，Claude全系宕机叠加可靠性基准测试曝光，依赖单一AI服务的企业面临业务中断实质风险，多供应商备份刻不容缓；其三，具身智能6个月15家企业估值破百亿、美国企业全面接入DeepSeek，AI产业格局正在以超预期速度重塑，战略布局窗口期正在收窄。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

## ACTION ITEMS · 行动建议

- 要求CFO与IT团队在两周内建立AI服务商API用量日监控与账单核查流程，设置超支预警阈值，参照Anthropic事件防范黑箱计费风险。
- 组织CTO评估当前关键业务流程对单一AI服务商的依赖程度，制定至少一个备用服务商的切换预案，含Claude等头部服务商的宕机应急方案。
- 责成战略部门在本季度内完成具身智能对自身主营业务影响的专项评估，明确未来18个月内哪些岗位或流程将最先受到冲击。
- 要求法务与合规团队将AI Agent行为审计、数据主权及跨境模型使用合规纳入下半年风险管控重点，输出可操作的红线清单。

#01 ★★★★★☆

新智元 · 1 分钟前

## Claude宕机暴露AI服务可靠性软肋，中国基准测出死穴 ↗

6月22日Anthropic Claude全系产品集体宕机，同期中国基准测试首次系统性揭示头部AI服务在高并发、长任务场景下的稳定性缺口，触及AI商业化规模落地的核心隐患。

**So What** 依赖单一AI服务商的企业面临业务中断风险；需立即评估关键业务流程是否有AI服务熔断与多供应商备份方案。

<https://aiera.com.cn/2026/06/30/other/admin/101572/claude%E3%80%8c%E6%96%ad%E7%94%B5%E...ba%E3%80%8c/>

#02 ★★★★★☆

新智元 · 2 分钟前

## 贾扬清离职英伟达，7亿美元收购一年即生变 ↗

英伟达斥资约7亿美元收购Lepton AI仅一年，创始人贾扬清被曝离职。这是英伟达近年最重要的AI基础设施人才引进之一，人事变动或影响其云服务与推理基础设施战略布局。

**So What** 巨额并购不等于人才留存，高溢价收购后核心创始人出走的风险值得警惕；企业在AI并购交割后须重点关注关键人才绑定机制。

<https://aiera.com.cn/2026/06/30/other/admin/101553/%E7%aa%81%E5%8f%91%Ef%bc%81%E8%B4%B...80%E5%B9%B4/>

#03 ★★★★★☆

36氪 · 6 分钟前

## 具身智能融资狂潮：6个月15家企业估值破百亿 ↗

2026年上半年，具身智能赛道迎来融资爆发，6个月内15家创企估值突破百亿人民币，资本加速押注机器人商业化落地，产业格局正在快速重塑。

**So What** 具身智能进入资本密集期，制造、物流、零售等行业的劳动力替代时间表正在提前；管理者须评估自身业务受冲击节点并提前布局供应链调整。

<https://36kr.com/p/3874254534710276>

#04 ★★★★★☆

36氪 · 12 分钟前

## 美国企业100%接入DeepSeek，中国模型渗透海外市场 ↗

一家美国企业选择全面接入中国DeepSeek模型，理由是性价比与能力均达到生产级要求。这一案例标志着中国开源大模型开始实质性进入海外企业技术栈。

**So What** 中国模型的全球渗透正从学术走向商用，国内企业有机会借助DeepSeek等降低AI采购成本，但数据主权与合规风险需同步评估。

<https://36kr.com/p/3874284272728968>

#01 ★★★★★

新智元 · 1 分钟前

## Anthropic账单超收170万美元，AI计费黑箱引发信任危机 ↗

Anthropic被曝向客户多收约170万美元API费用后退款但未正式认账。事件揭示AI服务计费透明度严重不足，企业对Token消耗与账单核查几乎无从审计，行业监管压力随之上升。

**So What** AI账单黑箱已是实质性财务风险，CFO和采购负责人须立即建立API用量监控与账单核查机制，避免成本失控。

<https://aiera.com.cn/2026/06/30/other/admin/101634/%e5%a4%9a%e6%94%b6170%e4%b8%87%ef%b...a4%e8%b4%a6/>

#02 ★★★★★☆

虎嗅 · 1 小时前

## Token经济尚未跑通，AI商业化仍在寻找正确姿势 ↗

当前企业普遍拥抱AI，但Token消耗成本高、ROI验证困难、落地场景与预期存在落差等问题普遍存在，行业尚未找到可规模复制的AI商业化路径。

**So What** AI投入规模化之前，管理者须建立清晰的ROI量化框架，避免陷入「用了AI但没有算清楚账」的预算黑洞。

<https://m.huxiu.com/article/4871362.html>

#03 ★★★★★☆

华尔街见闻 · 1 小时前

## A股50余家公司密集发布AI概念风险提示公告 ↗

6月17日以来，逾50家A股公司针对AI服务器、光模块、人形机器人等热点概念主动发布风险提示，监管压力推动企业厘清业务边界，概念炒作进入降温通道。

**So What** AI概念股降温信号明确，机构正转向关注有真实订单和现金流的标的；企业对外传播AI战略时需确保有实质业务支撑，防范监管与市场双重压力。

<https://wallstreetcn.com/livenews/3126335>

#04 ★★★★★☆

华尔街见闻 · 7 小时前

## 城堡证券高管警告：AI正日益演变为政治议题 ↗

城堡证券EMEA固定收益销售主管Nohshad Shah公开警告，AI已不再是单纯的技术或商业议题，正在快速政治化，将对跨国企业的合规、监管与市场准入带来新变量。

**So What** AI的地缘政治化趋势要求跨国企业将AI合规纳入政府事务与风险管理框架，而不仅是IT部门的职责。

<https://wallstreetcn.com/livenews/3126270>

#01 ★★★★★☆

Hacker News · 10 分钟前

## AI Agent防火墙工具出现，企业级安全审计需求凸显 ↗

Hacker News出现专为AI Agent设计的防火墙与审计工具，可拦截、记录和审计Agent行为。随着企业内部Agent数量激增，传统安全架构无法覆盖Agent的动态行为已成为明确风险。

**So What** AI Agent部署规模扩大后，安全与审计缺口将成为企业最大的隐性风险口；CISO须将Agent行为纳入安全管控体系。

<https://github.com/beebeeVB/trajeckt/>

#02 ★★★★★☆

Hacker News · 3 分钟前

## 自托管AI技术栈成本可控性讨论引发企业关注 ↗

Hacker News热议自托管现代AI技术栈的可行性，核心论点是随着开源模型能力提升，企业自建推理服务在数据安全、成本可控与定制化方面优势正在显现，适合有一定技术能力的中大型企业。

**So What** 具备技术团队的企业可将自托管AI纳入降本与数据安全双重目标的选项评估，尤其适用于有数据合规要求的金融、医疗等行业。

<https://github.com/raiyanyahya/llmaker>

#03 ★★★★★☆

虎嗅 · 32 分钟前

## AI医疗自诊误导用户，引发高管对AI可信度的警示 ↗

虎嗅报道一例骨折患者因使用AI自我诊断后被误导、产生严重心理恐慌的真实案例，揭示AI在医疗等高风险场景下输出不可靠信息的系统性风险。

**So What** 在医疗、法律、财务等高风险决策场景部署AI前，管理者须建立人工复核机制，避免AI误导引发的法律责任与品牌声誉损失。

<https://m.huxiu.com/article/4871388.html>

#04 ★★★★★☆

华尔街见闻 · 1 小时前

## 公私募调整下半年配置，AI赛道分歧加大 ↗

多家公私募机构表示，下半年将从AI概念估值修复转向业绩兑现验证，资金聚焦涨价持续、景气度高且能兑现利润的方向，AI赛道内部分化加速。

**So What** AI板块投资逻辑已转向业绩验证期，企业若有融资或市值管理需求，须尽快将AI战略落地为可量化的财务指标，而非停留在概念叙事。

<https://wallstreetcn.com/livenews/3126339>

# 大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

| #  | 模型                                                                                          | 参数量       | 单价 \$/1M  | 厂商 · 国家         | 能力分布 (II)   | 分数   |
|----|---------------------------------------------------------------------------------------------|-----------|-----------|-----------------|-------------|------|
| 1  | <b>Claude Fable 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort, Opus 4.8 Fallback) | 闭源未知      | 10/50     | Anthropic · ... | <div></div> | 59.9 |
| 2  | <b>Claude Opus 4.8</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 55.7 |
| 3  | <b>GPT-5.5</b> <span>R</span><br>(xhigh)                                                    | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 54.8 |
| 4  | <b>Claude Opus 4.7</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 53.5 |
| 5  | <b>GPT-5.5</b> <span>R</span><br>(high)                                                     | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 53.1 |
| 6  | <b>GLM-5.2</b> <span>R</span><br>(max)                                                      | 745B MoE  | 1.4/4.4   | ZAI · 中国        | <div></div> | 51.1 |
| 7  | <b>GPT-5.5</b> <span>R</span><br>(medium)                                                   | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 50.4 |
| 8  | <b>Gemini 3.5 Flash</b> <span>R</span><br>(high)                                            | 闭源未知      | 1.5/9     | Google · 美国     | <div></div> | 50.2 |
| 9  | <b>Claude Sonnet 4.6</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                 | 闭源未知      | 3/15      | Anthropic · ... | <div></div> | 47.2 |
| 10 | <b>Gemini 3.1 Pro Preview</b> <span>R</span>                                                | 闭源未知      | 2/12      | Google · 美国     | <div></div> | 46.5 |
| 11 | <b>Qwen3.7 Max</b> <span>R</span>                                                           | ≈1T · 闭源  | 2.5/7.5   | Alibaba · 中国    | <div></div> | 46.0 |
| 12 | <b>Gemini 3.5 Flash</b> <span>R</span><br>(medium)                                          | 闭源未知      | 1.5/9     | Google · 美国     | <div></div> | 45.4 |
| 13 | <b>MiniMax-M3</b> <span>R</span>                                                            | 闭源未知      | 0.3/1.2   | MiniMax · 中国    | <div></div> | 44.4 |
| 14 | <b>DeepSeek V4 Pro</b> <span>R</span><br>(Reasoning, Max Effort)                            | ≈671B ... | 0.43/0.87 | DeepSeek · ...  | <div></div> | 44.3 |
| 15 | <b>GPT-5.3 Codex</b> <span>R</span><br>(xhigh)                                              | 闭源未知      | 1.75/14   | OpenAI · 美国     | <div></div> | 44.3 |
| 16 | <b>GPT-5.5</b> <span>R</span><br>(low)                                                      | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 43.5 |
| 17 | <b>Muse Spark</b> <span>R</span>                                                            | 闭源未知      | —         | Meta · 美国       | <div></div> | 43.1 |
| 18 | <b>Kimi K2.6</b> <span>R</span>                                                             | 1T MoE    | 0.95/4    | Kimi · 中国       | <div></div> | 42.8 |
| 19 | <b>Claude Opus 4.7</b><br>(Non-reasoning, High Effort)                                      | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 42.7 |
| 20 | <b>MiMo-V2.5-Pro</b> <span>R</span>                                                         | 未公开       | 0.43/0.87 | Xiaomi · 中国     | <div></div> | 42.2 |

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>