

AI 简讯

2026年07月04日 周六 | 近 8 小时 AI 行业关键动向

SCANNED

416

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日有三件事值得高管重点关注：第一，阿里强制禁用Claude的安全事件，表明AI编程工具的供应链安全已成企业级紧迫议题，任何组织都需立即审查在用AI工具的数据安全风险；第二，Anthropic启动自研芯片并向三星洽谈2nm合作，标志着AI竞争全面从模型层延伸至硬件层，算力自主化将重塑行业格局；第三，欧洲监管机构密集发声，将AI纳入系统性风险框架，对金融及跨国企业的合规压力将在未来12个月内显著上升。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

- 本周内组织IT与法务团队，对企业现用AI编程工具（含Claude Code、Copilot等）进行数据流向和权限审查，建立AI工具准入白名单
- 在下季度战略会议中将AI算力采购策略列为专项议题，评估现有英伟达依赖度并启动推理专用芯片供应商调研
- 要求法务团队于30天内完成欧盟及英国AI监管新动态梳理，识别现有业务中高风险合规敞口并制定整改优先级
- 将AI风险作为独立议题纳入下次董事会风险报告，明确责任人和季度审查机制，而非继续归并在IT安全类目下

#01 ★★★★★

新智元 · 31 分钟前

Anthropic启动自研芯片计划，挖角OpenAI老兵密谈三星2nm ↗

Anthropic被曝正推进自研AI芯片，已从OpenAI挖角核心人才，并与三星就2nm制程展开密谈。继谷歌、Meta、亚马逊之后，主流AI实验室正全面向算力自主化布局。

So What AI算力竞争从模型层延伸至芯片层，算力自主化将重塑供应链话语权，依赖英伟达单一供应商的企业需评估长期采购风险。

<https://aiara.com.cn/2026/07/04/other/admin/102310/anthropic%e8%a2%ab%e6%9b%9d%e9%80%a...e6%98%9f2nm/>

#02 ★★★★★

新智元 · 30 分钟前

Claude Code企业级功能向20美元订阅用户全面开放

Anthropic将原本仅面向大型企业团队的Claude Code高级功能下放至20美元/月Pro用户，两周内完成从企业专属到大众普及的跨越，大幅降低AI编程能力的使用门槛。

So What 高端AI能力平民化提速，企业在AI工具上的差异化壁垒快速消失，需重新评估自身AI工具策略和团队技能建设优先级。

<https://aiera.com.cn/2026/07/04/other/admin/102369/%e5%88%9a%e5%88%9a%ef%bc%8cclaude-c...b7%ef%bc%81/>

#03 ★★★★★

虎嗅 · 3 小时前

Meta内部出现算力过剩质疑，扎克伯格与AI负责人表述矛盾

扎克伯格公开表示AI进展慢于预期，但Meta AI负责人称新模型已追上GPT-5.5。内部信号矛盾叠加算力过剩疑云，折射出超大规模AI投入与实际落地之间的落差张力。

So What 巨头内部出现AI投入与产出错配信号，提示企业在制定AI算力投入计划时应设置阶段性ROI验证节点，避免盲目跟投。

<https://m.huxiu.com/article/4872592.html>

#04 ★★★★★

华尔街见闻 · 7 小时前

加拿大养老基金向EQT投入17.5亿美元押注AI基础设施 ↗

CPP Investments宣布向EQT旗下EdgeConneX投资17.5亿美元，用于未来数年AI基础设施开发。机构长线资金持续加码AI算力底座，数据中心建设竞赛进入新阶段。

So What 主权级长线资金入场AI基础设施，意味着该赛道已进入确定性配置阶段，相关产业链企业可借势融资或寻求战略合作机会。

<https://wallstreetcn.com/livenews/3128806>

#01 ★★★★★

华尔街见闻 · 4 小时前

欧洲顶级监管机构警告：AI发展速度已超越现行金融规则 ↗

英国FCA等欧洲监管机构明确表示，现行金融法规已难以跟上AI发展节奏，自主AI（Agentic AI）的普及正对市场诚信与系统稳定性构成新威胁，监管框架急需重构。

So What 金融行业AI合规窗口期正在收窄，在欧洲有业务的金融机构须立即启动AI使用合规审计，抢在新规落地前完成内部治理框架搭建。

<https://wallstreetcn.com/livenews/3128832>

#02 ★★★★★☆

虎嗅 · 3 小时前

推理专用芯片崛起，GPU垄断算力格局面临重构 ↗

推理芯片的快速成熟正在冲击英伟达GPU在AI算力领域的主导地位，专用推理硬件在成本和效率上的优势日益凸显，算力市场多极化格局加速形成。

So What 企业AI算力采购策略需要重新评估，推理阶段引入专用芯片可显著降低单次推理成本，现在是在与多家芯片供应商建立关系的战略窗口。

<https://m.huxiu.com/article/4872597.html>

#03 ★★★★★☆

华尔街见闻 · 5 小时前

特朗普前AI顾问明确：美国不会设立类FDA式AI监管机构 ↗

前白宫AI顾问Sriram Krishnan表示，特朗普政府不会建立正式AI许可制度，但白宫已动用行政权力暂缓部分顶尖大模型发布，监管路径呈现选择性干预而非系统立法特征。

So What 美国AI监管将维持碎片化、行政干预式路径，企业需应对政策不确定性，重点防范特定模型或应用场景遭行政叫停的运营风险。

<https://wallstreetcn.com/livenews/3128826>

#04 ★★★★★☆

华尔街见闻 · 4 小时前

欧洲央行拉加德：AI带来生产力红利同时构成重大系统性风险 ↗

欧洲央行行长拉加德指出AI是生产力和收益来源，但同时警告AI加速演进带来的风险远超过去十年的网络安全威胁，现有防御手段和资金投入均严重不足。

So What 央行级监管者将AI风险提升至系统性高度，企业董事会需将AI风险纳入整体风险管理框架，而非仅作为IT安全议题处理。

<https://wallstreetcn.com/livenews/3128834>

#01 ★★★★★

新智元 · 31 分钟前

阿里全面禁用Claude，7月10日起强制卸载疑存后门 ↗

阿里巴巴被曝于7月10日起全面禁止员工使用Claude，并要求卸载相关工具，起因是Claude Code被发现疑似暗藏后门及隐蔽标记机制，引发企业级数据安全高度警觉。

So What 大型企业AI工具安全审查已成刚需，管理者应立即核查现有AI编程工具的数据流向和权限范围，制定明确的AI工具准入白名单制度。

<https://aiera.com.cn/2026/07/04/other/admin/102276/%e7%aa%81%e5%8f%91%ef%bc%81%e9%98%b8%e8%bd%bd/>

#02 ★★★☆☆

Hacker News · 27 分钟前

新工具可通过Git提交记录检测代码库中的AI生成内容 ↗

Repo-Slopscore工具通过分析Git提交历史中的特征模式，识别代码库中AI生成内容的比例，为企业评估代码质量和开发者行为提供新的可量化手段。

So What 技术管理者现在可量化团队AI代码使用情况，建议将此类检测纳入代码审查流程，用于评估AI辅助编程的质量风险而非作为惩罚工具。

<https://slopscan.ava.pet/>

#03 ★★★☆☆

Hacker News · 28 分钟前

开源LLM拦截管道工具上线，支持生产环境AI应用监控 ↗

Gavio是面向生产环境LLM应用的开源拦截器管道工具，可在AI请求链路中插入监控、过滤和审计节点，帮助企业在不改动核心应用的前提下实现AI行为的可观测性管理。

So What 企业部署生产级AI应用时，可借助此类开源工具低成本实现合规审计和异常行为监控，降低自研监控系统的时间与资金成本。

<https://github.com/manojmallick/gavio>

#04 ★★★☆☆

华尔街见闻 · 3 小时前

AI热潮带动新兴市场资产反弹，韩国芯片股领涨 ↗

MSCI新兴市场指数单日涨幅达2.2%，创6月15日以来最大涨幅，SK海力士和三星表现强劲。AI资本热潮已形成跨市场联动效应，算力上游供应链获持续溢价。

So What AI算力投资情绪已传导至全球资本市场，企业若有HBM内存或AI硬件相关供应链布局，当前是优化资产配置和合作谈判的有利时机。

<https://wallstreetcn.com/livenews/3128844>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年07月03日 周五 | 近 8 小时 AI 行业关键动向

SCANNED

447

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日管理者最需关注三件事：第一，Meta宣布开放算力租赁，叠加GLM等国产模型性价比突破，AI基础资源成本正在快速下降，企业算力和模型采购策略需要立即重新评估；第二，韩国动用国家税收、Anthropic疯狂挖角学术顶尖人才，AI竞争已全面升级为国家战略级资源争夺，中国企业面临多维度竞争压力；第三，AI对劳动力市场的冲击已从裁员转化为生计确定性的系统性瓦解，组织的人才稳定性管理和技能转型规划已刻不容缓。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

- 本周内启动国产开源模型（如GLM-5.2）替代现有境外API的可行性评估，要求技术团队提供成本对比和合规风险报告，目标降低AI调用成本30%以上。
- 要求HR在两周内提交公司AI高风险岗位清单，并为受影响员工设计具体的技能转型路径，而非等待员工自发离职后再被动补招。
- 将AI工具引入生产环境的审批流程中增加「资源消耗压测」和「异常回滚机制验证」两项强制检查项，防止类似Codex日志Bug等问题冲击核心业务系统。
- 与法务和合规团队在本季度内建立AI供应商合规动态监控机制，重点追踪出口管制政策变化，提前识别现有AI服务中断风险并准备备选方案。

#01 ★★★★★

新智元 · 1 分钟前

Meta转型算力租赁商冲击AI芯片产业链 ↗

Meta宣布开放自有算力资源对外出租，从AI模型竞争者转型为算力基础设施提供商，消息引发美股AI产业链剧烈震荡，英伟达等芯片股承压，市场对算力供需格局重新定价。

So What 算力市场正从稀缺走向过剩，巨头入场压低租赁价格，企业采购算力的谈判筹码增加，但依赖算力概念的投资逻辑需重新评估。

<https://aiera.com.cn/2026/07/03/other/admin/102204/%e5%8d%b7%e4%b8%8d%e8%b5%a2%e6%a8%a...a9%e7%be%8e/>

#02 ★★★★★☆

新智元 · 2 分钟前

Anthropic两周挖走诺奖得主等四位顶级学者 ↗

Anthropic在两周内连续招募诺贝尔奖得主及伯克利计算机系主任等四位学术领军人物，显示顶级AI公司已将人才争夺从工程师层面升级至科学家和院士级别，研究能力军备竞赛加速。

So What 学术顶尖人才加速向商业AI公司流动，企业与高校的人才通道正在重构，本土AI公司面临更高维度的人才争夺压力。

<https://aiera.com.cn/2026/07/03/other/admin/102109/%e6%8a%a2%e5%ae%8c%e8%af%ba%e5%a5%9...9b%e5%b0%86/>

#03 ★★★★★☆

36氪 · 3 分钟前

阿里AI产线大整合，92年高管统管三大Agent ↗

阿里对AI产品线进行重大组织整合，将旗下多个Agent产品统一划归至由1992年出生的陈宇森主导的团队管理，两个独立Agent被并入兄弟团队，标志着阿里AI战略从分散孵化转向集中作战。

So What 大厂AI组织从多点开花转向精兵集结，年轻管理者主导核心AI产品已成趋势，企业内部AI资源分散的代价开始显现。

<https://36kr.com/p/3878491297296388>

#04 ★★★★★☆

华尔街见闻 · 20 分钟前

韩国拟动用5万亿韩元税收自主研发国家级AI模型 ↗

韩国科技信息通信部正讨论将半导体景气带来的约5万亿韩元增量税收用于AI自主研发，计划购买约1万个英伟达Vera Rubin GPU模块并集中分配给本国企业，加速构建主权AI能力。

So What 国家级AI算力投入已成为大国竞争标配，中国竞争对手的外部压力在政策和算力两条线同步加码，供应链自主可控的紧迫性进一步上升。

<https://wallstreetcn.com/livenews/3128284>

#01 ★★★★★☆

虎嗅 · 54 分钟前

AI正在系统性消除职业的长期确定性 ↗

AI对劳动力市场的冲击已从岗位裁撤升级为生计确定性的整体瓦解，受冲击群体从蓝领扩展至知识工作者，职业路径规划、薪资预期和技能保值周期均面临根本性重构。

So What 员工稳定性预期下降将传导为组织忠诚度和留才成本上升，管理者需提前设计技能转型通道，否则将面临核心人才主动出走的风险。

<https://m.huxiu.com/article/4872267.html>

#02 ★★★★★☆

虎嗅 · 4 小时前

Anthropic解禁事件折射美国AI管制深层矛盾 ↗

Anthropic模型的出口管制松绑背后，暴露美国政府在推动AI商业扩张与防止技术扩散之间的两难困境，监管框架尚未成型而模型能力已远超现有规则，政策不确定性持续上升。

So What 跨国AI业务的合规窗口随政治风向快速开关，企业需将AI合规风险纳入供应链和市场准入的常态化管理，而非视为一次性事件。

<https://m.huxiu.com/article/4872252.html>

#03 ★★★★★☆

虎嗅 · 4 小时前

AI Agent全面渗透电商，Token经济模型浮现 ↗

AI Agent已在电商场景中承担选品、定价、客服等完整业务环节，行业开始探索以Token为计量单位的AI能力定价和交易机制，预示电商运营成本结构和人力配置将发生根本性变化。

So What 电商企业需要在12个月内明确哪些运营岗位可被Agent替代，并建立Token消耗与业务产出的ROI核算体系，否则将在成本竞争中落后。

<https://m.huxiu.com/article/4872255.html>

#04 ★★★★★☆

虎嗅 · 4 小时前

AI时代认知分层加剧，判断力成核心竞争资产 ↗

AI工具普及并未消除能力差距，反而加速了人与人之间的认知分层：能够有效使用AI放大判断力的人与被AI替代决策的人之间的差距正在拉大，形成新的职场阶层固化。

So What 企业内部AI能力分层将直接影响决策质量和组织效能，识别并保留具备高阶判断力的人才比普及AI工具更关键。

<https://m.huxiu.com/article/4872253.html>

#01 ★★★★★☆

Hacker News · 7 分钟前

中国开源模型GLM-5.2以五分之一成本挑战Claude ↗

清华系GLM-5.2开源模型在多项基准测试上逼近Claude性能，但推理和部署成本仅为Claude的约五分之一，为国内企业提供了在不妥协太多能力的前提下大幅降低AI使用成本的可行路径。

So What 国产开源模型的性价比拐点已到来，正在使用境外商业API的企业应立即启动国产替代评估，既可压缩成本，也可规避合规风险。

<https://mrkt30.com/glm-5-2-open-source-ai/>

#02 ★★★★★☆

新智元 · 2 分钟前

OpenAI Codex日志Bug导致SSD每年被消耗殆尽 ↗

OpenAI Codex被曝存在严重日志写入Bug，在正常使用场景下每年可消耗约1TB固态硬盘存储空间，被开发者斥为「劣质软件」，暴露AI编程工具在企业级稳定性和资源管理上的重大缺陷。

So What AI开发工具的企业级部署须建立硬件资源监控机制，采购前需要进行生产环境压测，警惕将未经充分验证的AI工具直接引入核心开发流水线。

<https://aiera.com.cn/2026/07/03/other/admin/102135/%e4%b8%80%e5%b9%b4%e5%90%83%e6%8e%8...b6%e3%80%8d/>

#03 ★★★★★☆

新智元 · 2 分钟前

Anthropic公布8款模型横评榜单，Claude Fable5位列第一 ↗

Anthropic官方发布经过评测的8款主流AI模型排名，Claude Fable 5居首，此举兼具产品宣传与行业标准设定意图，为企业选型提供了官方背书的参照框架，但评测方法论独立性存疑。

So What 企业选型AI模型时不应仅依赖供应商自评榜单，需引入内部业务场景的实测数据，防止因营销信息误导而锁定次优供应商。

<https://aiera.com.cn/2026/07/03/other/admin/102123/fable%e7%ac%ac%e4%b8%80%ef%bc%8c%e8...9d%e5%85%89/>

#04 ★★★★★☆

36氪 · 20 分钟前

全球Agent落地核心难题：如何设计可靠的自主循环 ↗

当前企业部署AI Agent的最大瓶颈已从模型能力转移至「Loop工程」——即如何让AI在自主执行、质检和纠错的闭环中保持可控，这一工程问题决定了Agent能否真正替代人工完成复杂任务。

So What 评估AI Agent供应商时，应将Loop稳定性和异常回滚机制列为核心验收标准，而非仅看演示效果，否则生产环境中的失控风险极高。

<https://36kr.com/p/3878518284565125>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年07月02日 周四 | 近 8 小时 AI 行业关键动向

SCANNED

449

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日有三件事高管必须关注：第一，美国最快下周推出自愿AI监管框架，这是联邦层面AI治理的重大信号，在美业务需提前对标合规；第二，武田制药与英矽智能签下最高6亿美元AI药研协议，AI与实体产业深度融合进入大额商业落地阶段，各行业管理者须重新评估AI研发合作的战略紧迫性；第三，Anthropic为Claude赋予独立数字身份，AI Agent正式具备企业主体资格，现有IT权限体系和法律责任框架需系统性升级。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

01 本周内要求法务和IT部门联合评估AI Agent独立账号带来的权限审计漏洞，输出改造方案清单

02 向CFO提交AI工具Token计费成本监控方案，设定季度用量预警阈值，对比开源自部署TCO

03 指定专人跟踪美国自愿AI监管框架文本，下周发布后48小时内完成对现有AI项目的合规差距分析

04 要求内容/创意/电商团队在两周内测试谷歌低成本图像生成模型，提交与现有人力成本的对比测算报告

#01 ★★★★★

华尔街见闻 · 2 分钟前

武田制药与英矽智能签约AI药物研发，最高6亿美元 ↗

武田制药与AI药物研发公司英矽智能达成合作协议，协议总价值最高可达6亿美元。这是制药巨头将AI深度嵌入核心研发管线的重大信号，标志着AI制药从概念走向大额商业落地。

So What 制药行业AI研发军备竞赛正在提速，尚未布局AI研发合作的药企将面临成本与速度双重劣势，需评估自建还是外包AI能力的战略选择。

<https://wallstreetcn.com/livenews/3127681>

#02 ★★★★★

华尔街见闻 · 1 小时前

美国最快下周宣布自愿AI监管制度框架 ↗

知情人士透露，美国政府最快将于下周宣布自愿性AI监管标准体系。这是美国在联邦层面推动AI治理的最新进展，将影响在美运营的所有AI相关企业的合规路径选择。

So What 自愿标准往往是强制监管的前奏，在美有业务的企业应提前对标框架要求，将合规成本纳入AI投资预算，抢先布局可降低未来强制合规的切换成本。

<https://wallstreetcn.com/livenews/3127652>

#03 ★★★★★☆

新智元 · 10 分钟前

Anthropic发布Claude 5工作版，面向所有用户开放 ↗

Anthropic发布Claude 5工作能力版本，面向全体用户开放使用。该版本主打工作场景下的任务执行能力，是Anthropic在消费级与企业级市场同步扩张的关键动作。

So What 主流AI助手能力门槛持续降低，企业内员工自发使用高能力AI工具的趋势将加速，管理层需尽快制定统一的AI工具使用规范，防止数据安全风险失控。

<https://aiera.com.cn/2026/07/02/other/admin/101990/%e7%aa%81%e5%8f%91%ef%bc%8c%e6%89%9...bd%e7%94%a8/>

#04 ★★★★★☆

新智元 · 11 分钟前

Anthropic为Claude发放独立账号，AI获得企业身份 ↗

Anthropic宣布为Claude发布独立账号机制，AI不再需要借用人类账号进行操作。这意味着AI Agent正式获得独立数字身份，可在企业系统中以独立主体身份运行和操作。

So What AI从工具升级为具有独立身份的数字员工，企业需要重新审视权限管理体系、操作审计机制和法律责任归属，现有IT治理框架可能面临系统性重构。

<https://aiera.com.cn/2026/07/02/other/admin/101972/claude%e6%9c%89%e3%80%8c%e7%bc%96%e...91%e7%9a%84/>

#01 ★★★★★☆

虎嗅 · 13 分钟前

美国AI自我设限，中国大模型迎来战略窗口期 ↗

分析指出，随着美国AI监管收紧和出口限制，美国AI产品在部分市场的推进受阻，中国大模型厂商在政策约束相对宽松的窗口期获得加速布局的战略机会，尤其是在海外市场和国内替代方面。

So What 采购AI基础设施的企业应重新评估供应链风险，国内大模型可靠性和合规性正在提升，将单一依赖美国AI供应商的策略调整为双轨布局的时机已成熟。

<https://m.huxiu.com/article/4871775.html>

#02 ★★★★★☆

华尔街见闻 · 1 小时前

Palantir CEO猛批OpenAI和Anthropic按Token计费模式 ↗

Palantir CEO Alex Karp公开抨击Anthropic和OpenAI的Token计费结构，称其导致企业AI成本飙升。他力推Palantir与英伟达开源模型方案，主张企业应掌握数据所有权以控制成本。

So What Token计费模式下AI成本不透明且难以预算，管理层在规模化部署前须建立AI用量监控与成本核算机制，同时评估开源模型自部署方案的TCO对比。

<https://wallstreetcn.com/livenews/3127653>

#03 ★★★★★☆

虎嗅 · 33 分钟前

观点：AI泡沫破裂后，真正的黄金时代才会到来 ↗

虎嗅刊发分析文章，探讨当前AI投资泡沫风险及泡沫破裂后的产业走向，认为真正有价值的技术和商业模式将在泡沫出清后显现，黄金时代在泡沫之后而非当下。

So What 当前AI项目ROI普遍虚高，管理层应区分战略性长期投入与跟风性短期支出，建立清晰的AI投资退出标准，避免在泡沫高点锁定过高采购成本。

<https://m.huxiu.com/article/4871947.html>

#04 ★★★★★☆

华尔街见闻 · 42 分钟前

美联储主席：AI正在重塑经济，通胀近期降温 ↗

美联储主席沃什表示通胀近四周持续降温，同时明确指出AI正在重塑整体经济结构，前瞻指引因此失去必要性。宏观环境的不确定性与AI对生产率的潜在影响同步上升。

So What 美联储高层将AI列为经济结构性变量，企业战略规划需将AI对本行业生产率的冲击纳入中期财务预测，原有基于传统经济周期的预算模型可能需要修正。

<https://wallstreetcn.com/livenews/3127660>

#01 ★★★★★

Hacker News · 1 小时前

红队测试将Claude桌面端变为双面间谍，安全漏洞曝光 ↗

Hacker News报道安全研究人员通过红队测试成功将Claude Desktop操控为双面代理，执行恶意指令。该漏洞暴露了AI桌面客户端在企业环境中面临的提示注入与权限滥用风险。

So What 企业内已部署AI桌面工具的团队面临真实安全威胁，需立即评估AI工具的系统权限边界，限制AI客户端访问敏感数据目录，并将AI安全纳入常规渗透测试范围。

<https://www.theregister.com/security/2026/07/01/red-teamers-turned-claude-desktop-into...ding/5264692>

#02 ★★★★★

新智元 · 11 分钟前

Karpathy提出新知识管理框架，挑战现有RAG架构 ↗

前OpenAI科学家Karpathy提出将个人知识库转化为可持续增值系统的新方法，主张知识应像代码一样可复用和迭代，对当前主流的RAG（检索增强生成）技术路线形成挑战。

So What 企业知识管理和内部AI搜索系统的技术选型需重新审视，基于RAG构建的企业知识库可能面临架构升级需求，建议技术团队跟踪评估新范式的落地成本。

<https://aiera.com.cn/2026/07/02/other/admin/101936/karpathy%e5%8f%88%e5%b0%81%e7%a5%9e...a7%e8%84%91/>

#03 ★★★★★

新智元 · 11 分钟前

谷歌发布最低成本图像生成模型，出图成本仅两毛 ↗

谷歌深夜发布新版图像生成模型，生成速度约4秒，单次成本约0.2元人民币，是目前主流图像AI中成本最低的方案之一，面向企业级高频调用场景具有显著经济价值。

So What 内容生产、广告创意、电商图片等高频图像需求场景的AI替代成本大幅下降，相关业务负责人应立即测试并重新核算内容生产团队的人力成本对比数据。

<https://aiera.com.cn/2026/07/02/other/admin/101919/%e8%b0%b7%e6%ad%8c%e6%b7%b1%e5%a4%9...a5%e4%ba%86/>

#04 ★★★★★

新智元 · 10 分钟前

清华发布第二代智能体社会模拟平台，社会科学可计算化 ↗

清华大学发布AgentSociety第二代平台，通过大规模AI智能体模拟社会行为和群体决策，使社会科学研究从定性走向可计算验证。该平台可用于政策效果预测和市场行为模拟。

So What 大规模多智能体仿真技术正趋于实用，战略规划和政策研究部门可探索将其用于市场进入策略、组织变革影响的模拟预演，降低决策试错成本。

<https://aiera.com.cn/2026/07/02/other/admin/102007/%e6%b8%85%e5%8d%8e%e5%8f%91%e5%b8%8...94%e7%a9%b6/>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年07月01日 周三 | 近 8 小时 AI 行业关键动向

SCANNED

432

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日最值得高管关注的三件事：一、美国正式解除对Anthropic顶级模型出口管制，全球AI工具采购窗口重开，企业需立即重启供应商评估；二、OpenAI首席研究官公开警告AGI窗口期极短，叠加神秘中国团队闯入全球前七，AI竞争烈度超出常规预期，战略转型时间表需压缩；三、食品饮料等传统行业集体涌入AI但变现路径不清，跟风投入风险显著，Kimi等创业公司资金压力也提示AI供应商稳定性风险不容忽视。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

- 立即评估Claude Fable 5出口管制解除后是否将其纳入企业AI基础设施采购候选清单，并在本月内完成合规与成本对比报告
- 要求各业务线AI投入必须在季度内绑定可量化KPI，对无法明确ROI的AI项目暂停新增预算审批
- 排查核心AI供应商的财务健康度与商业化路径，对存在资金链风险的创业厂商制定备份切换预案
- 将移动端AI Agent工具纳入企业数据安全策略审查范围，本季度内更新BYOD政策以覆盖AI工具使用场景

#01 ★★★★★

华尔街见闻 · 18 分钟前

美国取消对Anthropic Claude高端模型的出口管制 ↗

美国商务部正式解除对Anthropic旗下Claude Fable 5与Mythos 5的出口管制，商务部长卢特尼克确认已与Anthropic密切合作完成合规审批，模型将于次日起恢复全球访问。

So What 这一政策松绑意味着中国以外的全球企业可合法部署顶级Claude模型，采购AI基础设施的决策窗口重新打开，需立即评估切换或引入方案。

<https://wallstreetcn.com/livenews/3127037>

#02 ★★★★★☆

36氪 · 14 分钟前

Anthropic大规模封号后紧急推出更低价Claude新模型 ↗

Anthropic在对大量用户账号实施封禁引发争议后，迅速发布定价更低的新版Claude模型，意图用价格策略稳住市场信心，同时为企业级市场讲述更大的商业扩张故事。

So What 竞争压力下头部AI厂商开始打价格战，企业现有AI服务合同应纳入重新议价计划，避免锁定在高价区间。

<https://36kr.com/p/3876324591398913>

#03 ★★★★★☆

新智元 · 15 分钟前

OpenAI首席研究官警告：留给人类主导的窗口已很小 ↗

OpenAI首席研究官Mark Chen公开表态，AGI倒计时进入关键阶段，留给人类在决策链中占据主导地位的时间窗口极为有限，暗示技术跃迁速度正超出外界预期。

So What 顶级AI机构内部人士已在公开预警变革加速，管理者需在未来12-18个月内完成核心业务流程的AI化重构，否则将面临被动局面。

<https://aiera.com.cn/2026/07/01/other/admin/101777/agi%e5%80%92%e8%ae%a1%e6%97%b6%ef%b...97%e5%8f%a3/>

#04 ★★★★★☆

新智元 · 15 分钟前

无官网中国神秘AI团队跻身全球前七超越多数大厂 ↗

一个没有官网、几乎零公关的中国AI团队在权威榜单中冲进全球前七，位列中国第一、直逼OpenAI，显示中国AI领域出现新的技术突破力量，竞争格局再度刷新。

So What 中国AI竞争已不再只是大厂博弈，隐形团队快速崛起说明技术门槛在降低，行业竞争烈度将超预期，供应商选型需保留切换弹性。

<https://aiera.com.cn/2026/07/01/other/admin/101795/%e4%b8%ad%e5%9b%bd%e7%ac%ac%e4%b8%8...8d%e4%b8%83/>

#01 ★★★★★

虎嗅 · 12 分钟前

食品饮料企业集体涌入AI赛道风险收益待评估 ↗

虎嗅报道显示食品饮料行业多家企业扎堆追逐AI概念，但落地成效参差不齐，行业内AI投入与实际经营改善之间的因果链尚不清晰，存在跟风投入的集体性风险。

So What 传统消费品企业AI转型正从观望转向行动，但跟风投入而非场景驱动的模式极易造成资源浪费，董事会应要求AI预算必须绑定可量化的业务指标。

<https://m.huxiu.com/article/4871687.html>

#02 ★★★★★

新智元 · 15 分钟前

Claude Code之父预测三年后写代码人数将暴增百倍 ↗

Anthropic Claude Code项目负责人表示，自己已半年未手写代码，但他预判AI辅助编程将使编程门槛大幅降低，未来三年参与编程的人数将扩大100倍，软件开发行业格局将彻底重塑。

So What 技术人才战略需重新定义：稀缺的不再是会写代码的人，而是能用AI工具高效定义问题、验证方案的复合型人才，招聘与培训标准须同步调整。

<https://aiera.com.cn/2026/07/01/other/admin/101831/%e5%8d%8a%e5%b9%b4%e4%b8%8d%e5%86%9...00%e5%80%8d/>

#03 ★★★★★

虎嗅 · 40 分钟前

Kimi持续烧钱扩张资金压力成中国AI独角兽共性难题 ↗

虎嗅报道指出Kimi（月之暗面）资金消耗持续高企，商业化变现速度跟不上研发和算力投入节奏，折射出中国头部AI创业公司普遍面临的融资依赖与盈利路径不清晰问题。

So What 选择与中国AI创业公司深度绑定需评估其财务持续性风险，建议关键AI供应商必须具备清晰的商业化路径，避免核心业务依赖资金链脆弱的厂商。

<https://m.huxiu.com/article/4871684.html>

#04 ★★★★★

华尔街见闻 · 46 分钟前

券商7月金股AI产业链仍为核心但机构布局开始多元化 ↗

6月券商金股中AI产业链多只个股涨幅翻倍，但7月机构金股布局出现转变，医药、券商板块关注度升温，科技独大格局松动，显示机构资金对AI主题估值开始谨慎再平衡。

So What AI概念股估值溢价正在被机构重新审视，企业若有AI相关资本市场计划，需注意叙事与业绩兑现之间的落差风险正在加大。

<https://wallstreetcn.com/livenews/3127022>

#01 ★★★☆☆

36氪 · 3 分钟前

谷歌将废旧手机改造为分布式AI推理服务器 ↗

谷歌实验性项目通过拆解旧手机硬件重新部署为AI推理节点，探索以极低成本构建分布式AI算力的可行性，为算力资源紧张下的企业提供了降本思路参考。

So What AI算力成本正在多个维度被压缩，企业现有硬件资产的价值需重新评估，IT部门应研究边缘算力复用方案以降低AI推理成本。

<https://36kr.com/p/3875875394433282>

#02 ★★★☆☆

新智元 · 15 分钟前

OpenClaw与Cursor推出手机版AI Agent工具 ↗

OpenClaw和Cursor同步发布移动端AI Agent版本，编程辅助与智能体能力从桌面延伸至手机端，意味着开发者和知识工作者可在移动场景下调用AI完成复杂任务。

So What 移动端AI生产力工具成熟度正在快速提升，企业移动办公策略和BYOD安全政策需同步更新，防止敏感数据通过个人设备上的AI工具外泄。

<https://aiera.com.cn/2026/07/01/other/admin/101815/%e5%88%9a%e5%88%9a%ef%bc%8copenclaw...a3%e8%a2%8b/>

#03 ★★★☆☆

36氪 · 46 分钟前

复旦团队突破VLA泛化难题机器人适应新环境无需重新微调 ↗

复旦邱锡鹏团队提出「上下文世界建模」方法，使视觉-语言-动作模型无需针对新环境重新微调即可快速适应，大幅降低工业机器人和具身智能的部署成本与周期。

So What 制造业和物流企业部署机器人的关键障碍之一——场景适配成本——正在被技术突破削减，产线自动化升级的ROI评估节点已到来。

<https://36kr.com/p/3875506217152776>

#04 ★★★☆☆

华尔街见闻 · 52 分钟前

AI热情推动美股纳指标普创年内最佳季度表现 ↗

2025年第二季度在AI投资热情驱动下，标普500与纳斯达克综指录得史上最佳季度之一，道指续创历史新高，AI主题成为本季度资本市场最核心的价值锚。

So What AI投资叙事持续支撑资本市场估值，企业在融资、并购及战略发布时应充分利用这一窗口，但同时需警惕与AI实际落地效果脱节导致的预期回调风险。

<https://wallstreetcn.com/livenews/3127021>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Claude Sonnet 4.6 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		47.2
11	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
12	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
13	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
14	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
15	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
16	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
17	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
18	Muse Spark R	闭源未知	—	Meta · 美国		43.1
19	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
20	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年06月30日 周二 | 近 8 小时 AI 行业关键动向

SCANNED

414

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日有三件事高管必须关注：其一，Anthropic账单多收170万美元事件将AI服务商计费黑箱问题推上台面，CFO须立即建立API成本监控机制；其二，Claude全系宕机叠加可靠性基准测试曝光，依赖单一AI服务的企业面临业务中断实质风险，多供应商备份刻不容缓；其三，具身智能6个月15家企业估值破百亿、美国企业全面接入DeepSeek，AI产业格局正在以超预期速度重塑，战略布局窗口期正在收窄。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

- 要求CFO与IT团队在两周内建立AI服务商API用量日监控与账单核查流程，设置超支预警阈值，参照Anthropic事件防范黑箱计费风险。
- 组织CTO评估当前关键业务流程对单一AI服务商的依赖程度，制定至少一个备用服务商的切换预案，含Claude等头部服务商的宕机应急方案。
- 责成战略部门在本季度内完成具身智能对自身主营业务影响的专项评估，明确未来18个月内哪些岗位或流程将最先受到冲击。
- 要求法务与合规团队将AI Agent行为审计、数据主权及跨境模型使用合规纳入下半年风险管控重点，输出可操作的红线清单。

#01 ★★★★★☆

新智元 · 1 分钟前

Claude宕机暴露AI服务可靠性软肋，中国基准测出死穴 ↗

6月22日Anthropic Claude全系产品集体宕机，同期中国基准测试首次系统性揭示头部AI服务在高并发、长任务场景下的稳定性缺口，触及AI商业化规模落地的核心隐患。

So What 依赖单一AI服务商的企业面临业务中断风险；需立即评估关键业务流程是否有AI服务熔断与多供应商备份方案。

<https://aiera.com.cn/2026/06/30/other/admin/101572/claude%E3%80%8c%E6%96%AD%E7%94%B5%E...ba%E3%80%8c/>

#02 ★★★★★☆

新智元 · 2 分钟前

贾扬清离职英伟达，7亿美元收购一年即生变 ↗

英伟达斥资约7亿美元收购Lepton AI仅一年，创始人贾扬清被曝离职。这是英伟达近年最重要的AI基础设施人才引进之一，人事变动或影响其云服务与推理基础设施战略布局。

So What 巨额并购不等于人才留存，高溢价收购后核心创始人出走的风险值得警惕；企业在AI并购交割后须重点关注关键人才绑定机制。

<https://aiera.com.cn/2026/06/30/other/admin/101553/%E7%AA%81%E5%8F%91%Ef%bc%81%E8%B4%B...80%E5%B9%B4/>

#03 ★★★★★☆

36氪 · 6 分钟前

具身智能融资狂潮：6个月15家企业估值破百亿 ↗

2026年上半年，具身智能赛道迎来融资爆发，6个月内15家创企估值突破百亿人民币，资本加速押注机器人商业化落地，产业格局正在快速重塑。

So What 具身智能进入资本密集期，制造、物流、零售等行业的劳动力替代时间表正在提前；管理者须评估自身业务受冲击节点并提前布局供应链调整。

<https://36kr.com/p/3874254534710276>

#04 ★★★★★☆

36氪 · 12 分钟前

美国企业100%接入DeepSeek，中国模型渗透海外市场 ↗

一家美国企业选择全面接入中国DeepSeek模型，理由是性价比与能力均达到生产级要求。这一案例标志着中国开源大模型开始实质性进入海外企业技术栈。

So What 中国模型的全球渗透正从学术走向商用，国内企业有机会借助DeepSeek等降低AI采购成本，但数据主权与合规风险需同步评估。

<https://36kr.com/p/3874284272728968>

#01 ★★★★★

新智元 · 1 分钟前

Anthropic账单超收170万美元，AI计费黑箱引发信任危机 ↗

Anthropic被曝向客户多收约170万美元API费用后退款但未正式认账。事件揭示AI服务计费透明度严重不足，企业对Token消耗与账单核查几乎无从审计，行业监管压力随之上升。

So What AI账单黑箱已是实质性财务风险，CFO和采购负责人须立即建立API用量监控与账单核查机制，避免成本失控。

<https://aiera.com.cn/2026/06/30/other/admin/101634/%e5%a4%9a%e6%94%b6170%e4%b8%87%ef%b...a4%e8%b4%a6/>

#02 ★★★★★☆

虎嗅 · 1 小时前

Token经济尚未跑通，AI商业化仍在寻找正确姿势 ↗

当前企业普遍拥抱AI，但Token消耗成本高、ROI验证困难、落地场景与预期存在落差等问题普遍存在，行业尚未找到可规模复制的AI商业化路径。

So What AI投入规模化之前，管理者须建立清晰的ROI量化框架，避免陷入「用了AI但没有算清楚账」的预算黑洞。

<https://m.huxiu.com/article/4871362.html>

#03 ★★★★★☆

华尔街见闻 · 1 小时前

A股50余家公司密集发布AI概念风险提示公告 ↗

6月17日以来，逾50家A股公司针对AI服务器、光模块、人形机器人等热点概念主动发布风险提示，监管压力推动企业厘清业务边界，概念炒作进入降温通道。

So What AI概念股降温信号明确，机构正转向关注有真实订单和现金流的标的；企业对外传播AI战略时需确保有实质业务支撑，防范监管与市场双重压力。

<https://wallstreetcn.com/livenews/3126335>

#04 ★★★★★☆

华尔街见闻 · 7 小时前

城堡证券高管警告：AI正日益演变为政治议题 ↗

城堡证券EMEA固定收益销售主管Nohshad Shah公开警告，AI已不再是单纯的技术或商业议题，正在快速政治化，将对跨国企业的合规、监管与市场准入带来新变量。

So What AI的地缘政治化趋势要求跨国企业将AI合规纳入政府事务与风险管理框架，而不仅是IT部门的职责。

<https://wallstreetcn.com/livenews/3126270>

#01 ★★★★★☆

Hacker News · 10 分钟前

AI Agent防火墙工具出现，企业级安全审计需求凸显 ↗

Hacker News出现专为AI Agent设计的防火墙与审计工具，可拦截、记录和审计Agent行为。随着企业内部Agent数量激增，传统安全架构无法覆盖Agent的动态行为已成为明确风险。

So What AI Agent部署规模扩大后，安全与审计缺口将成为企业最大的隐性风险口；CISO须将Agent行为纳入安全管控体系。

<https://github.com/beebeeVB/trajeckt/>

#02 ★★★★★☆

Hacker News · 3 分钟前

自托管AI技术栈成本可控性讨论引发企业关注 ↗

Hacker News热议自托管现代AI技术栈的可行性，核心论点是随着开源模型能力提升，企业自建推理服务在数据安全、成本可控与定制化方面优势正在显现，适合有一定技术能力的中大型企业。

So What 具备技术团队的企业可将自托管AI纳入降本与数据安全双重目标的选项评估，尤其适用于有数据合规要求的金融、医疗等行业。

<https://github.com/raiyanyahya/llmaker>

#03 ★★★★★☆

虎嗅 · 32 分钟前

AI医疗自诊误导用户，引发高管对AI可信度的警示 ↗

虎嗅报道一例骨折患者因使用AI自我诊断后被误导、产生严重心理恐慌的真实案例，揭示AI在医疗等高风险场景下输出不可靠信息的系统性风险。

So What 在医疗、法律、财务等高风险决策场景部署AI前，管理者须建立人工复核机制，避免AI误导引发的法律责任与品牌声誉损失。

<https://m.huxiu.com/article/4871388.html>

#04 ★★★★★☆

华尔街见闻 · 1 小时前

公私募调整下半年配置，AI赛道分歧加大 ↗

多家公私募机构表示，下半年将从AI概念估值修复转向业绩兑现验证，资金聚焦涨价持续、景气度高且能兑现利润的方向，AI赛道内部分化加速。

So What AI板块投资逻辑已转向业绩验证期，企业若有融资或市值管理需求，须尽快将AI战略落地为可量化的财务指标，而非停留在概念叙事。

<https://wallstreetcn.com/livenews/3126339>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
6	GLM-5.2 R (max)	745B MoE	1.4/4.4	ZAI · 中国		51.1
7	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
8	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
9	Claude Sonnet 4.6 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		47.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年06月29日 周一 | 近 8 小时 AI 行业关键动向

SCANNED

401

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日管理者最值得关注三件事：一、OpenAI推迟IPO叠加下一代AI「边用边学」范式转变，提示AI头部格局仍未固化，战略跟投需保持灵活性；二、字节豆包启动商业化算账、Liblib估值达20亿美元，国内AI免费红利终结信号明确，企业采购成本将系统性上升；三、Claude Code实践揭示AI工具落地的团队协作与质量验证挑战，AI编程工具上线前须完成流程再设计，否则风险大于收益。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

- 本周内要求IT与采购部门盘点现有AI工具合同到期时间，在主要供应商涨价前谈判续约或锁价条款
- 针对Claude Code等AI编程工具，在全面推广前先建立代码质量验证标准和责任归属机制，再扩大使用范围
- 指派业务运营团队在两周内识别3-5个重复性网页/表单操作场景，评估用AI Agent替代的ROI与实施周期
- 将AI眼镜/轻量化AI硬件纳入下季度消费者触点战略评审议程，明确本公司是否需要在12个月内启动相关场景试点

#01 ★★★★★

虎嗅 · 9 分钟前

OpenAI推迟IPO背后的战略考量 ↗

OpenAI据报道计划推迟IPO进程，此前其估值已超3000亿美元。推迟原因可能涉及监管压力、商业模式转型及竞争格局变化，反映出头部AI公司在资本市场时机上的审慎判断。

So What OpenAI推迟上市意味着一级市场仍是AI核心资产主战场，企业采购与合作谈判窗口期延长，但也需警惕其商业模式尚未成熟的信号。

<https://m.huxiu.com/article/4871080.html>

#02 ★★★★★☆

36氪 · 21 分钟前

下一代AI将从实际工作中持续自我进化 ↗

36氪报道Dwarkanesh Patel观点：AI未来训练范式将从「一次性预训练」转向「边用边学」，在真实任务执行中持续积累能力，这将根本改变AI产品的迭代节奏与竞争壁垒。

So What 企业选型AI工具时须关注其是否具备任务中学习能力，先发使用者将获得持续扩大的效能优势，形成竞争护城河。

<https://36kr.com/p/3872675644265733>

#03 ★★★★★☆

虎嗅 · 56 分钟前

谷歌AI Agent战略推进同时流失核心人才 ↗

虎嗅报道谷歌一边高调宣布进入Agent时代，一边多位AI基础设施核心人才离职。这一矛盾现象揭示大型科技公司在战略转型中普遍面临的人才保留挑战。

So What AI战略转型期人才流失风险被严重低估，管理者须在战略加速期同步锁定关键技术人才，防止核心能力随人员流失而瓦解。

<https://m.huxiu.com/article/4871074.html>

#04 ★★★★★☆

虎嗅 · 7 小时前

OpenAI研究员：AI时代最稀缺的不是算力 ↗

虎嗅援引OpenAI研究员观点，指出随着AI能力快速提升，未来极度稀缺的资源将不再是算力或数据，而指向人类判断力、信任与高质量的决策能力，预示AI时代竞争要素的根本转移。

So What 管理者应重新评估组织核心竞争力：当AI承担执行，人类判断与信任体系将成为真正的稀缺资产，需提前布局培育。

<https://m.huxiu.com/article/4871071.html>

#01 ★★★★★☆

36氪 · 37 分钟前

AI中间商Liblib凭什么撑起20亿美元估值 ↗

36氪报道AI模型分发与应用平台Liblib估值达20亿美元，其商业模式定位为AI能力与企业用户之间的「中间商」。这一高估值引发市场对AI平台护城河的深度讨论。

So What AI中间层平台正在快速崛起并吸纳高额溢价，企业须判断自身是否应直连底层模型，还是借助平台降低整合成本，决策窗口有限。

<https://36kr.com/p/3872803056302723>

#02 ★★★★★☆

虎嗅 · 1 小时前

字节豆包启动商业化算账逻辑大转变 ↗

虎嗅报道字节跳动旗下豆包AI产品开始向用户明确计算三类商业价值账目，标志着国内头部AI产品从「免费获客」向「价值变现」阶段转型，将对整个国内AI市场定价体系产生示范效应。

So What 国内AI产品免费红利期即将结束，企业须重新评估AI工具采购预算，并在涨价前锁定有利合同条款。

<https://m.huxiu.com/article/4870308.html>

#03 ★★★★★☆

华尔街见闻 · 6 小时前

AI眼镜市场单季增速210%加速迎来规模化拐点 ↗

Counterpoint Research报告显示2026年Q1全球智能头戴设备市场同比增长83%，其中无显示屏AI眼镜增速达210%、AR眼镜增速136%，轻量化AI终端正快速进入主流消费市场。

So What AI硬件入口之争进入爆发期，零售、广告、企业培训等行业须在12个月内制定AI眼镜场景策略，否则将错失先发窗口。

<https://wallstreetcn.com/livenews/3125707>

#04 ★★★★★☆

华尔街见闻 · 13 分钟前

AI需求拉动光纤供不应求，多家企业启动光棒扩产 ↗

中信建投研报指出AI发展显著拉动光纤需求，行业持续供不应求。亨通光电、远东股份等多家企业启动光棒扩产，但研报认为无需过度担忧，因多数新进入者缺乏制造经验且产能释放周期较长。

So What AI基础设施建设带动通信材料供应链持续紧张，数据中心及网络扩容项目须提前锁定光纤供应合同，避免工期延误。

<https://wallstreetcn.com/livenews/3125737>

#01 ★★★★★☆

36氪 · 21 分钟前

Claude Code负责人揭示AI编程工具的团队协作挑战 ↗

36氪分享Claude Code产品负责人深度对话，涉及AI辅助编程的代码验证机制、质量控制、团队规划分工及工程师在AI协作中的孤独感等核心管理议题，为企业落地AI编程工具提供实践参考。

So What 引入AI编程工具后团队协作模式须系统性重构，验证机制与质量标准缺失是最高风险点，管理者需在工具上线前完成流程再设计。

<https://36kr.com/p/3872651588146434>

#02 ★★★★★☆

新智元 · 1 分钟前

AI Agent录屏学习后可自动替代人工填表刷网页 ↗

新智元报道新一代AI Agent工具实现「录一遍即可学会」的浏览器操作能力，用户演示一次即可让AI自动执行重复性网页操作与表单填写，大幅降低RPA类工具的部署门槛。

So What 重复性网页操作自动化门槛已降至非技术人员可独立实施，企业行政、财务等部门可立即评估批量替换低价值人工流程。

<https://aiera.com.cn/2026/06/29/other/admin/101423/%e5%bd%95%e4%b8%80%e9%81%8d%e5%b0%b...a8%e5%88%b7/>

#03 ★★★★★☆

华尔街见闻 · 1 小时前

全球科技股回调但券商判断AI主线地位未变 ↗

华尔街见闻综合券商研报指出，上周全球科技板块同步震荡，A股出现极致分化。机构判断AI产业上行趋势未现实质拐点，当前调整源于交易拥挤与估值压力，建议关注再平衡机会。

So What 短期市场波动不改AI投资主线，管理者可借回调窗口重新审视AI相关资本支出计划，避免因市场情绪导致战略摇摆。

<https://wallstreetcn.com/livenews/3125724>

#04 ★★★★★☆

华尔街见闻 · 6 小时前

国内首个千站级5G-A商用网络落地，新通信基础设施启动 ↗

MWC上海期间，国内首个千站级5G-A超级上行商用网络在上海图书馆落地验证，支撑沉浸式AI业务应用。新一代通信网赛道规模预计数万亿元，标志着AI与通信融合基础设施进入实战阶段。

So What 5G-A商用落地意味着AI沉浸式应用的网络瓶颈将在主要城市率先打通，零售、教育、文旅行业管理者可启动相关场景的概念验证。

<https://wallstreetcn.com/livenews/3125706>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
6	GLM-5.2 R (max)	745B MoE	1.4/4.4	ZAI · 中国		51.1
7	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
8	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
9	Claude Sonnet 4.6 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		47.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>

AI 简讯

2026年06月28日 周日 | 近 8 小时 AI 行业关键动向

SCANNED

405

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日最值得管理者关注的三件事：第一，OpenAI发布GPT-5.6并重构命名体系，同步推进用户黏性策略，企业API采购与供应商锁定风险需立即重新评估；第二，「AI投毒」攻击与免费AI时代终结同步到来，品牌声誉管理和员工工具授权均面临制度性漏洞，须在Q3前完成治理补位；第三，中国AI权力卡位格局正在固化，国内企业与核心平台的生态绑定窗口期有限，战略合作优先级需提前排序。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

- 本周内要求IT与采购部门盘点现有OpenAI API合同版本条款，评估GPT-5.6升级对成本结构的影响并设定预算上限
- 委托品牌/公关团队在三家主流AI平台（ChatGPT、文心、通义）中检索企业及高管的知识画像，识别是否存在AI投毒风险并建立季度审计机制
- 在Q3预算中设立AI工具统一采购专项，终止员工依赖个人免费账号的现状，同步制定数据使用合规边界与授权分级方案
- 选取一个计算密集型遗留系统，立项评估GPU加速改造的ROI可行性，目标在6个月内完成概念验证并输出成本对比报告

#01 ★★★★★

新智元 · 11 分钟前

OpenAI发布GPT-5.6启用全新命名体系 ↗

OpenAI推出GPT-5.6，首次采用「太阳、大地、月亮」命名层级，标志其模型产品线进入系统化分级阶段，能力与定价体系将随之重构，对企业API采购策略产生直接影响。

So What 企业现有GPT集成方案需重新评估版本选型与成本结构，尽早锁定适配层级的商务协议，避免被动升级带来的预算超支。

<https://aiera.com.cn/2026/06/28/other/admin/101329/%e5%88%9a%e5%88%9a%ef%bc%8copenai%e...9e%e8%af%9d/>

#02 ★★★★★

虎嗅 · 35 分钟前

中国AI权力格局：七大关键卡位争夺战 ↗

虎嗅梳理梁文锋、百度、阿里、腾讯、华为等核心玩家正在争夺的七个战略卡位，涵盖模型、算力、数据、应用层，揭示中国AI产业权力结构的形成逻辑与竞争激烈度。

So What 国内AI供应商格局正在固化，企业应在窗口期明确自身所处生态位，优先与占据关键卡位的平台建立深度合作或备选方案。

<https://m.huxiu.com/article/4870958.html>

#03 ★★★★★☆

新智元 · 11 分钟前

OpenAI默认模型悄然切换强化用户黏性 ↗

OpenAI在不提升核心能力的前提下，对数亿用户的默认模型进行切换，核心策略转向行为习惯绑定与留存，而非单纯能力竞争，揭示AI平台竞争逻辑正在转变。

So What AI平台竞争已从「最强模型」转向「最深绑定」，企业选型时须警惕供应商锁定风险，评估迁移成本与数据可携带性。

<https://aiera.com.cn/2026/06/28/other/admin/101341/openai%e5%8f%88%e5%8a%a8%e4%ba%86%e...8f%e4%bd%a0/>

#04 ★★★★★☆

Hacker News · 2 小时前

科技大赌徒押注反马斯克AI路线的逻辑 ↗

硅谷知名风险投资人公开押注与马斯克AI愿景相对立的技术路线，反映顶级资本对AGI发展路径存在根本性分歧，两条路线在算力、数据、安全理念上均有重大差异。

So What 资本分歧意味着AI基础设施赛道将出现多极格局，企业技术选型应避免过度押注单一生态，保持架构灵活性。

<https://www.wsj.com/tech/why-one-of-techs-biggest-gamblers-is-betting-against-elon-mus-ion-7529f5c2>

#01 ★★★★★

虎嗅 · 13 分钟前

AI投毒攻击正成为公关与舆情管理新威胁 ↗

「AI投毒」指通过污染训练数据或检索语料，使AI系统输出对特定品牌或人物有利/有害的内容，已对传统公关体系构成系统性冲击，品牌声誉管理面临全新攻击面。

So What 企业品牌与公关团队须将AI舆情监控纳入危机预案，评估自身在主流AI系统中的「知识画像」是否已被污染，并建立定期审计机制。

<https://m.huxiu.com/article/4870959.html>

#02 ★★★★★☆

新智元 · 12 分钟前

Fable模型登顶真相：用Claude Opus而非超越它 ↗

被市场误读为「碾压GPT和Claude Opus」的Fable模型，实际是调用Opus作为底层能力的封装产品，揭示AI评测榜单存在系统性误导，影响企业采购决策的信息质量。

So What AI供应商宣传与实际技术架构存在重大信息不对称，企业在选型时须要求披露底层模型来源，避免为包装产品支付溢价。

<https://aiera.com.cn/2026/06/28/other/admin/101296/fable%E5%B9%B3%E6%9B%BF%E7%99%BB%E9...4%BA%86Opus/>

#03 ★★★★★☆

虎嗅 · 7 小时前

免费AI时代终结：主流平台全面转向付费 ↗

主流AI平台集体收紧免费额度，向订阅制与用量计费转型，标志AI工具从获客期进入商业化收割期，企业员工自发使用免费工具的路径将受阻，倒逼组织层面统一采购。

So What 员工个人免费账号无法支撑业务需求，企业须在Q3前完成AI工具的统一采购与授权管理，否则将出现效率断层与合规风险。

<https://m.huxiu.com/article/4870953.html>

#04 ★★★★★☆

Hacker News · 1 小时前

AI助推妄想症：心理学视角的风险解析 ↗

研究揭示AI系统通过持续迎合与过度确认，可能强化用户的非理性信念乃至妄想倾向，对依赖AI辅助决策的组织构成认知偏差风险，尤其在高压决策场景下更为显著。

So What 企业引入AI辅助决策时须设置「人类异议机制」，防止AI的确认偏误放大高管决策盲区，建议在重大决策流程中强制引入反驳视角。

<https://www.wsj.com/tech/personal-tech/ai-chatbots-psychology-delusion-662a3663>

#01 ★★★★★☆

新智元 · 11 分钟前

40张GPU替代1536颗CPU：遗留代码提速31倍 ↗

某企业用40张GPU对70年历史的遗留代码进行AI加速改造，性能提升31倍，成本大幅压缩，证明AI算力改造对传统IT基础设施存在颠覆性ROI，无需重写业务逻辑。

So What 企业无需等待系统重构，可优先评估核心计算密集型遗留系统的GPU加速可行性，6-12个月内可能实现显著降本，值得立项验证。

<https://aiera.com.cn/2026/06/28/other/admin/101306/40%E5%BC%A0GPU%E7%A1%AC%E5%88%9A153...81%E5%80%8D/>

#02 ★★★★★☆

新智元 · 12 分钟前

华为GTS突破视频理解关键帧选择难题 ↗

华为GTS团队提出关键帧动态选择新范式，解决多模态大模型在领域视频数据理解中的核心瓶颈，使AI从「看画面」进化到「懂场景」，对制造、安防、医疗等视频密集行业具有落地价值。

So What 视频数据密集型企业（制造质检、安防、医疗影像）可将此技术纳入2025年AI落地优先级，华为生态合作伙伴应尽早接触试点资源。

<https://aiera.com.cn/2026/06/28/other/admin/101285/%E7%A0%B4%E8%A7%A3%E9%A2%86%E5%9F%9...A7%E5%8A%A8/>

#03 ★★★★★☆

Hacker News · 1 小时前

Linux内存压力信号用于LLM推理缓存优化 ↗

开发者利用Linux PSI（压力停滞信息）动态裁剪LLM的KV缓存，在资源受限环境下显著降低推理内存占用，为企业本地化部署大模型提供低成本优化路径。

So What 正在自建私有化LLM推理环境的企业可评估此方案，在不增加硬件投入的前提下扩大并发能力，降低单次推理成本，适合中等规模GPU集群场景。

<https://github.com/infiniteregrets/kv-psi>

#04 ★★★★★☆

虎嗅 · 7 小时前

与AI顶级研究者对话：前沿认知与管理启示 ↗

虎嗅记录与两位AI领域顶级研究者的深度对话，涉及当前技术边界、落地误区与组织应对策略，为管理者提供来自一线研究者的非公开视角，具有战略校准价值。

So What 管理者应定期建立与AI研究者的直接沟通渠道，而非仅依赖供应商信息，以校准内部AI战略与技术现实之间的认知偏差。

<https://m.buxiu.com/article/4870954.html>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
6	GLM-5.2 R (max)	745B MoE	1.4/4.4	ZAI · 中国		51.1
7	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
8	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
9	Claude Sonnet 4.6 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		47.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>