

AI 简讯

2026年07月04日 周六 | 近 8 小时 AI 行业关键动向

SCANNED

416

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今日有三件事高管必须关注：一是Anthropic自研芯片消息落实，AI算力自主化竞争全面打响，依赖单一供应商的风险窗口正在缩短；二是阿里强制下架Claude并启动数据安全排查，企业AI工具的供应链安全审查已从「建议」升级为「行动」；三是欧洲金融监管者集体发声，将AI风险定性为超越传统网络安全的系统性威胁，合规压力将快速向企业传导。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

- 01 本周内组织IT与法务团队完成内部AI工具清单排查，重点核查第三方AI工具的数据访问权限与外传风险，参照阿里禁用事件建立准入白名单制度
- 02 将AI风险条款纳入下季度董事会风险议程，明确AI安全的责任归属与应急响应流程，不再将其归类为普通IT风险
- 03 与采购和技术团队评估现有GPU算力合同，对比推理专用芯片方案的TCO，在下一轮采购周期前完成备选供应商测试
- 04 对标Claude Code功能下放至20美元用户的定价动作，重新核算企业AI工具采购清单，识别可替换为低成本方案的存量合同

#01 ★★★★★

新智元 · 5 分钟前

Anthropic密谋自研芯片，挖OpenAI老兵洽谈三星2nm

Anthropic被曝正推进自研AI芯片计划，已从OpenAI挖角芯片领域资深人才，并与三星就2nm制程工艺展开密谈。这标志着继谷歌、亚马逊、Meta之后，又一家顶级AI实验室加入算力自主化竞赛。

So What AI算力自主化已成头部玩家共识，依赖英伟达的单一供应链风险持续上升，硬件战略布局将成为未来AI竞争的核心门槛。

<https://aiera.com.cn/2026/07/04/other/admin/102310/anthropic%e8%a2%ab%e6%9b%9d%e9%80%a...e6%98%9f2nm/>

#02 ★★★★★

虎嗅 · 3 小时前

Meta内部分歧曝光：算力过剩疑云与模型进展争议

扎克伯格承认AI进展慢于预期，但Meta AI负责人声称新模型已追上GPT-5.5。内部信号矛盾折射出Meta在大规模算力投入与实际模型竞争力之间的张力，「算力过剩」「质疑声音不断」。

So What 巨头算力军备竞赛出现疑云，管理者应警惕盲目跟投基础设施，优先评估AI投入的实际产出与业务匹配度。

<https://m.huxiu.com/article/4872592.html>

#03 ★★★★★

华尔街见闻 · 7 小时前

加拿大养老基金向EQT旗下AI基础设施投资17.5亿美元 ↗

CPP Investments宣布投资17.5亿美元，支持EQT子公司EdgeConneX主导的AI基础设施建设，计划未来数年内大规模开发数据中心资产，显示机构长线资本持续押注AI算力赛道。

So What 主权和养老资金大规模入场AI基础设施，意味着该赛道长期回报预期被顶级机构认可，可作为自身数字化资产配置的重要参考信号。

<https://wallstreetcn.com/livenews/3128806>

#04 ★★☆☆☆

新智元 · 4 分钟前

Anthropic将Claude Code企业级功能下放至20美元用户 ↗

此前仅向大型企业团队开放的Claude Code高级功能，现已向20美元/月Pro订阅用户全面开放。两周内完成从企业专属到普及的跨越，显示Anthropic加速抢占开发者市场的战略意图。

So What 高端AI编程工具平民化提速，企业付费壁垒被打破，需重新评估内部AI工具采购策略与成本结构。

<https://aiera.com.cn/2026/07/04/other/admin/102369/%e5%88%9a%e5%88%9a%ef%bc%8c%l%aude-c...b7%ef%bc%81/>

#01 ★★★★★

华尔街见闻 · 3 小时前

欧洲顶级银行家警告：AI发展速度已超越现行金融监管规则 ↗

英国FCA首席执行官等欧洲监管者明确表示，现行金融法规已难以跟上AI尤其是自主AI（Agentic AI）的发展节奏，监管机构正努力在支持创新与防范市场风险间寻求平衡。

So What 金融领域AI合规灰区正在扩大，金融及强监管行业的管理者须提前建立内部AI合规审查机制，避免监管突然收紧带来的运营风险。

<https://wallstreetcn.com/livenews/3128832>

#02 ★★★★★☆

新智元 · 5 分钟前

阿里全面禁用Claude，7月10日起强制卸载 ↗

阿里巴巴被曝已发出内部指令，全面禁止员工使用Claude，并要求于7月10日前完成卸载。起因是Claude Code被指存在隐蔽后门及数据标记风险，引发企业级AI工具安全审查。

So What 头部企业启动AI工具强制下架先例，供应商安全审查已成企业刚需，管理者应立即排查内部使用的第三方AI工具权限与数据流向。

<https://aiera.com.cn/2026/07/04/other/admin/102276/%e7%aa%81%e5%8f%91%ef%bc%81%e9%98%b8%e8%bd%bd/>

#03 ★★★★★☆

虎嗅 · 2 小时前

推理芯片崛起正在重写AI算力市场格局 ↗

虎嗅分析指出，以推理为核心的专用芯片正对英伟达GPU主导的算力市场形成实质冲击，AI算力格局从「训练为王」向「推理优先」转变，多家新兴芯片厂商借此切入市场。

So What 企业采购AI算力时，推理芯片性价比窗口正在打开，应提前评估现有GPU采购计划，测试推理专用方案的TCO（总拥有成本）。

<https://m.huxiu.com/article/4872597.html>

#04 ★★★★★☆

华尔街见闻 · 4 小时前

特朗普前AI顾问明确：美国不会设立类FDA的AI监管机构 ↗

刚卸任的白宫AI顾问Sriram Krishnan表示，本届政府不会建立类似FDA的专职AI许可监管体系，但白宫仍在动用行政权力暂缓部分顶尖大模型发布，监管逻辑趋向「灵活干预」而非系统立法。

So What 美国AI监管短期不设硬性许可门槛，有利于企业加速部署，但行政干预随机性增强，跨国AI产品合规策略需保持弹性。

<https://wallstreetcn.com/livenews/3128826>

#01 ★★★★★☆

华尔街见闻 · 3 小时前

欧洲央行行长拉加德：AI带来生产力的同时构成重大安全风险 ↗

拉加德在公开场合明确表态，AI是生产力和收益来源，但也构成「重大风险」，其风险严重性远超过去十年的网络安全威胁，且发展速度超过防御能力积累速度。

So What AI风险已被全球顶级金融监管者定性为系统性威胁，董事会层面须将AI风险纳入企业风险管理框架，而非仅停留在IT安全层面。

<https://wallstreetcn.com/livenews/3128834>

#02 ★★★★★☆

新智元 · 5 分钟前

Claude Fable 5越狱后跑分断崖下跌，安全与性能难以兼得 ↗

Anthropic Fable 5模型在经历安全加固后重新上线，但多项基准测试成绩出现明显下滑，引发业界对「安全补丁以性能为代价」的质疑，AI模型安全与能力的权衡矛盾再次浮现。

So What 企业在选型AI模型时需将安全加固后的实际性能纳入评估，供应商的安全声明与真实能力之间可能存在落差，需建立独立测试流程。

<https://aiera.com.cn/2026/07/04/other/admin/102298/claude-fable-5%ef%bc%8c%e5%90%8d%e5...9e%e4%ba%a1/>

#03 ★★★★★☆

华尔街见闻 · 2 小时前

AI热潮推动新兴市场资产单日最大涨幅，韩国芯片股领涨 ↗

MSCI新兴市场指数单日上涨2.2%，创6月15日以来最大涨幅，韩国SK海力士与三星强势反弹成主要驱动力，AI算力需求预期持续支撑全球科技股估值。

So What AI算力供应链相关资产仍是市场热点，企业若有海外供应链或投资布局，需关注韩国芯片厂商产能变化对采购价格与交期的连锁影响。

<https://wallstreetcn.com/livenews/3128844>

#04 ★★☆☆☆☆

Hacker News · 1 小时前

智能路由技术可大幅降低Claude Code的Token消耗成本 ↗

Hacker News社区分享了通过智能路由策略优化Claude Code调用路径的方案，通过任务复杂度分级调度不同规格模型，可显著节省Token用量，降低企业API调用成本。

So What 已规模部署AI编程工具的团队，应将Token成本优化纳入运营管理，智能路由可在不降效的前提下实质性压缩AI运营支出。

<https://github.com/regolo-ai/brick-SR1>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		59.9
2	Claude Opus 4.8 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		55.7
3	GPT-5.5 R (xhigh)	闭源未知	5/30	OpenAI · 美国		54.8
4	Claude Opus 4.7 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		53.5
5	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	3/15	Anthropic · ...		53.4
6	GPT-5.5 R (high)	闭源未知	5/30	OpenAI · 美国		53.1
7	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		51.1
8	GPT-5.5 R (medium)	闭源未知	5/30	OpenAI · 美国		50.4
9	Gemini 3.5 Flash R (high)	闭源未知	1.5/9	Google · 美国		50.2
10	Gemini 3.1 Pro Preview R	闭源未知	2/12	Google · 美国		46.5
11	Qwen3.7 Max R	≈1T · 闭源	2.5/7.5	Alibaba · 中国		46.0
12	Gemini 3.5 Flash R (medium)	闭源未知	1.5/9	Google · 美国		45.4
13	MiniMax-M3 R	闭源未知	0.3/1.2	MiniMax · 中国		44.4
14	DeepSeek V4 Pro R (Reasoning, Max Effort)	≈671B ...	0.43/0.87	DeepSeek · ...		44.3
15	GPT-5.3 Codex R (xhigh)	闭源未知	1.75/14	OpenAI · 美国		44.3
16	GPT-5.5 R (low)	闭源未知	5/30	OpenAI · 美国		43.5
17	Muse Spark R	闭源未知	—	Meta · 美国		43.1
18	Kimi K2.6 R	1T MoE	0.95/4	Kimi · 中国		42.8
19	Claude Opus 4.7 (Non-reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		42.7
20	MiMo-V2.5-Pro R	未公开	0.43/0.87	Xiaomi · 中国		42.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>