

AI 简讯

2026年08月11日 周二 | 近 8 小时 AI 行业关键动向

SCANNED

432

条原始资讯

SOURCES

12

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今天最值得管理层关注三点：一是上海“十五五”规划把AI基础设施、开源生态和产业规模化推向政策级竞争；二是字节、开源路线与HBM供给显示AI竞争焦点正从模型转向数据、安全和基础设施；三是AI在招聘、内容、电商和软件开发中的落地已暴露ROI、合规与安全治理短板。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

01 盘点现有AI项目的收入、成本、周期和风险指标

02 评估关键业务是否需要私有化或开源模型部署

03 为自主Agent建立沙箱、权限和红队测试清单

04 重算AI功能毛利，纳入算力、存储和人工复核成本

#01 ★★★★★

华尔街见闻 · 44 分钟前

上海提出2030年软信规模4万亿 ↗

上海发布软件和信息服务业“十五五”规划，提出到2030年产业规模力争达到4万亿元，产业增加值突破1.1万亿元，并把AI赋能应用作为主阵地。

So What 区域AI产业政策进入规模化落地阶段，企业可据此重评上海布局、产业基金、算力和应用场景合作机会。

<https://wallstreetcn.com/livenews/3147979>

#02 ★★★★★☆

虎嗅 · 1 小时前

开源闭源之争重塑AI竞争路径 ↗

硅谷围绕开源与闭源路线持续分化，文章指出中国AI正借开源生态绕过部分外部限制，形成不同于封闭模型公司的扩散式竞争策略。

So What 技术路线选择会影响成本、生态和供应链韧性，管理层需明确哪些能力自建、开源复用或采购闭源服务。

<https://m.huxiu.com/article/4882140.html>

#03 ★★★★★☆

IT之家 · 8 小时前

字节新设AI数据与安全一级部门 ↗

消息称字节跳动近期成立AI数据与安全一级部门，与Seed、Flow、抖音等平行，负责人为王赢磊，显示其把数据资产与安全治理提升到集团级。

So What 大模型竞争从模型能力转向数据与安全体系，企业AI组织也需把数据治理、安全合规纳入核心架构。

<https://www.ithome.com/0/988/429.htm>

#04 ★★★★★☆

新智元 · 9 小时前

HBM紧缺推动AI存储价值重估 ↗

报道称英伟达下一代GPU面临HBM供给约束，同时SSD、DRAM、HBM与新型存储边界因压缩、索引、记忆和上下文服务而重新划分。

So What AI基础设施瓶颈不只在GPU，采购和架构决策需纳入内存、存储、上下文缓存等全链路成本。

<https://aieca.com.cn/2026/08/11/other/admin/108575/%e8%8b%h1%e4%bc%9f%e8%be%be%hm%e5%9...8e%e5%a4%h4/>

#01 ★★★★★☆

虎嗅 · 30 分钟前

电商遭遇AI、合规与增长三重压力 ↗

电商行业同时面临增长见顶、AI改写运营方式、平台与监管合规收紧等压力，中小商家和从业者的传统流量打法收益下降。

So What 零售企业需从流量运营转向数据、供应链和AI效率竞争，同时预留合规成本，避免低质自动化放大风险。

<https://m.huxiu.com/article/4882289.html>

#02 ★★★★★☆

虎嗅 · 42 分钟前

AI短剧流量红利快速退潮 ↗

报道称AI短剧万播收益已降至10元以内，破亿率不足0.5%，大量同质化内容涌入导致分发和商业化效率下滑。

So What 生成式内容行业已从工具红利转入供给过剩，内容公司应控制投放和产能，转向IP、渠道和精细化运营。

<https://m.huxiu.com/article/4882286.html>

#03 ★★★★★☆

Hacker News · 46 分钟前

法国律师被建议用开源AI处理机密 ↗

Hacker News讨论称法国律师被建议在处理保密数据时使用开源AI模型，以降低将敏感法律信息提交给外部闭源服务的风险。

So What 专业服务业AI采用将更强调数据主权，律所、咨询和金融机构可评估私有化或本地开源模型方案。

<https://huggingface.co/blog/jedisct1/lawyers-and-local-ai>

#04 ★★★★★☆

IT之家 · 8 小时前

谷歌AI招聘工具遭内部质疑 ↗

谷歌向企业客户推广AI简历筛选工具，但其DeepMind部分团队在招聘时不愿完全交给AI，内部文件提示可能误筛候选人。

So What HR场景自动化要保留人工复核和审计机制，否则可能带来人才流失、歧视争议与雇主品牌风险。

<https://www.ithome.com/0/988/380.htm>

#01 ★★★★★

InfoQ · 26 分钟前

企业Agentic AI落地需聚焦ROI ↗

InfoQ文章提出，企业高管推动Agentic Enterprise时应关注三个关键因素，核心是围绕业务回报、流程重构和可度量结果设计落地路径。

So What

不要以试点数量衡量AI进展，应把Agent项目绑定收入、成本、周期或风险指标，建立退出机制。

<https://www.infoq.cn/article/fe63sM0T127Pu7QpHP3a>

#02 ★★★★★

InfoQ · 1 小时前

AI代理安全评估暴露系统漏洞 ↗

InfoQ报道，一系列事件显示AI前沿实验室在评估自主网络攻击能力时存在系统性漏洞，涉及Artifactory零日漏洞、沙箱逃逸和入侵Hugging Face。

So What

企业部署自主Agent必须按高危系统治理，强化沙箱、权限、供应链监控和红队测试，不能只看功能效率。

<https://www.infoq.cn/article/gkzDEyCF5U4DtKAa1Eee>

#03 ★★★★★☆

InfoQ · 7 小时前

DORA称AI开发效益取决于组织体系 ↗

DORA研究负责人指出，AI辅助开发更像“放大器”；若团队协作、交付流程和工程文化不足，AI可能放大低效而非提升绩效。

So What

软件团队引入AI前应先优化流程、质量门禁和度量体系，否则工具投入难以转化为稳定生产率提升。

<https://www.infoq.cn/article/1oV8oaYwzU15W5BdSL7C>

#04 ★★★★★☆

钛媒体 · 7 小时前

Zoho因AI成本压力自研服务器 ↗

钛媒体报道，在AI侵蚀SaaS利润后，Zoho选择自研服务器以控制基础设施成本和性能，反映SaaS厂商成本结构被AI推理重塑。

So What

SaaS企业应重新测算AI功能毛利，评估自建、混合云和模型压缩策略，避免增收不增利。

<https://www.tmtpost.com/8098550.html>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Opus 5 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		63.1
2	Claude Opus 5 R (Adaptive Reasoning, Xhigh Effort)	闭源未知	5/25	Anthropic · ...		62.5
3	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		62.1
4	Claude Opus 5 R (Adaptive Reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		61.5
5	GPT-5.6 Sol R (max)	闭源未知	5/30	OpenAI · 美国		60.9
6	Kimi K3 R (max)	闭源未知	3/15	Kimi · 中国		59.7
7	GPT-5.6 Sol R (xhigh)	闭源未知	5/30	OpenAI · 美国		59.0
8	Claude Opus 5 R (Adaptive Reasoning, Medium Effort)	闭源未知	5/25	Anthropic · ...		58.6
9	Qwen3.8 Max R	≈1T · 闭源	2/6	Alibaba · 中国		58.1
10	GPT-5.6 Sol R (high)	闭源未知	5/30	OpenAI · 美国		57.3
11	Muse Spark 1.2 R (xhigh)	闭源未知	1.25/4.25	Meta · 美国		56.8
12	GPT-5.6 Terra R (max)	闭源未知	2/12	OpenAI · 美国		56.6
13	Grok 4.5 R (high)	闭源未知	2/6	SpaceXAI · ...		55.8
14	GPT-5.6 Sol R (medium)	闭源未知	5/30	OpenAI · 美国		55.6
15	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	2/10	Anthropic · ...		55.3
16	GPT-5.6 Terra R (xhigh)	闭源未知	2/12	OpenAI · 美国		52.8
17	GLM-5.2 R (max)	745B MoE	1.4/4.4	Z AI · 中国		52.6
18	Claude Opus 5 R (Adaptive Reasoning, Low Effort)	闭源未知	5/25	Anthropic · ...		52.5
19	GPT-5.6 Luna R (max)	闭源未知	0.2/1.2	OpenAI · 美国		52.3
20	DeepSeek V4 Flash 0731 R (Reasoning, Max Effort)	≈671B ...	0.14/0.28	DeepSeek · ...		51.8

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>