

AI 简讯

2026年08月14日 周五 | 近 8 小时 AI 行业关键动向

SCANNED

420

条原始资讯

SOURCES

11

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

EXECUTIVE SUMMARY · 执行摘要

今天最值得管理者关注的是三件事：一是腾讯、智谱、SSI等继续推进模型与入口竞争，模型能力正在向编程、推理和超级应用内嵌演进；二是地方政策与资本市场加码算力、词元和机器人基础设施，但AI应用股波动提示商业化压力；三是企业落地重心从工具试用转向生产执行、组织改造和安全治理。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

ACTION ITEMS · 行动建议

01 盘点核心流程中可审计、可回滚的AI执行场景

02 建立多模型评测表，覆盖成本、代码能力和替换风险

03 将AI交付纳入安全审计、依赖治理和责任追踪

04 评估算力与Token成本对明年预算和供应商议价的影响

#01 ★★★★★

虎嗅 · 2 小时前

Anthropic估值逻辑引发市场关注 ↗

Anthropic被讨论至2万亿美元估值谜局，反映头部模型公司在收入、算力、资本预期之间的高张力。

So What 模型层估值继续推高行业基准，企业采购和投资需警惕供应商融资周期与价格策略变化。

<https://m.huxiu.com/article/4883136.html>

#02 ★★★★★☆

华尔街见闻 · 10 分钟前

腾讯微信强化自研大模型团队 ↗

腾讯混元资深研究员徐灿近期转岗微信WeLM，继续从事大模型研发；其此前负责混元LLM后训练方向。

So What 微信加速把模型能力内嵌到超级入口，企业需重新评估腾讯生态内的AI触达与服务分发机会。

<https://wallstreetcn.com/livenews/3149635>

#03 ★★★★★☆

华尔街见闻 · 3 小时前

智谱预告发布GLM-5.3模型 ↗

智谱称下一代GLM-5.3将强化编程能力，基于6月前代同一7000亿参数基础模型，目标缩小与头部模型差距。

So What 国产模型竞争焦点转向代码与复杂任务能力，技术选型应保留多模型评测和替换弹性。

<https://wallstreetcn.com/livenews/3149504>

#04 ★★★★★☆

新智元 · 9 小时前

Ilya新公司首个模型传出进展 ↗

SSI据称正在构建小型推理引擎，核心路线为测试时训练TTT，显示后训练与推理时计算仍是前沿方向。

So What 若推理时自适应路线成熟，模型能力与成本结构可能改变，企业应跟踪但避免过早绑定单一路线。

<https://aiera.com.cn/2026/08/14/other/admin/109002/ilya%e7%9a%84%e9%a6%96%e4%b8%aa%e6%86%ef%bc%81/>

#01 ★★★★★

华尔街见闻 · 47 分钟前

广州海珠发布词元经济扶持政策 ↗

海珠区发布“词元八条”和Token贷，单项扶持最高500万元，鼓励提升单位芯片词元产出效率。

So What

地方政策开始围绕算力产出效率配置金融资源，AI企业可把Token产能纳入融资与落地选址模型。

<https://wallstreetcn.com/livenews/3149601>

#02 ★★★★★☆

量子位 · 9 小时前

机器人算力需求两年增长十倍 ↗

机器人走向真实物理世界带动算力需求两年涨10倍，相关方案声称可降低一半成本、提升80%部署效率。

So What

具身智能的瓶颈正从算法扩展到算力与部署体系，制造企业需提前规划数据、仿真和算力预算。

<https://www.qbitai.com/2026/08/472722.html>

#03 ★★★☆☆

华尔街见闻 · 1 小时前

A股算力硬件板块集体走强 ↗

A股创业板指缩量涨超1%，CPO、PCB、半导体芯片股拉升，中石科技、剑桥科技等多股涨停。

So What

资本市场继续押注AI基础设施链条，硬件采购方需关注供需波动对交付周期和议价能力的影响。

<https://wallstreetcn.com/livenews/3149556>

#04 ★★★☆☆

华尔街见闻 · 2 小时前

港股AI应用股午后扩大跌幅 ↗

港股AI应用股午后走弱，MINIMAX跌超10%，智谱跌近6%，反映应用层估值承压。

So What

AI应用商业化验证压力上升，管理层应把用户留存、毛利和付费转化放在估值叙事之前。

<https://wallstreetcn.com/livenews/3149519>

#01 ★★★★★☆

Hacker News · 36 分钟前

企业AI从辅助转向执行落地 ↗

英文讨论聚焦企业如何把AI从信息辅助推进到任务执行，强调流程嵌入、权限边界和业务闭环。

So What

AI项目评估应从单点提效转向可控执行，优先选择高频、可审计、可回滚的业务流程试点。

<https://openai.com/index/how-enterprises-put-ai-to-work/>

#02 ★★★★★☆

InfoQ · 5 小时前

CTO讨论AI原生组织构建路径 ↗

InfoQ CTO圆桌总结AI原生工程组织三点：让AI进入生产、验证有效实践、把投资投向长期竞争优势。

So What

工程管理要从工具采购升级为组织设计，明确AI进入交付链路后的角色、指标和责任边界。

<https://www.infoq.cn/article/cFM02oN8SyaR9vuUVUeQ>

#03 ★★★★★☆

InfoQ · 6 小时前

IBM与红帽强化AI交付治理 ↗

IBM与Red Hat扩展Lightwell，面向AI参与软件交付场景加强开源软件信任、溯源与治理能力。

So What

当Agent开始改代码和交付产物，审计、签名、依赖治理将成为企业AI落地的硬门槛。

<https://www.infoq.cn/article/AJz1m242RSJLpXpsC1eg>

#04 ★★★☆☆☆

虎嗅 · 1 小时前

AI Agent使用转向注意力管理 ↗

文章提出企业使用AI Agent的重点从写好Prompt转向管理AI注意力，即约束目标、上下文和执行边界。

So What

管理者应把Agent当作受控流程节点设计，减少开放式任务，避免隐性成本和错误扩散。

<https://m.huxiu.com/article/4883143.html>

大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

#	模型	参数量	单价 \$/1M	厂商 · 国家	能力分布 (II)	分数
1	Claude Opus 5 R (Adaptive Reasoning, Max Effort)	闭源未知	5/25	Anthropic · ...		63.1
2	Claude Opus 5 R (Adaptive Reasoning, Xhigh Effort)	闭源未知	5/25	Anthropic · ...		62.5
3	Claude Fable 5 R (Adaptive Reasoning, Max Effort, Opus 4.8 Fallback)	闭源未知	10/50	Anthropic · ...		62.1
4	Claude Opus 5 R (Adaptive Reasoning, High Effort)	闭源未知	5/25	Anthropic · ...		61.5
5	GPT-5.6 Sol R (max)	闭源未知	5/30	OpenAI · 美国		60.9
6	Grok 4.6 R (high)	闭源未知	2/6	SpaceXAI · ...		60.9
7	Kimi K3 R (max)	闭源未知	3/15	Kimi · 中国		59.7
8	GPT-5.6 Sol R (xhigh)	闭源未知	5/30	OpenAI · 美国		59.0
9	Claude Opus 5 R (Adaptive Reasoning, Medium Effort)	闭源未知	5/25	Anthropic · ...		58.6
10	Qwen3.8 Max R	≈1T · 闭源	2/6	Alibaba · 中国		58.1
11	Qwen3.8 2.4T A95B R	闭源未知	2/6	Alibaba · 中国		57.7
12	GPT-5.6 Sol R (high)	闭源未知	5/30	OpenAI · 美国		57.3
13	Muse Spark 1.2 R (xhigh)	闭源未知	1.25/4.25	Meta · 美国		56.8
14	GPT-5.6 Terra R (max)	闭源未知	2/12	OpenAI · 美国		56.6
15	Gemini 3.7 Flash R (high)	闭源未知	0.75/3.75	Google · 美国		56.0
16	Grok 4.5 R (high)	闭源未知	2/6	SpaceXAI · ...		55.8
17	GPT-5.6 Sol R (medium)	闭源未知	5/30	OpenAI · 美国		55.6
18	Claude Sonnet 5 R (Adaptive Reasoning, Max Effort)	闭源未知	2/10	Anthropic · ...		55.3
19	Gemini 3.7 Flash R (medium)	闭源未知	0.75/3.75	Google · 美国		53.4
20	DeepSeek V4 Pro 0813 R (Reasoning, Max Effort)	≈671B ...	1.32/3.96	DeepSeek · ...		53.2

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>