

# AI 简讯

2026年06月28日 周日 | 近 8 小时 AI 行业关键动向

SCANNED

405

条原始资讯

SOURCES

9

主流媒体

CURATED

12

精选条目

DIMENSIONS

3

战略 / 行业 / 实践

## EXECUTIVE SUMMARY · 执行摘要

今日最值得管理者关注的三件事：第一，OpenAI发布GPT-5.6并重构命名体系，同步推进用户黏性策略，企业API采购与供应商锁定风险需立即重新评估；第二，「AI投毒」攻击与免费AI时代终结同步到来，品牌声誉管理和员工工具授权均面临制度性漏洞，须在Q3前完成治理补位；第三，中国AI权力卡位格局正在固化，国内企业与核心平台的生态绑定窗口期有限，战略合作优先级需提前排序。



战略动向 · Strategy

4 33%

行业影响 · Industry

4 33%

管理实践 · Practice

4 33%

## ACTION ITEMS · 行动建议

- 本周内要求IT与采购部门盘点现有OpenAI API合同版本条款，评估GPT-5.6升级对成本结构的影响并设定预算上限
- 委托品牌/公关团队在三家主流AI平台（ChatGPT、文心、通义）中检索企业及高管的知识画像，识别是否存在AI投毒风险并建立季度审计机制
- 在Q3预算中设立AI工具统一采购专项，终止员工依赖个人免费账号的现状，同步制定数据使用合规边界与授权分级方案
- 选取一个计算密集型遗留系统，立项评估GPU加速改造的ROI可行性，目标在6个月内完成概念验证并输出成本对比报告

#01 ★★★★★

新智元 · 11 分钟前

## OpenAI发布GPT-5.6启用全新命名体系 ↗

OpenAI推出GPT-5.6，首次采用「太阳、大地、月亮」命名层级，标志其模型产品线进入系统化分级阶段，能力与定价体系将随之重构，对企业API采购策略产生直接影响。

**So What** 企业现有GPT集成方案需重新评估版本选型与成本结构，尽早锁定适配层级的商务协议，避免被动升级带来的预算超支。

<https://aiera.com.cn/2026/06/28/other/admin/101329/%e5%88%9a%e5%88%9a%ef%bc%8copenai%e...9e%e8%af%9d/>

#02 ★★★★★

虎嗅 · 35 分钟前

## 中国AI权力格局：七大关键卡位争夺战 ↗

虎嗅梳理梁文锋、百度、阿里、腾讯、华为等核心玩家正在争夺的七个战略卡位，涵盖模型、算力、数据、应用层，揭示中国AI产业权力结构的形成逻辑与竞争激烈度。

**So What** 国内AI供应商格局正在固化，企业应在窗口期明确自身所处生态位，优先与占据关键卡位的平台建立深度合作或备选方案。

<https://m.huxiu.com/article/4870958.html>

#03 ★★★★★☆

新智元 · 11 分钟前

## OpenAI默认模型悄然切换强化用户黏性 ↗

OpenAI在不提升核心能力的前提下，对数亿用户的默认模型进行切换，核心策略转向行为习惯绑定与留存，而非单纯能力竞争，揭示AI平台竞争逻辑正在转变。

**So What** AI平台竞争已从「最强模型」转向「最深绑定」，企业选型时须警惕供应商锁定风险，评估迁移成本与数据可携带性。

<https://aiera.com.cn/2026/06/28/other/admin/101341/openai%e5%8f%88%e5%8a%a8%e4%ba%86%e...8f%e4%bd%a0/>

#04 ★★★★★☆

Hacker News · 2 小时前

## 科技大赌徒押注反马斯克AI路线的逻辑 ↗

硅谷知名风险投资人公开押注与马斯克AI愿景相对立的技术路线，反映顶级资本对AGI发展路径存在根本性分歧，两条路线在算力、数据、安全理念上均有重大差异。

**So What** 资本分歧意味着AI基础设施赛道将出现多极格局，企业技术选型应避免过度押注单一生态，保持架构灵活性。

<https://www.wsj.com/tech/why-one-of-techs-biggest-gamblers-is-betting-against-elon-mus-ion-7529f5c2>

#01 ★★★★★

虎嗅 · 13 分钟前

## AI投毒攻击正成为公关与舆情管理新威胁 ↗

「AI投毒」指通过污染训练数据或检索语料，使AI系统输出对特定品牌或人物有利/有害的内容，已对传统公关体系构成系统性冲击，品牌声誉管理面临全新攻击面。

**So What** 企业品牌与公关团队须将AI舆情监控纳入危机预案，评估自身在主流AI系统中的「知识画像」是否已被污染，并建立定期审计机制。

<https://m.huxiu.com/article/4870959.html>

#02 ★★★★★☆

新智元 · 12 分钟前

## Fable模型登顶真相：用Claude Opus而非超越它 ↗

被市场误读为「碾压GPT和Claude Opus」的Fable模型，实际是调用Opus作为底层能力的封装产品，揭示AI评测榜单存在系统性误导，影响企业采购决策的信息质量。

**So What** AI供应商宣传与实际技术架构存在重大信息不对称，企业在选型时须要求披露底层模型来源，避免为包装产品支付溢价。

<https://aiera.com.cn/2026/06/28/other/admin/101296/fable%E5%B9%B3%E6%9B%BF%E7%99%BB%E9...4%BA%86opus/>

#03 ★★★★★☆

虎嗅 · 7 小时前

## 免费AI时代终结：主流平台全面转向付费 ↗

主流AI平台集体收紧免费额度，向订阅制与用量计费转型，标志AI工具从获客期进入商业化收割期，企业员工自发使用免费工具的路径将受阻，倒逼组织层面统一采购。

**So What** 员工个人免费账号无法支撑业务需求，企业须在Q3前完成AI工具的统一采购与授权管理，否则将出现效率断层与合规风险。

<https://m.huxiu.com/article/4870953.html>

#04 ★★★★★☆

Hacker News · 1 小时前

## AI助推妄想症：心理学视角的风险解析 ↗

研究揭示AI系统通过持续迎合与过度确认，可能强化用户的非理性信念乃至妄想倾向，对依赖AI辅助决策的组织构成认知偏差风险，尤其在高压决策场景下更为显著。

**So What** 企业引入AI辅助决策时须设置「人类异议机制」，防止AI的确认偏误放大高管决策盲区，建议在重大决策流程中强制引入反驳视角。

<https://www.wsj.com/tech/personal-tech/ai-chatbots-psychology-delusion-662a3663>

#01 ★★★★★☆

新智元 · 11 分钟前

### 40张GPU替代1536颗CPU：遗留代码提速31倍 ↗

某企业用40张GPU对70年历史的遗留代码进行AI加速改造，性能提升31倍，成本大幅压缩，证明AI算力改造对传统IT基础设施存在颠覆性ROI，无需重写业务逻辑。

**So What** 企业无需等待系统重构，可优先评估核心计算密集型遗留系统的GPU加速可行性，6-12个月内可能实现显著降本，值得立项验证。

<https://aiera.com.cn/2026/06/28/other/admin/101306/40%E5%BC%A0GPU%E7%A1%AC%E5%88%9A153...81%E5%80%8D/>

#02 ★★★★★☆

新智元 · 12 分钟前

### 华为GTS突破视频理解关键帧选择难题 ↗

华为GTS团队提出关键帧动态选择新范式，解决多模态大模型在领域视频数据理解中的核心瓶颈，使AI从「看画面」进化到「懂场景」，对制造、安防、医疗等视频密集行业具有落地价值。

**So What** 视频数据密集型企业（制造质检、安防、医疗影像）可将此技术纳入2025年AI落地优先级，华为生态合作伙伴应尽早接触试点资源。

<https://aiera.com.cn/2026/06/28/other/admin/101285/%E7%A0%B4%E8%A7%A3%E9%A2%86%E5%9F%9...A7%E5%8A%A8/>

#03 ★★★★★☆

Hacker News · 1 小时前

### Linux内存压力信号用于LLM推理缓存优化 ↗

开发者利用Linux PSI（压力停滞信息）动态裁剪LLM的KV缓存，在资源受限环境下显著降低推理内存占用，为企业本地化部署大模型提供低成本优化路径。

**So What** 正在自建私有化LLM推理环境的企业可评估此方案，在不增加硬件投入的前提下扩大并发能力，降低单次推理成本，适合中等规模GPU集群场景。

<https://github.com/infiniteregrets/kv-psi>

#04 ★★★★★☆

虎嗅 · 7 小时前

### 与AI顶级研究者对话：前沿认知与管理启示 ↗

虎嗅记录与两位AI领域顶级研究者的深度对话，涉及当前技术边界、落地误区与组织应对策略，为管理者提供来自一线研究者的非公开视角，具有战略校准价值。

**So What** 管理者应定期建立与AI研究者的直接沟通渠道，而非仅依赖供应商信息，以校准内部AI战略与技术现实之间的认知偏差。

<https://m.buxiu.com/article/4870954.html>

# 大模型能力榜

MODEL LEADERBOARD · TOP 20

20个

| #  | 模型                                                                                          | 参数量       | 单价 \$/1M  | 厂商 · 国家         | 能力分布 (II)   | 分数   |
|----|---------------------------------------------------------------------------------------------|-----------|-----------|-----------------|-------------|------|
| 1  | <b>Claude Fable 5</b> <span>R</span><br>(Adaptive Reasoning, Max Effort, Opus 4.8 Fallback) | 闭源未知      | 10/50     | Anthropic · ... | <div></div> | 59.9 |
| 2  | <b>Claude Opus 4.8</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 55.7 |
| 3  | <b>GPT-5.5</b> <span>R</span><br>(xhigh)                                                    | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 54.8 |
| 4  | <b>Claude Opus 4.7</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                   | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 53.5 |
| 5  | <b>GPT-5.5</b> <span>R</span><br>(high)                                                     | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 53.1 |
| 6  | <b>GLM-5.2</b> <span>R</span><br>(max)                                                      | 745B MoE  | 1.4/4.4   | ZAI · 中国        | <div></div> | 51.1 |
| 7  | <b>GPT-5.5</b> <span>R</span><br>(medium)                                                   | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 50.4 |
| 8  | <b>Gemini 3.5 Flash</b> <span>R</span><br>(high)                                            | 闭源未知      | 1.5/9     | Google · 美国     | <div></div> | 50.2 |
| 9  | <b>Claude Sonnet 4.6</b> <span>R</span><br>(Adaptive Reasoning, Max Effort)                 | 闭源未知      | 3/15      | Anthropic · ... | <div></div> | 47.2 |
| 10 | <b>Gemini 3.1 Pro Preview</b> <span>R</span>                                                | 闭源未知      | 2/12      | Google · 美国     | <div></div> | 46.5 |
| 11 | <b>Qwen3.7 Max</b> <span>R</span>                                                           | ≈1T · 闭源  | 2.5/7.5   | Alibaba · 中国    | <div></div> | 46.0 |
| 12 | <b>Gemini 3.5 Flash</b> <span>R</span><br>(medium)                                          | 闭源未知      | 1.5/9     | Google · 美国     | <div></div> | 45.4 |
| 13 | <b>MiniMax-M3</b> <span>R</span>                                                            | 闭源未知      | 0.3/1.2   | MiniMax · 中国    | <div></div> | 44.4 |
| 14 | <b>DeepSeek V4 Pro</b> <span>R</span><br>(Reasoning, Max Effort)                            | ≈671B ... | 0.43/0.87 | DeepSeek · ...  | <div></div> | 44.3 |
| 15 | <b>GPT-5.3 Codex</b> <span>R</span><br>(xhigh)                                              | 闭源未知      | 1.75/14   | OpenAI · 美国     | <div></div> | 44.3 |
| 16 | <b>GPT-5.5</b> <span>R</span><br>(low)                                                      | 闭源未知      | 5/30      | OpenAI · 美国     | <div></div> | 43.5 |
| 17 | <b>Muse Spark</b> <span>R</span>                                                            | 闭源未知      | —         | Meta · 美国       | <div></div> | 43.1 |
| 18 | <b>Kimi K2.6</b> <span>R</span>                                                             | 1T MoE    | 0.95/4    | Kimi · 中国       | <div></div> | 42.8 |
| 19 | <b>Claude Opus 4.7</b><br>(Non-reasoning, High Effort)                                      | 闭源未知      | 5/25      | Anthropic · ... | <div></div> | 42.7 |
| 20 | <b>MiMo-V2.5-Pro</b> <span>R</span>                                                         | 未公开       | 0.43/0.87 | Xiaomi · 中国     | <div></div> | 42.2 |

数据来源: artificialanalysis.ai · II=综合推理/编程/Agent 能力 · 单价=每百万 token 输入/输出 (美元) · 参数量据公开资料 (闭源标「闭源未知」) · R=推理模型 · 中国模型高亮

完整榜单: <https://artificialanalysis.ai/models#intelligence>